Przeprowadzenie topology-aware ewaluacji wpływu narzutu SWAP i rozmieszczenia kubitów na skuteczność mitygacji błędów oraz kodowania logicznego na sprzęcie nadprzewodzącym

Karina Leskiewicz

8 września 2026

Spis treści

1 Wprowadzenie **2**
- 1.1 Dlaczego mitygacja błędów jest dziś konieczna . . . 2
- 1.2 Rodzina metod i ich założenia . . . 3
- 1.3 Zmienna porównawcza: narzut routingu . . . 3
- 1.4 Problem badawczy: granice użyteczności metody . . . 3
- 1.5 Cel pracy i luka badawcza . . . 4

2 Metodologia **5**
- 2.1 Definicje i konwencje . . . 5
- 2.2 Taksonomia błędów: koherentne i niekoherentne . . . 6
- 2.3 Urządzenia, rozmieszczenia i drabina routingu . . . 7
- 2.4 Obwód testowy: zbiór danych, ansatz, kodowanie i odczyt . . . 8
- 2.5 Metody mitygacji: założenia, konstrukcja i granice . . . 10
- 2.6 Circuit twirling (randomized compiling) . . . 12
- 2.7 Protokół statystyczny . . . 14

3 Walidacja potoku i punkt wyjścia: ODRA **15**

4 Wynik 1: załamanie jest topologicznie ogólne **16**

5 Wynik 2: mechanizmem jest błąd koherentny **17**

6 Wynik 3: twirling przywraca skuteczność CDR na sprzęcie **19**

7 Wynik 4: progi rozdzielone po urządzeniach **21**

8 Pozostałe rezultaty **26**
- 8.1 Mitygacja błędu odczytu na klasyfikatorze wariacyjnym . . . 27

9 Wnioski **28**

A Odtwarzalność: repozytorium **29**

Streszczenie

Komputery kwantowe ery NISQ dysponują dziś dziesiątkami kubitów o wierności bramek dwukubitowych rzędu 99%. Pełna korekcja błędów pozostaje poza zasięgiem, ponieważ wymaga zakodowania jednego kubita logicznego w setkach lub tysiącach kubitów fizycznych. Aby uzyskiwać wyniki *teraz*, trzeba radzić sobie z nieskorygowanym szumem, a jedynym praktycznym narzędziem jest *mitygacja* błędów (QEM). Metody mitygacji nie działają jednak bezwarunkowo: każda zakłada określony model szumu, każda ma własny narzut pomiarowy i każda przestaje się opłacać poza pewnym reżimem. Praca poszukuje usystematyzowanego sposobu oceny, które metody mają szansę pomóc w konkretnych warunkach.

Jako zmienną porządkującą przyjęto *narzut routingu*: bramki SWAP, które kompilator musi wstawić, gdy obwód logiczny nie odwzorowuje topologii urządzenia. Ustalono obciążenie obliczeniowe (zamrożony klasyfikator wariacyjny) i zmieniamy wyłącznie koszt routingu, mierząc na trzech rzeczywistych procesorach nadprzewodzących IQM: **ODRA** (Spark, 5 kubitów, topologia gwiazdy), **Garnet** (20 kubitów, krata) oraz **Emerald** (54 kubity, krata, klasycznie niesymulowalny). Ten sam obwód logiczny kosztuje na nich od 12 do 114 bramek CZ.

Wyłania się z tego usystematyzowany obraz reżimów. Trzy metody okazują się w tym obciążeniu bezużyteczne: mitygacja błędu odczytu (REM) zmniejsza błąd wartości oczekiwanej, lecz nie zmienia *żadnej* decyzji klasyfikatora, dynamiczne odsprzęganie (DD) pogarsza wynik w każdym punkcie drabiny, a detekcja w kodzie $[[4, 2, 2]]$ nie zwraca kosztu post-selekcji. Praktyczny wybór sprowadza się do dwóch pozostałych.

Ekstrapolacja do zerowego szumu (ZNE) wygrywa poniżej punktu równowagi w okolicy 39 bramek CZ i jest tam siedmiokrotnie tańsza od regresji danych Clifforda (CDR). Jej okno użyteczności jest jednak ograniczone z *obu* stron, a dolną krawędź tego okna wyprowadzono analitycznie z konstrukcji estymatora Richardsona i potwierdzono na sprzęcie dla dwóch różnych zbiorów węzłów ekstrapolacji, bez ani jednego parametru dopasowywanego do danych. Powyżej punktu równowagi najlepsze wyniki daje CDR, lecz i ona załamuje się w sposób *topologicznie ogólny*: jakość dopasowania liniowego r^2 spada monotonicznie z liczbą bramek dwukubitowych na wszystkich trzech urządzeniach.

Zidentyfikowano mechanizm tego załamania – błąd *koherentny* naruszający założenie liniowości – oraz interwencję, która go neutralizuje. *Circuit twirling* przywraca skuteczność CDR na żywym sprzęcie, przy czym zysk okazuje się przewidywalny: koreluje z jakością dopasowania bez twirlingu ($\rho = -0{,}85$, $p = 0{,}004$), a nie bezpośrednio z liczbą bramek. Jest tym większy, im bardziej koherencja wcześniej zepsuła liniowość. Daje to regułę decyzyjną możliwą do zastosowania *przed* wydaniem czasu maszynowego. Współczynnik r^2 powstaje jako produkt uboczny samej procedury CDR, więc kosztuje zero dodatkowych obwodów, a mimo to mówi, czy w danym przebiegu warto uruchamiać twirling – w odróżnieniu od liczby bramek, która informuje jedynie o tym, ile koherencji *mogło* narosnąć.

1 Wprowadzenie

1.1 Dlaczego mitygacja błędów jest dziś konieczna

Korekcja błędów (QEC) koduje jeden kubit *logiczny* w setkach kubitów *fizycznych* i naprawia błędy w trakcie obliczenia. Próg opłacalności tej konstrukcji został niedawno przekroczony [23], ale na sprzęcie o skali niedostępnej typowemu użytkownikowi.

Kto chce liczyć *teraz*, musi radzić sobie z nieskorygowanym szumem. Służy do tego **mitygacja** (QEM): techniki, które nie usuwają błędu z obliczenia, lecz odzyskują poprawną wartość oczekiwaną z zaszumionych pomiarów – kosztem dodatkowych powtórzeń, wiedzy o urządzeniu albo obu naraz [1]. Praktycznie każdy współczesny eksperyment sprzętowy raportuje wyniki po mitygacji.

1.2 Rodzina metod i ich założenia

Metody QEM nie są wymienne: każda celuje w inny kanał błędu i opiera się na innym założeniu.

- **REM** (mitygacja błędu odczytu) koryguje wyłącznie pomyłki detektora, odwracając macierz przejścia wyznaczoną z kalibracji [24, 25]. Nie dotyka błędów bramkowych.
- **DD** (dynamiczne odsprzęganie) tłumi defazowanie w okresach bezczynności przez sekwencje impulsów refokusujących. Zakłada, że otoczenie zmienia się *wolniej* niż trwa sama sekwencja impulsów – inaczej impuls odwracający nie trafia już w to samo zaburzenie, które miał odwrócić.
- **ZNE** (ekstrapolacja do zerowego szumu) celowo *wzmacnia* szum i ekstrapoluje wynik do granicy bezszumowej [2, 3, 4]. Zakłada gładką zależność wartości oczekiwanej od siły szumu.
- **CDR** (regresja danych Clifforda) uczy się poprawki na obwodach bliskich Cliffordowskim, które da się zasymulować klasycznie [5]. Zakłada *liniową* zależność między wartością zaszumioną a idealną.
- **Twirling** (randomized compiling) nie koryguje wyniku, lecz *przekształca charakter szumu* z koherentnego na stochastyczny [6, 7]. Jest komponentem przygotowawczym dla metod, które stochastyczności wymagają [10].
- **Detekcja** w kodzie $[[4, 2, 2]]$ wykrywa pojedyncze błędy i odrzuca skażone przebiegi [13, 14]. Zakłada obwód Cliffordowski.

1.3 Zmienna porównawcza: narzut routingu

Metody QEM charakteryzuje się w literaturze na *ustalonych* obwodach i opisuje parametrami szumu urządzenia. Na rzeczywistym sprzęcie pojawia się jednak zmienna, która w takim ujęciu jest niewidoczna: **obwód, który się zapisuje, nie jest obwodem, który się wykonuje**. Procesor nadprzewodzący ma ustaloną, rzadką mapę sprzężeń – bramkę dwukubitową można wykonać tylko między kubitami fizycznie sąsiadującymi. Kompilator uzupełnia więc obwód o bramki SWAP [15], a każda z nich kosztuje kolejne operacje dwukubitowe. Wielkość tego narzutu zależy od topologii urządzenia oraz od tego, na których fizycznych kubitach obwód umieszczono: w tym badaniu ten sam obwód logiczny kosztuje od 12 do 114 bramek CZ.

1.4 Problem badawczy: granice użyteczności metody

Naturalne wydaje się stwierdzenie, że im mniej szumu, tym lepiej dla metod mitygacji. Wyniki pokazują jednak, że jest to założenie fałszywe. Skuteczność metody zależy od tego, czy jej założenie jest spełnione przy danym poziomie szumu – a nie od tego, czy szumu jest mało. Ekstrapolacja ZNE ilustruje to najostrzej: przy zbyt *dużym* szumie sygnał osiąga podłogę obserwabla i nie ma czego ekstrapolować, ale przy zbyt *małym* usuwany błąd systematyczny nie pokrywa już kosztu wzmocnionej wariancji, więc metoda również szkodzi [20]. Podobnie CDR: załamuje się nie dlatego, że szumu jest „dużo", lecz dlatego, że wraz z głębokością obwodu zmienia się jego *charakter* na bardziej koherentny, co łamie założenie liniowości.

W konsekwencji użycie metody mitygacji może dać wynik *gorszy* niż jej niezastosowanie.

1.5 Cel pracy i luka badawcza

Celem pracy jest **usystematyzowana charakterystyka reżimów opłacalności** metod QEM na rzeczywistym sprzęcie, uporządkowana według narzutu routingu i rozdzielona po topologiach – prowadząca do reguł decyzyjnych: *którą metodę wybrać przy danym budżecie bramek, budżecie pomiarów i charakterze szumu urządzenia.*

Prace nad kompozycją metod [10, 11, 12] analizują *ustalone* obwody. Nie udało się znaleźć charakterystyki, która traktowałaby **narzut routingu jako zmienną niezależną** i rozdzielała skuteczność metod **po topologiach** rzeczywistych urządzeń. Nie odnotowano też użycia **jakości dopasowania CDR jako diagnostyki koherencji** szumu obwodu. Ta ostatnia luka jest szczególnie warta uwagi, bo dotyczy wielkości, którą i tak się liczy. Kanał depolaryzujący skaluje wartość oczekiwaną przez stałą, więc *zachowuje* liniowość niezależnie od tego, jak jest silny; błąd koherentny wprowadza zależność typu $\cos(N\theta)$ i liniowość *łamie*. Współczynnik r^2 dopasowania CDR rozróżnia zatem *rodzaje* szumu, a nie tylko jego wielkość. Powstaje przy tym jako produkt uboczny procedury, którą użytkownik wykonuje tak czy inaczej, w odróżnieniu od dedykowanych eksperymentów typu unitarity RB. Kontrolowane są natomiast jawnie dwie znane pułapki benchmarkingu mitygacji: pozorne poprawy ZNE przy kolapsie sygnału [19] oraz skończono-pomiarową granicę jej opłacalności [20]. Najbliższa przyjętemu tu ujęciu jest praca [22], w której cykliczne permutacje rozmieszczeń kubitów służą jako *mechanizm skalowania szumu* dla ZNE – rozmieszczenie jest tam więc narzędziem mitygacji, tu zaś zmienną niezależną wyznaczającą koszt.

Wkład pracy

1. **Charakterystyka reżimów**: trzy metody (bez mitygacji, CDR, ZNE) zmierzone na wspólnej osi kosztu routingu na trzech rzeczywistych topologiach, uzupełnione o trzy ramiona zbadane punktowo (REM i dynamiczne odsprzęganie na ODRZE, twirling na Garnecie) oraz ramię detekcji $[[4, 2, 2]]$, zamknięte jako wynik negatywny.

2. **Prawo topologicznie ogólne**: jakość dopasowania liniowego CDR spada monotonicznie z kosztem routingu na każdym z badanych urządzeń (Sekcja 4).

3. **Mechanizm**: załamanie jest sygnaturą błędu koherentnego, oddzieloną od szumu niekoherentnego przez kontrolę zerową i kontrolę z wstrzykniętą koherencją (Sekcja 5).

4. **Interwencja**: circuit twirling przywraca skuteczność CDR, a wielkość zysku jest przewidywalna ze stopnia zniszczenia liniowości (Sekcja 6).

5. **Granica opłacalności ZNE – wyprowadzona i potwierdzona pomiarem.** Z samej konstrukcji estymatora Richardsona wyprowadzamy próg budżetu pomiarów $S^* = \kappa V/B^2$ ze stałą κ zależną *wyłącznie* od wyboru węzłów ekstrapolacji, a następnie potwierdzamy go na sprzęcie dla dwóch różnych zbiorów węzłów, bez ani jednego parametru dopasowywanego do danych (Sekcja 7). Jako reguła decyzyjna „pomoże czy zaszkodzi" przewiduje poprawnie 6 z 7 punktów sprzętowych – a jedyny wyjątek należy do drugiego, niezależnie zidentyfikowanego reżimu (kolaps sygnału).

6. **Progi i reguły decyzyjne**: punkt równowagi ZNE $\leftrightarrow$ CDR, obustronne okno użyteczności ZNE oraz próg pełnego kolapsu (Sekcja 7).

7. **Wkład metodologiczny**: kontrola zrównana na liczbie pomiarów oraz reguła decyzji oparta na symulowanym poziomie zerowym – bez nich naiwne porównanie wytwarza pozorny zysk porównywalny z badanym efektem (Sekcja 2.7).

2 Metodologia

Ten sam klasyfikator wariacyjny – z zamrożonymi wagami, tym samym obserwablem i tą samą metryką – uruchamiamy na trzech topologiach i przy czterech wzorcach splątania, które różnią się wyłącznie liczbą bramek dwukubitowych po transpilacji. Zmienną jest zatem tylko koszt routingu.

2.1 Definicje i konwencje

Obwód logiczny a obwód wykonany. Obwód *logiczny* to ten, który zapisuje autor algorytmu; zakłada on, że dowolne dwa kubity można ze sobą splątać. Rzeczywiste urządzenie nadprzewodzące ma jednak ustaloną *mapę sprzężeń* – bramkę dwukubitową można wykonać tylko między kubitami fizycznie połączonymi. Kompilator (transpiler) uzupełnia więc obwód o bramki **SWAP**, które przesuwają stany kubitów po urządzeniu, aż znajdą się obok siebie. Obwód *wykonany* zawiera zatem operacje, których w obwodzie logicznym nie było. Różnica między nimi to **narzut routingu**.

Koszt routingu. Jako miarę narzutu przyjęto **liczbę bramek CZ po transpilacji**: liczbę natywnych bramek dwukubitowych w obwodzie faktycznie wykonanym na urządzeniu. Ta sama funkcja logiczna może odpowiadać bardzo różnym wartościom tej wielkości – w tym badaniu od 12 do 114 – w zależności od topologii i rozmieszczenia. Alternatywne miary (liczba SWAP, głębokość, sumaryczna odległość topologiczna) analizujemy w Sekcji 8.

Wyniki pracy precyzują granicę zastosowania tej osi. Jako zmienna *porządkująca* degradację liczba CZ sprawdza się bez zastrzeżeń: r^2 spada wraz z nią monotonicznie na każdym urządzeniu. Jako *predyktor* zysku z konkretnej interwencji jest natomiast jedynie pośrednikiem – zysk z twirlingu koreluje z liczbą CZ nieistotnie, a z faktycznym stopniem zniszczenia liniowości silnie (Sekcja 6). Liczba CZ pozostaje więc właściwą osią kosztu, ale nie zastępuje pomiaru samego założenia metody.

„Funkcja routingu". Stwierdzenie, że skuteczność metody jest *funkcją routingu*, rozumie się przez to, że wielkość poprawy wnoszonej przez metodę mitygacji zależy od kosztu routingu obwodu, a nie jest stałą charakteryzującą samą metodę.

Błąd wartości oczekiwanej. Metryka pierwotna,

$$\varepsilon \;=\; \frac{1}{|X|}\sum_{x\in X}\big|\,\langle O\rangle_x^{\text{zmierzone}} - \langle O\rangle_x^{\text{idealne}}\,\big|, \tag{1}$$

gdzie X jest ustalonym zbiorem punktów ewaluacyjnych, a $\langle O\rangle^{\text{idealne}}$ pochodzi z dokładnej symulacji wektora stanu. Jest to metryka ciągła i tania statystycznie – w odróżnieniu od dokładności klasyfikacji, która jest decyzją znaku i ma wysoką wariancję. Ponieważ obserwabl przyjmuje wartości z przedziału $[-1, 1]$, formalnie $\varepsilon \in [0, 2]$; w zebranych pomiarach mieści się w [0,02; 0,31]. **Wartością docelową jest** $\varepsilon = 0$, a metodę uznaje się za opłacalną wtedy, gdy obniża ε względem wyniku niemitygowanego przy zrównanym budżecie pomiarów.

Jakość dopasowania r^2. Metoda CDR zakłada, że wartość zaszumiona i idealna wiążą się zależnością liniową. Dopasowując prostą $\langle O\rangle^{\text{idealne}} \approx a\,\langle O\rangle^{\text{zaszumione}} + b$ do zbioru obwodów treningowych, definiuje się

$$r^2 \;=\; 1 - \frac{\sum_i \big(y_i - \hat{y}_i\big)^2}{\sum_i \big(y_i - \bar{y}\big)^2}, \tag{2}$$

gdzie y_i to wartości idealne obwodów treningowych, $\hat{y}_i$ – wartości przewidziane przez dopasowaną prostą, a $\bar{y}$ – średnia. **Wartością docelową jest** $r^2 = 1$: wartość ta oznacza, że punkty leżą dokładnie na prostej, czyli że założenie CDR jest spełnione idealnie. Wartość bliska zeru oznacza, że zależność liniowa nie opisuje danych (formalnie r^2 może być ujemne, gdy dopasowanie jest gorsze od stałej; w zebranych pomiarach mieści się w [0,57; 0,98]). Jako próg załamania przyjęto $r^2 < 0{,}8$.

Wielkością wiodącą jest r^2, a nie surowy błąd ε, ponieważ ε *saturuje*: gdy stan wyjściowy zbliża się do maksymalnie zmieszanego, błąd przestaje rosnąć, mimo że obwód nadal się pogarsza. Widać to w korelacjach z kosztem routingu – ε daje Spearmana +0,50 na Garnecie i +0,80 na Emeraldzie, podczas gdy r^2 daje −1,00 na każdym urządzeniu. Współczynnik r^2 pozostaje więc czuły w całym badanym zakresie.

r^2 jako sonda charakteru szumu. Kluczowa dla całej pracy jest następująca obserwacja: r^2 **nie mierzy jedynie jakości dopasowania, lecz stopień, w jakim spełnione jest założenie fizyczne stojące za CDR** – a ponieważ założenie to jest spełnione przez jeden rodzaj szumu, a łamane przez inny, wielkość ta rozróżnia *rodzaje* błędu, nie tylko ich wielkość.

Rozumowanie jest następujące. Kanał depolaryzujący o prawdopodobieństwie p, przyłożony do N bramek, przekształca wartość oczekiwaną w sposób *dokładnie* liniowy:

$$\langle O \rangle^{\text{zaszumione}} \;=\; (1-p)^N \, \langle O \rangle^{\text{idealne}}, \tag{3}$$

czyli daje postać $\langle O \rangle^{\text{idealne}} = a \, \langle O \rangle^{\text{zaszumione}}$ ze współczynnikiem $a = (1-p)^{-N}$ i wyrazem wolnym $b = 0$. Cały wpływ szumu sprowadza się do jednej stałej skalującej, identycznej dla obwodów treningowych i docelowego – *niezależnie od tego, jak duże jest p*. Regresja odtwarza tę stałą, a punkty leżą na prostej: $r^2 \to 1$. Analogicznie zachowuje się relaksacja termiczna, która dokłada jedynie stały wyraz wolny $b \neq 0$.

Błąd koherentny działa inaczej. Systematyczny nadobrót o kąt θ na bramkę daje po N bramkach przekręcenie o $N\theta$, a wpływ na wartość oczekiwaną ma postać $\cos(N\theta)$ – funkcję, która nie jest liniowa, zależy od *stanu* obwodu i potrafi zmienić znak. Obwody treningowe (bliskie Cliffordowi) i obwód docelowy (o kątach ciągłych) doświadczają jej w różnym stopniu, więc jedna prosta przestaje je opisywać i r^2 spada.

Konsekwencja jest praktyczna i stanowi jeden z głównych wkładów tej pracy: **spadek r^2 nie oznacza po prostu „więcej szumu", lecz „szum innego rodzaju"**. Wysokie r^2 przy dużym błędzie mówi, że szum jest stochastyczny – CDR sobie poradzi, a twirling nie ma czego naprawiać. Niskie r^2 mówi, że narosła koherencja i że opłaca się ją usunąć. Wielkość ta jest *darmowa*: powstaje jako produkt uboczny samej procedury CDR, więc nie wymaga ani jednego dodatkowego obwodu, w odróżnieniu od dedykowanych eksperymentów typu unitarity RB czy cycle benchmarking. Hipotezę tę weryfikujemy bezpośrednio w Sekcji 5, porównując zachowanie r^2 pod szumem znanego rodzaju.

Efektywna liczba pomiarów. Metody mitygacji różnią się kosztem, więc porównuje się je przy zrównanym budżecie. Jeżeli pojedynczy obwód wymaga S pomiarów, to koszt efektywny wynosi S dla pomiaru bez mitygacji, $|\Lambda| \cdot S$ dla ZNE o $|\Lambda|$ współczynnikach skalowania, $(n_{\text{train}}+1) \cdot S$ dla CDR, oraz $M \cdot S$ dla twirlingu uśrednianego po M randomizacjach. Koszty te mnożą się przy składaniu metod.

2.2 Taksonomia błędów: koherentne i niekoherentne

Rozróżnienie dwóch rodzajów błędu jest osią całej pracy, dlatego omawiamy je osobno.

Błąd niekoherentny (stochastyczny). Kanał depolaryzujący z prawdopodobieństwem p zastępuje stan stanem maksymalnie zmieszanym:

$$\mathcal{E}_{\mathrm{dep}}(\rho) \;=\; (1-p)\,\rho \;+\; p\,\frac{\mathbb{I}}{2^n}. \tag{4}$$

Dla obserwabla bezśladowego (jak zastosowane tu średnie Z) drugi człon nie wnosi wkładu, więc

$$\langle O\rangle_{\mathrm{zaszumione}} \;=\; (1-p)\,\langle O\rangle_{\mathrm{idealne}}. \tag{5}$$

Po N bramkach daje to $\langle O\rangle \to (1-p)^N \langle O\rangle_{\mathrm{idealne}} \approx e^{-Np}\langle O\rangle_{\mathrm{idealne}}$. *Niezależnie od liczby bramek pozostaje to przeskalowanie o stały czynnik* – kierunek stanu nie ulega zmianie, maleje jedynie jego długość. Błąd kumuluje się **w prawdopodobieństwie**: rośnie jak $\sim Np$.

Błąd koherentny. Jest to systematyczne, deterministyczne przekręcenie – na przykład niedokładnie skalibrowana bramka obracająca stan o θ za dużo:

$$\mathcal{E}_{\mathrm{koh}}(\rho) \;=\; U_\theta\,\rho\,U_\theta^\dagger, \qquad U_\theta = e^{-i\theta P/2}, \tag{6}$$

gdzie P jest pewnym operatorem Pauliego. Kanał ten jest *unitarny*: nie zmniejsza czystości stanu, tylko go obraca. Skutki są dwa i oba mają znaczenie.

Po pierwsze, **kumulacja jest szybsza**. Dwa kolejne przekręcenia o θ dają obrót o 2θ, a po N bramkach – o $N\theta$. Ponieważ niewierność rośnie jak kwadrat amplitudy, błąd skaluje się jak $\sim (N\theta)^2$, podczas gdy dla szumu stochastycznego jak $\sim Np$. Przy $N = 100$ i $\theta = 0{,}01$ daje to wkład rzędu jedności wobec $\sim 10^{-2}$ dla porównywalnego błędu stochastycznego – różnicę dwóch rzędów wielkości. *Głębokie obwody – a więc obwody o dużym narzucie routingu – są zatem nieproporcjonalnie wrażliwe właśnie na błąd koherentny.*

Po drugie, **zależność między wartością idealną a zaszumioną przestaje być prostym przeskalowaniem**. Obrót wprowadzony przez U_θ działa różnie na stany o różnej orientacji, więc odwzorowanie $\langle O\rangle_{\mathrm{idealne}} \mapsto \langle O\rangle_{\mathrm{zaszumione}}$ zależy od konkretnego stanu, a nie tylko od liczby bramek. Zestawiając to z równaniem (5):

szum niekoherentny	$\langle O\rangle_{\mathrm{zasz.}} = \lambda\,\langle O\rangle_{\mathrm{ideal.}}$	– prosta przez początek układu
szum koherentny	$\langle O\rangle_{\mathrm{zasz.}} = f(\langle O\rangle_{\mathrm{ideal.}}, \text{kierunek stanu})$	– zależność nieliniowa

Pierwszy przypadek to *dokładnie* model, który zakłada CDR – stąd wysokie r^2. Drugi ten model narusza – stąd spadek r^2. **To jest mechanizm, wokół którego zbudowana jest cała praca**, i zarazem uzasadnienie, dlaczego r^2 może służyć jako sonda koherencji.

2.3 Urządzenia, rozmieszczenia i drabina routingu

Badanie obejmuje trzy topologie nadprzewodzące o rosnącym rozmiarze i odmiennej łączności.

Ponieważ obwód logiczny zajmuje pięć kubitów, a urządzenia mają ich 20 lub 54, o koszcie routingu decyduje *rozmieszczenie* (ang. *placement*) kubitów logicznych na fizycznych. Stosujemy dwie strategie: **optimal** – zwarty klaster sąsiadujących kubitów, minimalizujący liczbę wymuszonych bramek SWAP – oraz **adverse** – zbiór rozproszony po urządzeniu, celowo maksymalizujący narzut routingu. Rozmieszczenia dla Garneta wyznaczono z żywej mapy sprzężeń (`optimal` $= [3, 0, 2, 4, 8]$, `adverse` $= [0, 16, 12, 5, 18]$); dla Emeralda wyprowadzono je algorytmicznie (zwarty klaster oraz próbkowanie najdalszych punktów; `optimal` $= [10, 1, 9, 11, 19]$, `adverse` $= [0, 53, 6, 30, 45]$) i zweryfikowano testem kontrolnym na sprzęcie przed właściwą kampanią.

Iloczyn strategii rozmieszczenia i wzorca splątania (`star`, `linear`, `circular`, `all_to_all`) daje **drabinę routingu** – uporządkowany zbiór punktów pracy o rosnącej liczbie skompilowanych bramek CZ. Jako oś kosztu przyjęto **liczbę bramek CZ po transpilacji**, ponieważ jest ona bezpośrednio mierzalna, wspólna dla wszystkich urządzeń i najsilniej skorelowana z degradacją wyniku (Sekcja 8). Zrealizowane drabiny obejmują: ODRA 12–54 CZ, Garnet 12–96 CZ, Emerald 21–114 CZ.

2.4 Obwód testowy: zbiór danych, ansatz, kodowanie i odczyt

Zbiór danych. Obciążeniem głównym jest `two_curves` – syntetyczny zbiór klasyfikacyjny z pakietu `qml-benchmarks` [18], w którym dwie klasy leżą na dwóch krzywych zanurzonych w przestrzeni cech. Używamy wariantu *trudnego*: 8 cech, stopień krzywej 8, odstęp między krzywymi `offset` = 0,1, szum 0,01, 300 próbek. Wybór wariantu trudnego jest celowy – zadanie zbyt łatwe pozostawałoby poprawnie klasyfikowane mimo znacznego szumu, co uniemożliwiałoby obserwację degradacji. Dokładność bezszumowa wynosi 0,725 na zbiorze testowym.

Kodowanie danych i jego uzasadnienie. Cechy wprowadzamy metodą *data re-uploading*: ten sam wektor cech kodujemy w kątach obrotów $R_y(x)$ wielokrotnie – w każdej z L warstw ansatzu, przeplatając go warstwami parametrów trenowalnych (Rys. 1). Wybór ten jest optymalny w świetle wyniku Schulda, Swekego i Meyera [16], którzy wykazali, że model wariacyjny z kodowaniem kątowym realizuje *skończony szereg Fouriera* zmiennej wejściowej:

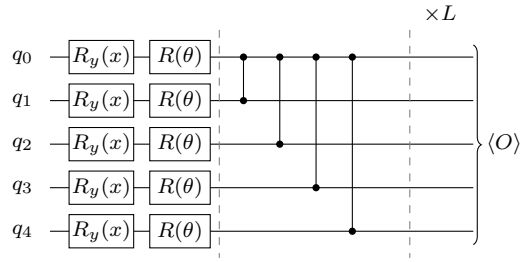
$$f_{\boldsymbol{\theta}}(x) \;=\; \sum_{\omega \in \Omega} c_\omega(\boldsymbol{\theta})\, e^{i\omega x}, \tag{7}$$

przy czym rolę obu składników pełnią *różne* części obwodu. Zbiór dostępnych częstotliwości Ω jest wyznaczony **wyłącznie przez sposób kodowania danych** – konkretnie przez widmo wartości własnych generatorów bramek kodujących – natomiast parametry trenowalne wpływają *tylko* na współczynniki c_ω. Konsekwencja jest istotna: *żadne zwiększanie liczby parametrów nie doda modelowi częstotliwości, których nie wprowadziło kodowanie.* Jeżeli funkcja docelowa zawiera składowe spoza Ω, model nie potrafi jej wyrazić niezależnie od tego, jak długo go trenujemy.

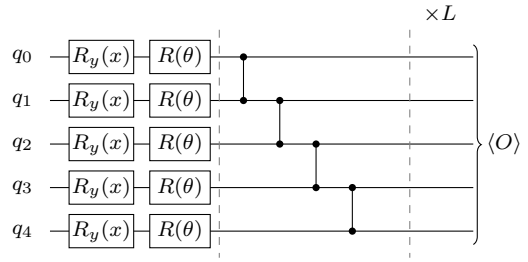
Dla pojedynczego kodowania generatorem R_y widmo obejmuje jedną częstotliwość na cechę, co ogranicza model do funkcji niemal liniowych w $\sin$ / $\cos$ cechy. L-krotne powtórzenie kodowania poszerza Ω do zbioru zawierającego wielokrotności częstotliwości bazowej, dając model zdolny reprezentować funkcje wyższych rzędów [16, 17]. Ponieważ badane zadanie ma stopień 8, pojedyncze kodowanie byłoby *strukturalnie* niewystarczające, niezależnie od jakości optymalizacji. Trzy warstwy przyjęto jako kompromis: zapewniają widmo wystarczające dla zadania, przy koszcie routingu na tyle umiarkowanym, by drabina obejmowała także punkty o niskim narzucie (co, jak pokazano w Sekcji 7, jest istotne dla zbadania dolnej granicy opłacalności ZNE).

Ansatz. Zastosowano ansatz *hardware-efficient* o 5 kubitach i 3 warstwach, z 55 parametrami trenowalnymi. Każda warstwa składa się z bloku kodowania cech, bloku obrotów trenowalnych oraz bloku splątującego zbudowanego z bramek CX. Blok splątujący występuje w czterech wariantach (Rys. 1), które różnią się *liczbą i zasięgiem* par splątanych, a tym samym – po transpilacji – kosztem routingu. To właśnie ten wybór, wraz ze strategią rozmieszczenia, generuje drabinę 12–114 bramek CZ.

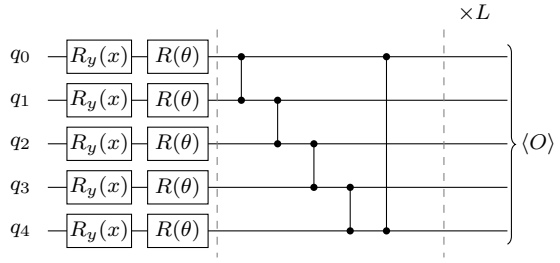
Zamrożony model. Wagi trenowano *raz* i zapisujemy wraz z bezszumową wartością odniesienia; wszystkie dalsze uruchomienia – symulacyjne i sprzętowe – korzystają z identycznego, w pełni



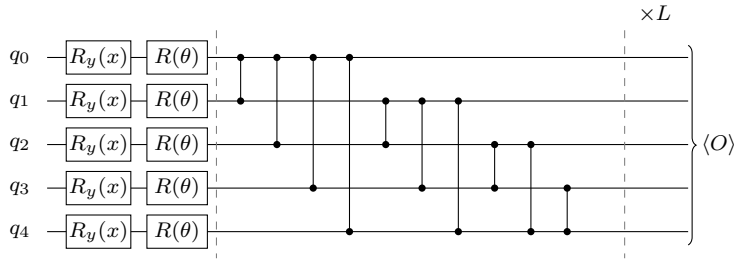
(a) **star** – hub q_0 splata się z każdym pozostałym kubitem; 4 bramki CZ na warstwę. Po transpilacji: **12 CZ** (optimal) / **36 CZ** (adverse).



(b) **linear** – łańcuch sąsiadów; 4 bramki CZ na warstwę. Po transpilacji: **24 CZ** / **42 CZ**.



(c) **circular** – łańcuch domknięty w ring; 5 bramek CZ. Po transpilacji: **39 CZ** / **54 CZ**.



(d) **all-to-all** – każda para kubitów; 10 bramek CZ na warstwę, najdroższy w routingu. Po transpilacji: **57 CZ** / **96 CZ**.

Rysunek 1: Pełne obwody czterech wariantów ansatzu. Struktura warstwy jest identyczna (kodowanie kątowe $R_y(x)$, uczone obroty $R(\theta)$, blok splątujący zaznaczony liniami przerywanymi), zmienia się *wyłącznie* blok CZ, który generuje drabinę kosztu routingu. Liczby CZ po transpilacji podano dla Garneta, dla obu strategii rozmieszczenia.

związanego obwodu. Dzięki temu żadna obserwowana różnica nie może pochodzić z ponownego treningu. Wagi są trenowane osobno dla każdego wzorca splątania, aby porównanie dotyczyło modeli faktycznie dopasowanych, a nie jednego modelu przenoszonego między architekturami.

Obserwabl i jego uzasadnienie. Odczytem jest **średnie** Z, $\langle O\rangle = \frac{1}{n}\sum_{i=1}^{n} Z_i$, a decyzją klasyfikatora – znak tej wartości. Wybór zweryfikowano eksperymentalnie wobec naturalnej alternatywy, jaką jest pojedyncze Z na wyróżnionym kubicie odczytu. W eksperymencie z modelami trenowanymi osobno dla każdego obserwabla wariant jednokubitowy obniżył pułap klasyfikatora – dokładność na punktach „łatwych" spadła z 0,87 do 0,62 – ponieważ pojedynczy kubit niesie mniej informacji o klasie niż średnia po wszystkich pięciu splątanych kubitach. Średnie Z pozostaje zatem obserwablem podstawowym.

Metryki. Metryką pierwotną jest błąd wartości oczekiwanej ε (równanie (1)) – ciągły i tani statystycznie. Dokładność klasyfikacji i macro-F1 raportowane są jako metryki wtórne: są decyzjami znaku, a więc mają wysoką wariancję i saturują. Metryką diagnostyczną jest r^2 (równanie (2)), pełniące rolę sondy koherencji (Sekcja 2.2).

2.5 Metody mitygacji: założenia, konstrukcja i granice

Każda metoda mitygacji naprawia *określony* rodzaj błędu i opiera się na *określonym* założeniu. Poniżej podano dla każdej z nich konstrukcję, zakładany model błędu oraz warunki, w których przestaje działać. Zestawienie zbiorcze zawiera Tabela 1.

REM – mitygacja błędu odczytu. Detektor myli stany bazowe, co opisuje macierz przejścia A, gdzie A_{ij} to prawdopodobieństwo odczytania i przy faktycznym stanie j. Zmierzony rozkład to $\vec{p}_{\text{zm}} = A\vec{p}_{\text{praw}}$, więc korekta polega na odwróceniu tej relacji, $\vec{p}_{\text{praw}} = A^{-1}\vec{p}_{\text{zm}}$ (w praktyce z więzami dodatniości). *Naprawia:* wyłącznie błąd pomiaru końcowego. *Nie naprawia:* żadnego błędu bramkowego – stan wchodzący do pomiaru jest już zepsuty. *Warunek stosowalności:* znajomość macierzy A, czyli dostęp do kalibracji odczytu per kubit. W badaniu głównym REM jest **wyłączone**, ponieważ platforma IQM Resonance takiej kalibracji nie udostępnia; w Miesiącu 1 na ODRZE dawało poprawę umiarkowaną (0,1115 → 0,0884 przy 12 CZ), co potwierdza, że błąd odczytu nie jest dominującym kanałem w badanym reżimie.

DD – dynamiczne odsprzęganie. W okresach bezczynności kubit oddziałuje z otoczeniem, gromadząc błąd fazowy. Wstawienie sekwencji impulsów (np. X–Y–X–Y) powoduje *refokusację*: obrót nabyty w pierwszej połowie okna jest odwracany w drugiej, o ile zaburzenie jest wolnozmienne w porównaniu z odstępem impulsów. *Naprawia:* niskoczęstotliwościowe defazowanie w czasie bezczynności. *Nie naprawia:* błędów samych bramek. *Zawodzi, gdy:* okresy bezczynności są krótkie – wtedy koszt dodatkowych impulsów (każdy ze swoim błędem) przewyższa zysk z refokusacji. Dokładnie to zaobserwowaliśmy na topologii gwiazdy (Sekcja 3), gdzie DD pogorszyło wynik w *każdym* punkcie drabiny.

ZNE – ekstrapolacja do zerowego szumu. Metoda opiera się na założeniu, że wartość oczekiwana jest gładką funkcją siły szumu λ:

$$\langle O\rangle(\lambda) \;=\; \langle O\rangle_0 \;+\; \sum_{k\geq 1} a_k \lambda^k, \tag{8}$$

gdzie $\langle O\rangle_0$ jest szukaną wartością bezszumową. Szum wzmacniamy *składaniem unitarnym*: fragment obwodu U zastępujemy przez $U(U^\dagger U)^m$, co zwiększa liczbę bramek $(2m{+}1)$-krotnie, nie zmieniając działania idealnego. Mierząc $\langle O\rangle$ dla $\lambda \in \{1,3,5\}$ i eliminując wyrazy a_1, a_2 kombinacją liniową (ekstrapolacja Richardsona), uzyskuje się estymator $\langle O\rangle_0$. *Naprawia:* każdy błąd rosnący gładko i monotonicznie ze skalą szumu, w szczególności stochastyczny. *Nie wymaga* wartości odniesienia, co jest jej główną zaletą.

Kluczowe dla dalszych wyników jest to, że ZNE **wymienia obciążenie na wariancję**. Estymator Richardsona powstaje jako interpolacja Lagrange'a wyliczona w punkcie $\lambda = 0$, a więc jego współczynniki są *dokładnymi* liczbami wymiernymi, zależnymi wyłącznie od wyboru węzłów:

$$\langle \hat{O}\rangle_0 \;=\; \sum_i c_i \,\langle O\rangle(\lambda_i), \qquad c_i \;=\; \prod_{j\neq i} \frac{\lambda_j}{\lambda_j - \lambda_i}. \tag{9}$$

Dla przyjętych węzłów $\lambda \in \{1,3,5\}$ daje to

$$c_1 = \frac{3\cdot 5}{(3-1)(5-1)} = \frac{15}{8}, \qquad c_2 = \frac{1\cdot 5}{(1-3)(5-3)} = -\frac{5}{4}, \qquad c_3 = \frac{1\cdot 3}{(1-5)(3-5)} = \frac{3}{8}, \tag{10}$$

przy czym $\sum_i c_i = \frac{15}{8} - \frac{10}{8} + \frac{3}{8} = 1$, jak wymaga zgodność estymatora. Współczynniki mają jednak znaczne wartości bezwzględne i naprzemienne znaki. Jeżeli każdy pomiar obarczony jest niezależną wariancją σ^2, to wariancja estymatora wynosi

$$\mathrm{Var}(\langle \hat{O}\rangle_0) = \sigma^2 \sum_i c_i^2 = \sigma^2\, \frac{225 + 100 + 9}{64} = \frac{167}{32}\,\sigma^2 \approx 5{,}22\,\sigma^2, \tag{11}$$

czyli błąd standardowy rośnie 2,28-krotnie; przy *zrównanym całkowitym* budżecie pomiarów (rozdzielonym na trzy skale) – niemal czterokrotnie. Wielkość tej kary jest *stała*: nie zależy od poziomu szumu w obwodzie, lecz wyłącznie od wyboru węzłów. Metoda opłaca się zatem tylko wtedy, gdy usuwane obciążenie B spełnia w przybliżeniu $B^2 \gtrsim 4{,}2\,\sigma^2$.

Zestawiając *stałą* karę wariancyjną ze *zmiennym* obciążeniem, uzyskuje się przewidywanie o trzech reżimach. Formułujemy je jako **hipotezę badawczą**, ponieważ jest ono bezpośrednio testowalne i stanowi ilościową wersję pytania o progi opłacalności, wokół którego zbudowana jest cała praca (Sekcja 7).

Reżim	Bilans obciążenie–wariancja	Przewidywanie
H1: duże obciążenie ($B^2 \gg \sigma^2$)	jest co usuwać; kara wariancyjna się zwraca	ZNE pomaga
H2: małe obciążenie ($B^2 \lesssim 4{,}2\,\sigma^2$)	kara wariancyjna niezmieniona, zysk znika	ZNE *szkodzi*
H3: sygnał na podłodze	brak informacji o zależności od λ; ekstrapolacja degeneruje się	ZNE bezużyteczne

Hipoteza **H2** jest najbardziej kontrintuicyjna – przewiduje, że mitygacja szkodzi tam, gdzie szumu jest *mało*, a zarazem najostrzej testowalna, bo położenie granicy da się przewidzieć ilościowo. Granica dolna jest zjawiskiem *skończonego budżetu pomiarów*: przy $\sigma \to 0$ kara znika i ZNE pozostaje korzystne także dla małego szumu. Weryfikację obu granic przedstawiamy w Sekcji 7.

Zawodzi, gdy: (i) rozwinięcie (8) przestaje obowiązywać, bo przy $\lambda > 1$ sygnał osiąga podłogę obserwabla (Sekcja 7); (ii) usuwane obciążenie jest małe *względem* wzmocnionego szumu statystycznego – co przy ustalonym budżecie pomiarów zachodzi w reżimie niskiego szumu [20]. Oba przypadki

mają wspólną przyczynę: ekstrapolacja odczytuje *różnice* między punktami pomiarowymi, a te stają się zdominowane przez szum statystyczny zarówno wtedy, gdy wzmocnienie szumu ledwo zmienia $\langle O \rangle$, jak i wtedy, gdy wszystkie punkty leżą już na podłodze obserwabla. ZNE dysponuje więc *oknem* użyteczności ograniczonym z obu stron, którego dolna krawędź przesuwa się wraz z budżetem pomiarów.

Dla punktu o najmniejszym szumie (Emerald, 21 CZ) obciążenie wynosi 0,037 wobec wzmocnionego szumu statystycznego rzędu 0,023 przy 2048 pomiarach – stosunek zaledwie 1,6, a więc reżim graniczny. Zaobserwowane pogorszenie jest jednak większe (0,168), niż tłumaczy sama wariancja, co wskazuje na dodatkowy mechanizm: przy punktach nieukładających się na gładkiej krzywej dopasowanie staje się źle uwarunkowane, a ekstrapolacja wykonuje duży „wystrzał" poza zakres wyznaczony przez dane. Formalizacja granicy help–harm w tej postaci pochodzi z pracy [20], do której się odwołujemy.

CDR – regresja danych Clifforda. Dla każdego punktu pracy budujemy zbiór obwodów treningowych o *identycznej strukturze i identycznym routingu* jak obwód docelowy, w których kąty obrotów przyciągnięto do najbliższych wielokrotności $\pi/2$. Obwody takie są bliskie Cliffordowskim, a więc ich wartości idealne dają się wyznaczyć *dokładnie i klasycznie* w formalizmie stabilizatorowym (twierdzenie Gottesmana–Knilla), przy koszcie wielomianowym zamiast wykładniczego – to właśnie czyni metodę wykonalną. Mierząc te same obwody na sprzęcie, uzyskuje się pary $(\langle O \rangle_i^{\text{zasz.}}, \langle O \rangle_i^{\text{ideal.}})$ i dopasowujemy

$$\langle O \rangle^{\text{idealne}} \;\approx\; a \cdot \langle O \rangle^{\text{zaszumione}} + b, \tag{12}$$

po czym stosuje się tę zależność do obwodu docelowego. *Naprawia:* dowolny błąd działający na wartość oczekiwaną w sposób *liniowy* – w szczególności depolaryzację, dla której równanie (5) daje dokładnie postać (12) z $a = (1-p)^{-N}$ i $b = 0$. *Zawodzi, gdy:* (i) błąd koherentny łamie liniowość, co objawia się spadkiem r^2 (ii) urządzenie dryfuje między pomiarem zbioru treningowego a obwodu docelowego, dlatego mierzone są zawsze w tym samym oknie. Koszt: $(n_{\text{train}} + 1)$-krotny; używamy $n_{\text{train}} = 10$.

Detekcja $[[4, 2, 2]]$**.** Ramię to działa odwrotnie niż pozostałe: nie koryguje wyniku po fakcie, lecz *zmienia sam obwód* tak, by błędy stały się rozpoznawalne. Kod $[[4, 2, 2]]$ koduje 2 kubity logiczne w 4 fizycznych i ma odległość 2 – pozwala *wykryć* pojedynczy błąd, lecz nie wskazać, gdzie zaszedł. Mierzymy więc stabilizatory i odrzucamy przebiegi o naruszonej parzystości, płacąc za to czynnikiem $1/p_{\text{akc}}$.

Zawodzi, gdy: obwód zawiera bramki nie-Cliffordowskie – kod pozwala wykonywać transwersalnie tylko operacje Cliffordowskie, a ciągłe obroty do nich nie należą. Warianty częściowe (weryfikacja symetrii z kubitem pomocniczym) zrealizowaliśmy i działają technicznie, lecz koszt weryfikacji przewyższył zysk z post-selekcji, zgodnie z wcześniejszymi obserwacjami dla układów pięciokubitowych [13, 14].

2.6 Circuit twirling (randomized compiling)

Twirling przekształca błąd *koherentny* w *stochastyczny*, nie zmieniając działania obwodu w granicy bezszumowej. Każdą natywną bramkę dwukubitową G otaczamy losową bramką Pauliego A przed nią i kompensatorem $B = G\,A\,G^{\dagger}$ za nią, tak że $B\,G\,A = G$ z dokładnością do fazy globalnej.

Jak dokładnie znoszą się błędy. Rozważmy najprostszy przypadek: bramkę obarczoną małym systematycznym nadobrotem, $\tilde{G} = e^{-i\theta Z/2}\,G$, gdzie θ jest stałe i to samo przy każdym powtórzeniu.

Tabela 1: Zestawienie metod: naprawiany rodzaj błędu, zakładany model i warunki załamania.

Metoda	Naprawia	Zakłada	Zawodzi, gdy
REM	błąd odczytu	znajomość macierzy A	brak kalibracji odczytu; dominuje błąd bramkowy
DD	defazowanie w bezczynności	wolnozmienne zaburzenie	krótkie okresy bezczynności (narzut impulsów)
ZNE	błąd gładko rosnący ze skalą szumu	rozwinięcie (8); zachowany sygnał	sygnał kolapsuje przy $\lambda >$ 1; lub zbyt mały szum przy skończonej statystyce
CDR	błąd działający *liniowo* na $\langle O \rangle$	liniowość (12); brak dryfu w oknie	błąd koherentny łamie liniowość (spadek r^2)
Twirling	– (konwertuje koherentny $\to$ stochastyczny)	bramki Cliffordowskie	mały udział błędu koherentnego (narzut przeważa)
$[[4, 2, 2]]$	pojedyncze błędy (detekcja)	obwód Cliffordowski	obwód nie-Cliffordowski; koszt weryfikacji > zysk

Wstawiamy przed bramką losową $A \in \{I, X\}$ i kompensator za nią. Dla $A = I$ błąd pozostaje $e^{-i\theta Z/2}$. Dla $A = X$ zachodzi sprzężenie

$$X\, e^{-i\theta Z/2}\, X \;=\; e^{-i\theta\,(XZX)/2} \;=\; e^{+i\theta Z/2}, \tag{13}$$

ponieważ $XZX = -Z$. Oba przypadki występują z prawdopodobieństwem $\frac{1}{2}$, więc *średni* kanał to $\frac{1}{2}\big(e^{-i\theta Z/2}\rho\, e^{+i\theta Z/2}\big) + \frac{1}{2}\big(e^{+i\theta Z/2}\rho\, e^{-i\theta Z/2}\big)$. Rozwijając do drugiego rzędu w θ, wyrazy liniowe – te, które kumulują się *koherentnie* – znoszą się parami, a pozostaje

$$\mathcal{E}(\rho) \;\approx\; \Big(1 - \tfrac{\theta^2}{4}\Big)\rho \;+\; \tfrac{\theta^2}{4}\, Z\rho Z, \tag{14}$$

czyli **kanał defazujący** – błąd stochastyczny o prawdopodobieństwie $\theta^2/4$.

Kluczowa jest różnica w kumulacji przez N bramek. Bez twirlingu nadobroty dodają się w kącie: N bramek daje obrót $N\theta$, a błąd wartości oczekiwanej rośnie jak $(N\theta)^2$. Po twirlingu dodają się *prawdopodobieństwa*: łączny błąd jest rzędu $N\theta^2/4$. Dla $\theta = 0{,}05$ i $N = 50$ daje to $(N\theta)^2 = 6{,}25$ (obrót całkowicie poza reżimem małych kątów) wobec $N\theta^2/4 = 0{,}031$. Twirling zamienia więc kumulację *kwadratową w liczbie bramek* na *liniową* – kosztem tego, że błędu nie da się już odwrócić, bo stał się losowy.

Uogólnienie na pełną macierz procesu χ przebiega tak samo: uśrednienie po grupie Pauliego zeruje elementy pozadiagonalne χ_{jk} $(j \neq k)$, odpowiadające za interferencję amplitud błędu, pozostawiając diagonalę o interpretacji prawdopodobieństw [6, 9]. Kanał po twirlingu jest zatem *kanałem Pauliego*: zachowuje całkowitą wierność procesu, lecz traci zdolność do koherentnej kumulacji.

Implementacja. Bramki Pauliego emitujemy bezpośrednio jako natywne bramki `r` (PRX), aby obwód pozostał natywny i nie wymagał ponownej transpilacji. Owinięcie stosowane jest na poziomie *logicznym*, przed transpilacją względem backendu – jest to ta sama, zweryfikowana ścieżka, którą przechodzi ramię nietwirlowane. Konsekwencją jest *niepełne pokrycie*: bramki SWAP wstawione przez router nie są owijane, co czyni zmierzony zysk **dolnym ograniczeniem** zysku osiągalnego przy pełnym randomized compiling. Poprawność konstrukcji weryfikujemy przed każdym uruchomieniem

testem bezszumowym: wartość $\langle O \rangle$ obwodu otwirlowanego musi być identyczna z wartością obwodu wyjściowego (w przeciwnym razie uruchomienie jest przerywane).

2.7 Protokół statystyczny

Krok 1: kontrola zrównana na liczbie pomiarów. Ramię z twirlingiem uśrednia M randomizacji, a więc wykonuje M-krotnie więcej pomiarów niż pojedynczy obwód odniesienia. Większa liczba pomiarów sama w sobie zawęża szum próbkowania, a węższy szum *podnosi* r^2 – punkty treningowe układają się ciaśniej wokół prostej, niezależnie od tego, czy w obwodzie był jakikolwiek błąd koherentny. Naiwne porównanie mierzyłoby więc głównie różnicę budżetu, a nie działanie twirlingu. Skalę tego artefaktu zmierzono w symulacji z szumem czysto depolaryzującym, gdzie twirling z definicji nie ma czego usuwać: przy $M = 10$ pozorny zysk wyniósł $\Delta r^2 \approx +0{,}10 \ldots + 0{,}15$, czyli tyle, ile sam poszukiwany efekt.

Rozwiązanie: ramię odniesienia uśrednia M **identycznych, *nie*otwirlowanych kopii** tego samego obwodu. Oba ramiona zużywają wtedy dokładnie tyle samo pomiarów i mają identyczny szum próbkowania, więc różnica między nimi izoluje wyłącznie tłumienie błędu koherentnego. Po wprowadzeniu tej kontroli pozorny zysk w warunkach depolaryzacji spadł do zera (Tabela 5).

Krok 2: pasma dryfu kalibracyjnego. Wszystkie wielkości mierzono w ≥ 2 (docelowo 3) *oknach kalibracyjnych*, tj. w różnych cyklach kalibracji urządzenia; powtórzenia wewnątrz jednego okna nie oddają dryfu i zaniżałyby niepewność. Ramiona włączone i wyłączone mierzono zawsze *w tym samym oknie*, dzięki czemu różnica sparowana $\Delta = (\mathrm{ON}) - (\mathrm{OFF})$ znosi dryf wspólny; niepewność raportowana jest jako odchylenie standardowe *między* oknami. Każde okno losuje niezależny zestaw M randomizacji Pauliego (ziarno zależne od identyfikatora okna), więc pasmo obejmuje zarówno dryf, jak i skończoną wariancję estymatora twirlingu. Konstrukcja zbioru CDR i transpilacja pozostają na stałym ziarnie, aby śledzić dryf *tego samego* estymatora.

Krok 3: poziom zerowy i reguła decyzji. Ponieważ r^2 szacowane z dziesięciu punktów treningowych ma własny szum, poziom zerowy nie jest punktowym zerem, lecz rozkładem. Wyznaczono go symulacyjnie (Sekcja 5), uruchamiając identyczny protokół pod szumem *niekoherentnym*. Przyjęto następujące kryterium: zysk twirlingu na sprzęcie uznaje się za rzeczywisty efekt koherentny tylko wtedy, gdy $\Delta r^2 > 0$, przekracza poziom zerowy (wartość średnia powiększona o odchylenie) *oraz* wykazuje dodatni trend względem liczby bramek CZ – przy czym trend poziomu zerowego jest płaski lub ujemny.

Zestawienie założeń wszystkich pomiarów. Ponieważ wnioski zależą od parametrów statystycznych, zbieramy je jawnie w Tabeli 2. Kolumna „okna” oznacza liczbę niezależnych cykli kalibracyjnych: wartość 1 oznacza, że wynik nie ma pasma dryfu i należy go czytać jako pojedynczą realizację.

Ograniczenie zasobów obliczeniowych. Budżet **3700 kredytów** platformy IQM Resonance wymusił kompromis: mniej pomiarów i punktów ewaluacyjnych niż typowo w literaturze (1024 i 4), za to *trzy* okna kalibracyjne zamiast jednego. Wybór ten jest świadomy – bez pasm dryfu wynik byłby nieinterpretowalny, podczas gdy mniejszy budżet pomiarów jedynie poszerza słupki błędu, a zmierzone pasma okazały się na tyle wąskie, że efekt główny pozostaje istotny.

Tabela 2: Założenia pomiarowe poszczególnych kampanii. „Pomiary” to liczba powtórzeń obwodu; „punkty ew.” – liczba różnych wektorów cech; „powt.” – niezależne powtórzenia całego pomiaru.

Kampania	Pomiary	Punkty ew.	Powt.	Okna	Uwagi
ODRA, drabina routingu	4096	30	3	1	REM i DD jako osobne ramiona
Garnet, pełna drabina	4096	30	–	1	raw + ZNE, 8 punktów drabiny
Garnet, CDR	2048	30	–	1	$n_{\text{train}} = 40$
Garnet, odzysk dokładności	4096	100	–	1	jeden punkt, 96 CZ
Garnet, mirror fidelity	4096	3	–	1	miara task-agnostyczna
Garnet, kampania twirlingowa	**1024**	**4**	–	**3**	$n_{\text{train}} = 10$, $M = 6$, budżet zrównany
Emerald, cross-topology	2048	4	–	1	bez twirlingu (brak walidacji sim)
Symulacja towarzysząca	1024	4	–	5 (null), 5/3 (koh.)	parametry jak w kampanii sprzętowej
Unitarity RB	1024	–	10 sekw.	2	długości $\{1, 2, 4, 8, 16\}$
Granica opłacalności ZNE	**96–2048**	**6**	**12**	1	budżet jest zmienną niezależną

Parametry kampanii twirlingowej. Główna kampania sprzętowa (Garnet) obejmuje 3 punkty drabiny routingu (12, 57, 96 CZ), 3 ramiona (bez mitygacji, CDR, ZNE), 4 punkty ewaluacyjne, 1024 pomiary na obwód, $n_{\text{train}} = 10$ oraz $M = 6$ randomizacji przy zrównanej liczbie pomiarów, powtórzone w 3 oknach kalibracyjnych. Ramię ZNE i ramię bez mitygacji uruchamiamy wyłącznie bez twirlingu – dostarczają one pasm dryfu dla obszaru załamania przy marginalnym koszcie. Kampania cross-topologiczna (Emerald) obejmuje 4 punkty (21–114 CZ), 3 ramiona, 2048 pomiarów, jedno okno i *nie zawiera* twirlingu: urządzenie 54-kubitowe jest klasycznie niesymulowalne, więc nie da się dla niego zbudować kontroli zerowej wymaganej przez powyższą regułę decyzji.

3 Walidacja potoku i punkt wyjścia: ODRA

Pomiary na urządzeniu ODRA (IQM Spark, topologia gwiazdy) stanowią punkt wyjścia całego badania: ustalają konwencje pomiarowe, weryfikują zgodność potoku „symulacja ↔ sprzęt” i dostarczają pierwszej obserwacji motywującej oś routingu. Drabina obejmuje 12–54 CZ, przy **4096 pomiarach na obwód, 30 punktach ewaluacyjnych i 3 powtórzeniach**.

Wyniki tego etapu, istotne dla dalszej części pracy, są następujące.

- **Zysk z mitygacji maleje z kosztem routingu** (Tabela 3): z 4,59× przy 12 CZ do 1,49× przy 54 CZ. To pierwsza obserwacja motywująca całe badanie główne – skuteczność metody nie jest własnością metody, lecz funkcją budżetu bramek.
- **Dynamiczne odsprzęganie (DD) jest zmierzonym wynikiem negatywnym.** Włączenie DD pogorszyło błąd w *każdym* punkcie drabiny (np. 0,1115 → 0,1591 przy 12 CZ oraz 0,3565 → 0,4583 przy 54 CZ). Na topologii gwiazdy okresy bezczynności są krótkie, więc narzut impulsów DD przeważa nad tłumieniem defazowania.

Tabela 3: Miesiąc 1, ODRA: błąd ε bez mitygacji i po ZNE (ekstrapolacja Richardsona) wzdłuż drabiny routingu. Zysk ZNE maleje monotonicznie z kosztem routingu.

CZ	ε (bez mitygacji)	ε (ZNE)	krotność redukcji
12	0,1115	0,0243	4,59×
27	0,2811	0,1150	2,44×
36	0,2990	0,1760	1,70×
54	0,3565	0,2390	1,49×

- **Dokładność klasyfikacji jest niewrażliwa** – pozostaje w przedziale 0,87–0,92 niezależnie od kosztu routingu i zastosowanej metody, podczas gdy błąd ε zmienia się trzykrotnie. Obserwacja ta uzasadnia przyjęcie ε jako metryki pierwotnej (Sekcja 2.4).
- **Mitygacja błędu odczytu (REM)** daje poprawę umiarkowaną (0,1115 → 0,0884 przy 12 CZ) i *nie jest dostępna* na platformie IQM Resonance, która nie udostępnia kalibracji odczytu per kubit. W badaniu głównym REM jest zatem wyłączone.

Etap ten dostarczył ponadto architektury zamrożonego modelu, wykorzystywanej we wszystkich dalszych pomiarach.

4 Wynik 1: załamanie jest topologicznie ogólne

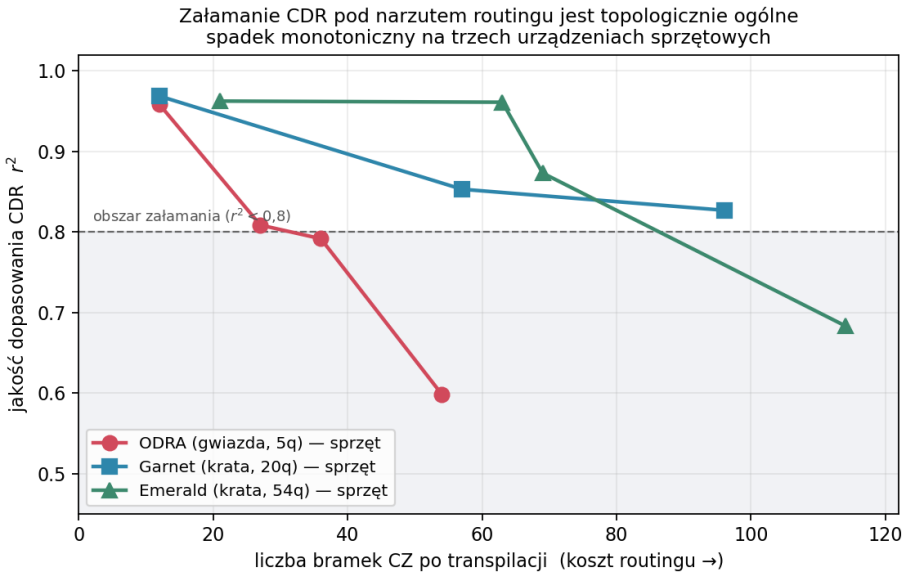
Pierwsze pytanie brzmi, czy załamanie CDR pod narzutem routingu jest własnością konkretnego urządzenia, czy zjawiskiem ogólnym. Odpowiedź daje zestawienie trzech topologii na wspólnej osi kosztu (Tabela 4, Rysunek 2).

Tabela 4: Jakość dopasowania CDR (r^2) wzdłuż drabiny routingu na trzech topologiach; w nawiasach liczba bramek CZ po transpilacji. Wartości dla Garneta uśredniono po trzech oknach kalibracyjnych. Drabina Garneta obejmuje trzy punkty, a nie cztery, ponieważ kampania twirlingowa na tym urządzeniu – jedyna prowadzona w wielu oknach – została ograniczona do trzech punktów przez budżet kredytów.

Urządzenie	r^2 przy kolejnych wartościach CZ			
ODRA (gwiazda, 5q)	0,958 (12)	0,809 (27)	0,792 (36)	0,598 (54)
Garnet (krata, 20q)	0,969 (12)	0,853 (57)	0,827 (96)	–
Emerald (krata, 54q)	0,962 (21)	0,961 (63)	0,873 (69)	0,683 (114)

Obserwacja główna. Na *wszystkich trzech* topologiach r^2 spada monotonicznie z kosztem routingu. Załamanie nie jest więc artefaktem jednego urządzenia ani jednej kraty – jest **topologicznie ogólne**. Ponieważ struktura obwodu logicznego, model, obserwabl i metryka są identyczne, jedyną zmienną odpowiedzialną za tę degradację pozostaje narzut routingu.

Spadek nie jest przy tym gładki w liczbie bramek. Na Emeraldzie przejście z 21 do 63 CZ, a więc potrojenie kosztu routingu, obniża r^2 zaledwie o 0,001; degradacja przyspiesza dopiero powyżej tego zakresu. Sugeruje to, że koherencja musi najpierw skumulować się do pewnego poziomu, zanim zacznie mierzalnie naruszać liniowość – co jest spójne z kwadratową zależnością od liczby bramek wyprowadzoną w Sekcji 2.2.



Rysunek 2: Jakość dopasowania CDR (r^2) w funkcji liczby bramek CZ po transpilacji, dla trzech topologii nadprzewodzących. Obszar zacieniony oznacza region załamania ($r^2 < 0{,}8$), w którym liniowe założenie CDR przestaje być spełnione. Wartości dla Garneta uśredniono po trzech oknach kalibracyjnych. Wszystkie trzy krzywe pochodzą z pomiarów na rzeczywistych urządzeniach.

Różnice tempa. Topologie różnią się *szybkością* wchodzenia w region załamania. Interpolując liniowo między zmierzonymi punktami, gwiazda przekracza próg $r^2 < 0{,}8$ w okolicy **32 CZ**, Emerald dopiero przy **86 CZ**, a Garnet nie schodzi poniżej progu w całym zbadanym zakresie (minimum 0,827 przy 96 CZ). Jest to spójne z geometrią: na gwieździe każda operacja między kubitami zewnętrznymi musi przejść przez węzeł centralny, co szybko mnoży liczbę bramek SWAP. *Zastrzeżenie:* próg dla Garneta jest *dolnym ograniczeniem* – drabina tego urządzenia kończy się na 96 CZ, więc przecięcie mogło po prostu nie zostać osiągnięte.

Wniosek praktyczny: budżet bramek jest specyficzny dla topologii. Ta sama liczba bramek CZ oznacza inny stopień degradacji na gwieździe niż na kracie, więc próg opłacalności trzeba wyznaczać osobno dla każdego urządzenia – ale *kształt* zależności jest wspólny, co pozwala przenosić samą procedurę wyznaczania progu.

5 Wynik 2: mechanizmem jest błąd koherentny

Monotoniczny spadek r^2 mówi, że wraz z narzutem routingu *coś* narusza założenie liniowości CDR. Aby wykazać, że tym czymś jest błąd *koherentny*, przeprowadzono eksperyment symulacyjny, w którym znamy naturę szumu, a protokół pomiarowy jest identyczny jak na sprzęcie (te same parametry, ta sama kontrola zrównana na liczbie pomiarów, te same okna).

Kontrola zerowa. Pod szumem czysto depolaryzującym – niekoherentnym z definicji – zysk twirlingu jest zgodny z zerem lub nieznacznie ujemny w całym zakresie, a jego trend względem kosztu routingu jest płaski ($-0{,}019 \pm 0{,}065$). Nieznaczna ujemność jest zresztą oczekiwana: obwód otwirlowany zawiera dodatkowe bramki Pauliego, które same wnoszą trochę szumu. Kontrola ta pełni

Tabela 5: Symulacja towarzysząca: zysk twirlingu $\Delta r^2 = r^2(\mathrm{ON}) - r^2(\mathrm{OFF})$ przy kontroli zrównanej na liczbie pomiarów, w trzech reżimach szumu. Niepewności to odchylenia standardowe między oknami. Pod szumem niekoherentnym twirling nie przynosi zysku; pod szumem koherentnym zysk rośnie z kosztem routingu i skaluje się z amplitudą koherencji.

Reżim szumu	33 CZ	87 CZ	90 CZ	trend (na 100 CZ)
depolaryzacja (kontrola zerowa)	$-0{,}001 \pm 0{,}005$	$-0{,}003 \pm 0{,}030$	$-0{,}018 \pm 0{,}049$	$-0{,}019 \pm 0{,}065$
koherentny, $\theta = 0{,}05$	$+0{,}034 \pm 0{,}007$	$+0{,}235 \pm 0{,}005$	$+0{,}140 \pm 0{,}004$	$+0{,}270 \pm 0{,}015$
koherentny, $\theta = 0{,}10$	$+0{,}157 \pm 0{,}024$	$+0{,}571 \pm 0{,}022$	$+0{,}484 \pm 0{,}008$	$+0{,}659 \pm 0{,}034$

w pracy podwójną rolę: dowodzi, że protokół nie wytwarza zysku tam, gdzie go być nie powinno, i wyznacza *poziom zerowy* (rzędu $\pm 0{,}03$–$0{,}05$ przy wysokim koszcie routingu), który wynik sprzętowy musi przekroczyć.

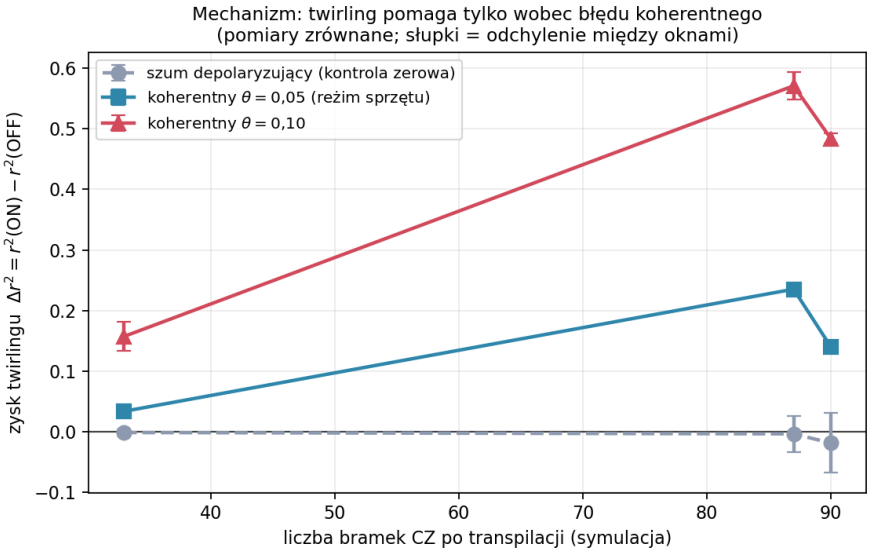
Kontrola pozytywna i zależność dawka–odpowiedź. Po wstrzyknięciu koherentnego obrotu nadmiarowego na każdej bramce CZ obraz zmienia się jakościowo: zysk twirlingu jest dodatni, istotny i *rośnie z kosztem routingu* (trend $+0{,}270 \pm 0{,}015$ przy $\theta = 0{,}05$). Podwojenie amplitudy koherencji zwiększa zysk 2,4–4,6-krotnie – zależność dawka–odpowiedź, której szum niekoherentny nie odtwarza w żadnym stopniu. Reżim $\theta = 0{,}05$ odpowiada przy tym warunkom sprzętowym: r^2 ramienia nietwirlowanego spada w nim z 0,94 do 0,75 wzdłuż drabiny, co odpowiada obserwowanemu na Garnecie spadkowi z 0,98 do 0,79.

Pomiar koherencji na poziomie bramki. Niezależnie wykonano *unitarity randomized benchmarking* [8] na parze kubitów Garneta, uzyskując unitarność $u = 0{,}843$ przy zaniku standardowego RB $p = 0{,}908$ (a więc $p^2 = 0{,}824$). Nadwyżka $u - p^2 = +0{,}019$ wskazuje na niewielki udział błędu koherentnego *pojedynczej bramki*, przy czym dryf tej wielkości między oknami ($\approx 0{,}09$) znacznie przewyższa sam sygnał. Wniosek jest zatem ograniczający, ale istotny: koherencja izolowanej bramki CZ jest mała, więc obserwowany zysk twirlingu musi pochodzić z poziomu *obwodu* – z kumulacji na łańcuchach SWAP, okresach bezczynności i przesłuchach – a nie z pojedynczej operacji. Ilościowe domknięcie tej ścieżki (przewidziany = zmierzony zysk) wymagałoby *cycle benchmarkingu* na poziomie warstwy i pozostaje zadaniem otwartym.

Wniosek praktyczny: r^2 jest tanią sondą charakteru szumu. Skoro spadek r^2 jest sygnaturą koherencji, a nie ogólnego „pogorszenia", to samo dopasowanie CDR – które i tak trzeba wykonać, żeby metody użyć – mówi za darmo, czy w obwodzie warto uruchamiać twirling.

Wartość tej obserwacji bierze się z porównania z alternatywami. Żeby dowiedzieć się, jaka część błędu urządzenia jest koherentna, trzeba normalnie wykonać *osobny eksperyment*: unitarity randomized benchmarking albo cycle benchmarking. Oba wymagają własnych obwodów, własnego czasu maszynowego i własnej analizy, a ich wynik dotyczy *bramki* lub *warstwy* – nie tego konkretnego obwodu, który ma zostać uruchomiony. Widać to na własnym pomiarze: unitarity RB dało nadwyżkę koherentną $+0{,}019$ przy dryfie między oknami rzędu 0,09, czyli sygnał *utonął* w dryfie i nie pozwolił przewidzieć niczego o pojedynczym przebiegu.

Współczynnik r^2 nie ma żadnej z tych wad. Jest liczony na *tym samym* obwodzie, w *tym samym* oknie kalibracyjnym i z *tych samych* pomiarów, które i tak trzeba wykonać – koszt dodatkowy wynosi zero. Mierzy przy tym dokładnie tę wielkość, która decyduje o opłacalności interwencji, a nie jej pośrednik: liczba bramek CZ mówi, ile koherencji *mogło* narosnąć, podczas gdy r^2 mówi, ile



Rysunek 3: Symulacja towarzysząca: zysk twirlingu Δr^2 w funkcji kosztu routingu dla trzech reżimów szumu, przy kontroli zrównanej na liczbie pomiarów. Pod szumem niekoherentnym efekt jest zgodny z zerem i pozbawiony trendu; pod szumem koherentnym rośnie z kosztem routingu i skaluje się z amplitudą koherencji (zależność dawka–odpowiedź).

jej *jest* – w tym przebiegu, przy tym stanie urządzenia. To dlatego zysk z twirlingu koreluje z r^2, a z liczbą bramek już nie (Sekcja 6).

6 Wynik 3: twirling przywraca skuteczność CDR na sprzęcie

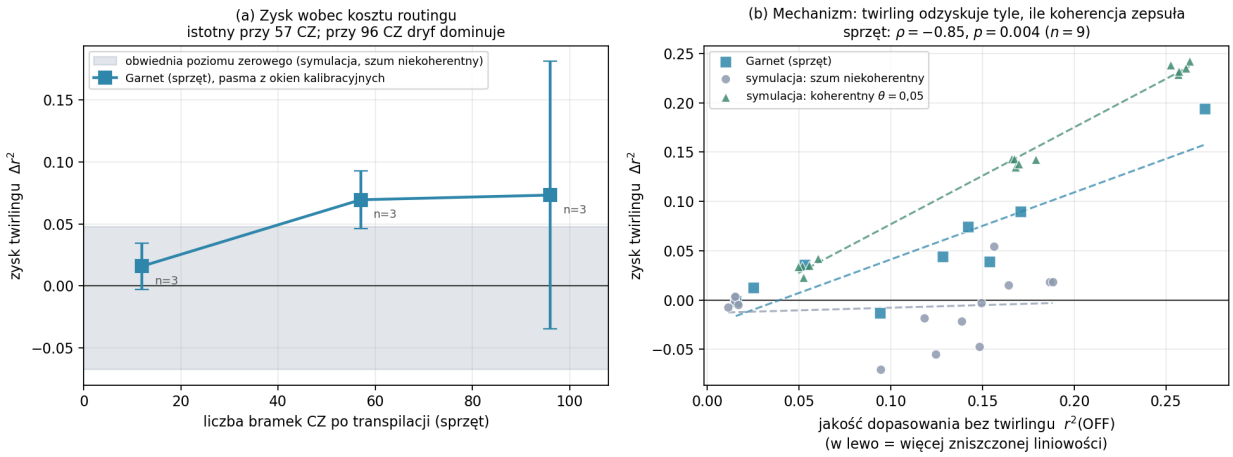
Jeżeli mechanizmem załamania jest błąd koherentny, to konwersja tego błędu na stochastyczny powinna przywrócić liniowość CDR – i to tym silniej, im większy narzut routingu. Hipotezę tę zweryfikowano na żywym urządzeniu Garnet.

Tabela 6: Garnet: sparowany zysk twirlingu przy kontroli zrównanej na liczbie pomiarów, z trzech okien kalibracyjnych. Niepewności to odchylenia standardowe między oknami.

CZ	Δr^2	$\Delta\varepsilon$	wartości w oknach	werdykt
12	$+0{,}016 \pm 0{,}019$	$-0{,}024 \pm 0{,}022$	$-0{,}001$; $+0{,}012$; $+0{,}036$	w poziomie zerowym
57	$+0{,}069 \pm 0{,}023$	$-0{,}016 \pm 0{,}019$	$+0{,}090$; $+0{,}044$; $+0{,}074$	**istotny**
96	$+0{,}073 \pm 0{,}108$	$-0{,}027 \pm 0{,}028$	$+0{,}039$; $+0{,}194$; $-0{,}013$	nierozstrzygnięty

Wynik zgodny z przewidywaniem mechanizmu – i jego granice. Przy najniższym koszcie routingu (12 CZ) zysk mieści się w poziomie zerowym ($+0{,}016 \pm 0{,}019$), co jest oczekiwane: obwód jest zbyt płytki, by koherencja zdążyła się skumulować. Przy 57 CZ zysk jest **istotny** ($+0{,}069 \pm 0{,}023$) i *dodatni we wszystkich trzech oknach* ($+0{,}090$; $+0{,}044$; $+0{,}074$), przekraczając poziom zerowy wyznaczony symulacyjnie. Punkt 96 CZ pozostaje jednak **nierozstrzygnięty**: rozrzut między oknami ($+0{,}039$; $+0{,}194$; $-0{,}013$) jest większy niż sam efekt. W konsekwencji *trend względem liczby bramek CZ nie jest istotny statystycznie* (Spearman $\rho = +0{,}32$, $p = 0{,}41$; $n = 9$). Twirling pomaga zatem

istotnie w reżimie pośredniego kosztu routingu, natomiast przy koszcie najwyższym dryf kalibracyjny dominuje nad efektem.



Rysunek 4: (a) Zysk twirlingu wobec kosztu routingu z pasmami dryfu; istotny przy 57 CZ, przy 96 CZ zdominowany przez dryf. (b) Ten sam zbiór punktów przedstawiony wobec jakości dopasowania bez twirlingu: zysk jest *przewidywalny* z r^2(OFF) i rośnie w lewo, czyli tam, gdzie koherencja bardziej zepsuła liniowość; punkty sprzętowe układają się między symulacją niekoherentną a koherentną.

Właściwym predyktorem nie jest liczba bramek, lecz zniszczenie liniowości. Duży rozrzut przy 96 CZ ma konkretne wyjaśnienie: w trzech oknach urządzenie znajdowało się w wyraźnie różnym stanie, a r^2 ramienia nietwirlowanego wynosiło odpowiednio 0,846, 0,729 i 0,906. W oknie najgorszym zysk był największy (+0,194), w najlepszym – zerowy (−0,013). Sugeruje to, że wielkością sterującą jest nie sam koszt routingu, lecz *ilość koherencji faktycznie obecnej w danym oknie*. Dane są z tą hipotezą zgodne: dla wszystkich dziewięciu pomiarów sprzętowych (3 punkty × 3 okna) zysk twirlingu koreluje z jakością dopasowania bez twirlingu na poziomie $\rho = -0{,}85$ ($p = 0{,}004$), podczas gdy korelacja z liczbą bramek CZ jest nieistotna ($\rho = +0{,}32$, $p = 0{,}41$). **Twirling odzyskuje dokładnie tyle, ile koherencja wcześniej zepsuła**, a liczba bramek CZ jest jedynie zaszumionym pośrednikiem tej wielkości – zaszumionym, ponieważ stan urządzenia dryfuje między oknami.

Kontrola artefaktu regresji do średniej. Korelowanie różnicy $\Delta = \mathrm{ON} - \mathrm{OFF}$ z samym OFF jest podatne na sprzężenie matematyczne: szum pomiarowy w r^2(OFF) wchodzi do obu wielkości z przeciwnymi znakami, wytwarzając ujemną korelację nawet przy braku efektu. Wielkość tego artefaktu zmierzono bezpośrednio na danych kontrolnych: w symulacji z szumem niekoherentnym ($n = 15$) korelacja wynosi zaledwie $\rho = -0{,}39$ i *nie jest istotna* ($p = 0{,}16$). Wynik sprzętowy (−0,85) znacznie ten poziom przekracza i odpowiada reżimom z wstrzykniętą koherencją (−0,91 dla $\theta = 0{,}05$; −0,82 dla $\theta = 0{,}10$), co widać także na Rysunku 4(b) jako nachylenie prostych dopasowania. Zależność nie jest zatem artefaktem statystycznym.

Zakres wniosku. Korelacja opiera się na dziewięciu pomiarach (3 punkty drabiny × 3 okna kalibracyjne), co jest liczebnością małą – przy takim n sam współczynnik Spearmana ma istotną wariancję i pojedynczy odstający punkt drabiny mógłby go zauważalnie przesunąć. Zależność tę traktuje się zatem jako wynik wstępny, wsparty jednak spójnym obrazem: wartość sprzętowa −0,85

leży wyraźnie powyżej poziomu kontroli zerowej ($-0{,}39$, nieistotne) i w przedziale wyznaczonym przez oba reżimy wstrzykniętej koherencji ($-0{,}91$ i $-0{,}82$). Rozszerzenie drabiny o punkty pośrednie w kolejnych oknach kalibracyjnych jest naturalnym sposobem domknięcia tej kwestii.

Kalibracja skali koherencji. Średni zysk twirlingu układa się monotonicznie wzdłuż reżimów: $-0{,}008$ (szum niekoherentny), $+0{,}053$ (Garnet), $+0{,}137$ ($\theta = 0{,}05$), $+0{,}404$ ($\theta = 0{,}10$). Umiejscawia to Garnet *powyżej* poziomu niekoherentnego, lecz *poniżej* najsłabszej wstrzykniętej koherencji, co odpowiada efektywnej amplitudzie rzędu $\theta \approx 0{,}02$–$0{,}03$ rad na bramkę dwukubitową. Jest to zgodne z niezależnym pomiarem unitarity RB (Sekcja 5), według którego koherencja pojedynczej bramki jest niewielka, co potwierdza, że obserwowany efekt gromadzi się na poziomie obwodu.

Reguła decyzyjna: zmierz r^2, nie licz bramek

Wyniki tej sekcji składają się w jedno stwierdzenie, które uważamy za najbardziej użytkowy wniosek całej pracy:

> **Twirling odzyskuje dokładnie tyle, ile koherencja wcześniej zepsuła.** Wielkością sterującą nie jest koszt routingu, lecz stopień naruszenia liniowości – mierzalny *przed* podjęciem decyzji, za darmo, jako r^2 zwykłego dopasowania CDR.
>
> *Reguła:* dopasuj CDR bez twirlingu i odczytaj r^2. Przy $r^2 \gtrsim 0{,}95$ twirling nie ma czego naprawiać – zysk mieści się w poziomie zerowym, a M-krotny narzut pomiarowy zostaje. Przy $r^2 \lesssim 0{,}90$ narosła koherencja i twirling ją usuwa: w zebranych pomiarach odzyskał $\Delta r^2 = +0{,}069 \pm 0{,}023$ przy $r^2(\mathrm{OFF}) = 0{,}853$.

Wartość tej reguły polega na tym, że *odwraca kolejność* zwykłego rozumowania. Naturalny odruch – „obwód ma dużo bramek, więc pewnie warto twirlować" – w zebranych danych zawodzi: korelacja zysku z liczbą bramek CZ nie osiąga istotności ($\rho = +0{,}32$, $p = 0{,}41$), ponieważ liczba bramek mówi o *potencjale* kumulacji koherencji, a nie o tym, ile jej faktycznie narosło w danym oknie kalibracyjnym. Stan urządzenia dryfuje, więc ten sam obwód bywa raz mocno, a raz słabo dotknięty, co widać wprost w danych: przy 96 CZ ten sam punkt drabiny dał w trzech oknach zyski $+0{,}039$, $+0{,}194$ i $-0{,}013$. Liczba bramek była za każdym razem identyczna; różniła się *koherencja*, a r^2 ją wychwyciło.

Praktyczna konsekwencja jest taka, że użytkownik nie musi ani znać modelu szumu swojego urządzenia, ani wykonywać osobnego eksperymentu benchmarkingowego, żeby zdecydować o zastosowaniu twirlingu. Wystarczy, że i tak stosuje CDR – wtedy diagnostyka jest gotowa, zanim wyda pierwszy dodatkowy pomiar.

7 Wynik 4: progi rozdzielone po urządzeniach

Poprzednie sekcje opisują mechanizm i jego neutralizację; ta umieszcza je w kontekście praktycznym: *która metoda opłaca się przy jakim budżecie bramek*. Tabela 7 zestawia wszystkie trzy podejścia na wspólnej osi kosztu.

Punkt równowagi ZNE $\leftrightarrow$ CDR. Przy niskim koszcie routingu wygrywa ZNE (12 CZ na ODRZE i na Garnecie), przy wyższym – CDR. Niezależna analiza kosztowa na Garnecie umiejscawia punkt równowagi w okolicy **39 CZ**. Wybór metody nie jest przy tym neutralny kosztowo: przy parametrach kampanii obu metod (ZNE: 4096 pomiarów $\times$ 3 skale; CDR: 2048 pomiarów $\times$ 41 obwodów, czyli 40 treningowych i docelowy) ZNE zużywa 12 288 efektywnych pomiarów wobec 83 968

Tabela 7: Błąd ε bez mitygacji, po CDR i po ZNE wzdłuż drabin routingu trzech urządzeń. Pogrubiono metodę najlepszą w danym punkcie.

Urządzenie	CZ	bez mitygacji	CDR	ZNE	najlepsza
ODRA	12	0,075	0,027	**0,023**	ZNE
	27	0,150	**0,071**	0,090	CDR
	36	0,186	**0,105**	0,142	CDR
	54	0,278	0,220	0,219	*remis*
Garnet	12	0,073	0,049	**0,031**	ZNE
	57	0,127	**0,058**	0,081	CDR
	96	0,111	**0,058**	0,103	CDR
Emerald	21	0,037	**0,024**	0,168	CDR (ZNE szkodzi)
	63	0,101	**0,070**	0,077	CDR
	69	0,079	0,059	**0,049**	ZNE
	114	**0,101**	0,279	0,139	*kolaps*

Wszystkie wartości pochodzą z pomiarów sprzętowych; dla każdego urządzenia wszystkie trzy metody zmierzono w jednej kampanii i jednym oknie kalibracyjnym.

dla CDR, a więc blisko siedmiokrotnie mniej. Poniżej punktu równowagi ZNE jest zatem zarówno *lepsze*, jak i *tańsze*; powyżej trzeba dopłacić za CDR, aby cokolwiek zyskać.

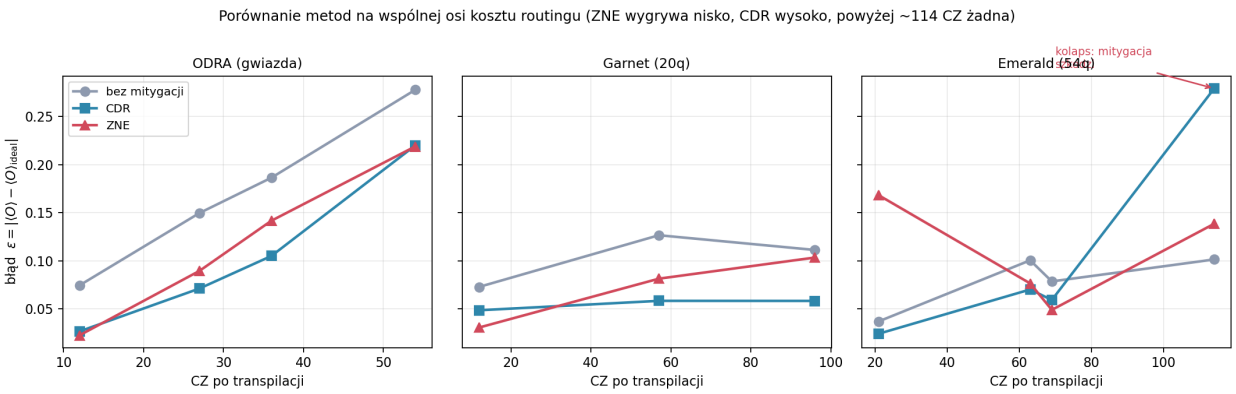
ZNE bywa szkodliwe – granica help–harm. Na Emeraldzie przy 21 CZ ekstrapolacja Richardsona daje błąd 0,168 wobec 0,037 bez jakiejkolwiek mitygacji – pogorszenie ponad czterokrotne. Nie jest to anomalia, a empiryczna granica: przy ustalonym budżecie pomiarów wzmocniona wariancja próbkowania dominuje nad redukowanym obciążeniem [20]. Punkt ten jest w tym badaniu *najmniej* zaszumiony (błąd bez mitygacji 0,037) i zmierzony przy zaledwie 2048 pomiarach, a więc leży dokładnie po „szkodliwej" stronie granicy. Obserwacja ta zamyka oś opłacalności z drugiej strony: ZNE ma nie tylko górny próg (kolaps sygnału, poniżej), lecz także *dolny* – przy zbyt małym szumie i skończonej statystyce lepiej nie mitygować wcale.

Granica opłacalności – prognoza pre-rejestrowana. Warunek wyprowadzony w Sekcji 2.5 można zapisać jako granicę na obciążenie przy ustalonym budżecie pomiarów S,

$$B^* \;=\; \sqrt{\frac{\kappa\, V}{S}}, \qquad \kappa = \left(\textstyle\sum_i c_i^2\right) |\Lambda| - 1 = 14{,}66, \tag{15}$$

lub równoważnie jako budżet krytyczny $S^* = \kappa V / B^2$ dla danego punktu drabiny. Skonfrontowanie tego przewidywania z danymi zebranymi w kampanii głównej (Tabela 8) daje zgodność w sześciu na siedem punktów, przy czym jedyna rozbieżność – Emerald przy 114 CZ – jest punktem niezależnie zdiagnozowanym jako kolaps sygnału ($R = 0{,}15$), a więc podlegającym *drugiemu* mechanizmowi. Oba mechanizmy razem wyjaśniają wszystkie siedem obserwacji. Szczególnie wymowny jest punkt Emerald 21 CZ, w którym zmierzone obciążenie 0,0370 leży praktycznie na przewidzianej granicy 0,0378, i w którym ZNE faktycznie zaszkodziło.

Powyższa zgodność opiera się jednak na pojedynczym przejściu granicy. Ostrzejszym testem jest pomiar *całej krzywej przejścia*: dla ustalonego punktu drabiny zwiększamy budżet pomiarów i sprawdzamy, przy jakiej jego wartości ZNE przestaje szkodzić, a zaczyna pomagać. Zapisujemy



Rysunek 5: Błąd ε bez mitygacji, po CDR i po ZNE wzdłuż drabin routingu trzech urządzeń. ZNE wygrywa przy niskim koszcie routingu, CDR przy wyższym; przy 114 CZ (Emerald) żadna metoda nie przewyższa wyniku niemitygowanego.

Tabela 8: Przewidywanie granicy (15) wobec danych. Wartość $V \approx 0{,}2$ oszacowano analitycznie dla obserwabla średniego Z na pięciu kubitach; nie dopasowywano żadnego parametru do danych.

Urządzenie	CZ	S	B	B^*	przewidywanie	obserwacja
Emerald	21	2048	0,0370	0,0378	zaszkodzi	zaszkodziło
Emerald	63	2048	0,1005	0,0378	pomoże	pomogło
Emerald	69	2048	0,0786	0,0378	pomoże	pomogło
Emerald	114	2048	0,1014	0,0378	pomoże	*zaszkodziło* (kolaps)
Garnet	12	1024	0,0729	0,0535	pomoże	pomogło
Garnet	57	1024	0,1266	0,0535	pomoże	pomogło
Garnet	96	1024	0,1113	0,0535	pomoże	pomogło

zatem prognozę *przed* wykonaniem pomiaru, w postaci, która nie zawiera żadnego parametru dopasowywanego do danych:

> **Prognoza pre-rejestrowana.** Ponieważ ekstrapolacja z trzech węzłów usuwa jedynie dwa pierwsze rzędy rozwinięcia (8), ramię ZNE zachowuje obciążenie resztkowe B_{zne}, a różnica błędów średniokwadratowych przyjmuje postać liniową w budżecie:
>
> $$\big(\mathrm{MSE}_{\mathrm{ZNE}} - \mathrm{MSE}_{\mathrm{raw}}\big)\cdot S \;=\; \underbrace{\kappa V}_{\text{wyraz wolny}} \;-\; \underbrace{\big(B^2 - B_{\mathrm{zne}}^2\big)}_{\text{nachylenie}}\, S. \tag{16}$$
>
> Przewidujemy, że dopasowanie prostej do zmierzonych punktów da wyraz wolny równy κV ze *stałą* $\kappa = 14{,}66$, wynikającą wyłącznie z wyboru węzłów $\{1, 3, 5\}$, przy czym V wyznaczymy niezależnie z rozkładu zliczeń w tym samym przebiegu. Falsyfikowalna jest zatem sama stała κ, a nie konkretna wartość budżetu krytycznego. Nachylenie dostarcza dodatkowo pomiaru tego, *jaką część* obciążenia ekstrapolacja faktycznie usuwa, oraz kontroli krzyżowej wobec obciążenia zmierzonego bezpośrednio.

Wynik testu. Kampanię wykonano na Garnecie w dwóch punktach drabiny o różnym obciążeniu, przy budżetach 96–2048 pomiarów, 12 powtórzeniach i 6 punktach ewaluacyjnych (Tabela 9). Prognoza została potwierdzona.

Tabela 9: Wynik testu pre-rejestrowanej prognozy. Wartość κ wyznaczono z wyrazu wolnego dopasowania (16), przy V zmierzonym niezależnie z rozkładu zliczeń. Żaden parametr nie był dopasowywany do danych.

Punkt	CZ	B	V	κ zmierzone	odchylenie
`optimal:star`	12	0,056	0,193	$14{,}42 \pm 0{,}95$	$0{,}25\sigma$
`adverse:star`	48	0,100	0,202	$13{,}29 \pm 1{,}73$	$0{,}79\sigma$
średnia ważona				$\mathbf{14{,}16 \pm 0{,}83}$	$\mathbf{0{,}60\sigma}$

Wynik jest zgodny z przewidywaniem $\kappa = 14{,}66$ na poziomie $0{,}60\sigma$. Potwierdzenia dostarczają ponadto dwie niezależne kontrole. Po pierwsze, zmierzona wariancja obserwabla na pomiar ($V = 0{,}190$–$0{,}206$) pokrywa się z wartością oszacowaną analitycznie (0,200). Po drugie – i jest to *osobna* falsyfikacja – teoria przewiduje skalowanie budżetu krytycznego $S^* \propto B^{-2}$. Dla obu punktów stosunek kwadratów obciążeń wynosi 3,24, a zmierzony stosunek budżetów krytycznych (847 wobec 291 pomiarów) – 2,91, czyli zgodność w granicach 10%. Przejścia zaobserwowano bezpośrednio: dla `optimal:star` w przedziale $(1024, 2048]$, dla `adverse:star` w $(256, 384]$ – większe obciążenie oznacza wcześniejsze przejście, zgodnie z przewidywaniem.

Konsekwencja praktyczna: liczba węzłów przesuwa granicę. Ponieważ κ zależy wyłącznie od wyboru węzłów, dobór tego zbioru jest *decyzją projektową*, która wprost przesuwa dolną granicę opłacalności. Dla składania globalnego (dającego wyłącznie skale nieparzyste) uzyskuje się $\kappa = 4{,}00$ dla $\{1, 3\}$, 14,66 dla $\{1, 3, 5\}$ oraz 44,56 dla $\{1, 3, 5, 7\}$. Redukcja liczby węzłów z trzech do dwóch obniża zatem próg budżetowy $S^* = \kappa V / B^2$ blisko czterokrotnie – kosztem mniejszej redukcji obciążenia, ponieważ ekstrapolacja usuwa wtedy tylko pierwszy rząd rozwinięcia. W reżimie płytkich obwodów i oszczędnych budżetów pomiarów jest to kompromis wart rozważenia i stanowi bezpośrednią rekomendację praktyczną.

Test na drugim zbiorze węzłów. Dopasowanie jednej stałej do jednego pomiaru zawsze można uznać za zbieg okoliczności. Powtórzyliśmy więc całą kampanię z węzłami $\{1, 3\}$, dla których teoria przewiduje $\kappa = 4{,}00$ dokładnie (współczynniki Richardsona $\frac{3}{2}, -\frac{1}{2}$, zatem $\sum_i c_i^2 = \frac{5}{2}$ oraz $\kappa = 2 \cdot \frac{5}{2} - 1$). Protokół, urządzenie i analiza pozostały bez zmian; zmienił się wyłącznie zbiór węzłów. Wyniki zebrano w Tabeli 10.

Tabela 10: Test ogólności prawa κ: ta sama procedura, dwa różne zbiory węzłów o przewidywanych wartościach różniących się 3,66-krotnie. Wartości zmierzone pochodzą z wyrazu wolnego dopasowania (16); ponownie żaden parametr nie był dopasowywany do danych.

Zbiór węzłów Λ	κ przewidziane	κ zmierzone	odchylenie
$\{1, 3, 5\}$	14,656	$14{,}16 \pm 0{,}83$	$0{,}60\sigma$
$\{1, 3\}$	4,000	$3{,}39 \pm 0{,}40$	$1{,}52\sigma$
wspólne dopasowanie $\kappa_{\text{zmierz}} = s\,\kappa_{\text{przewid}}$		$s = 0{,}937 \pm 0{,}049$	$1{,}27\sigma$

Oba zbiory węzłów dają wartości zgodne z przewidywaniami, przy czym zgodny jest sam *stosunek*: teoria przewiduje skok $14{,}656/4{,}000 = 3{,}66$, pomiar daje $4{,}18 \pm 0{,}55$. Wspólne dopasowanie prostej przez zero do czterech niezależnych punktów pomiarowych (dwa zbiory węzłów $\times$ dwa punkty drabiny) daje nachylenie $0{,}937 \pm 0{,}049$, odległe od jedności o $1{,}27\sigma$, przy $\chi^2/\text{dof} = 0{,}79$. Punkty

drabiny użyte w obu kampaniach różniły się narzutem routingu (12–48 bramek CZ), a mimo to dały spójne oszacowania tej samej stałej – co jest oczekiwane, ponieważ w modelu cała zależność od obwodu jest zawarta w B i V, a κ jest wielkością czysto kombinatoryczną, wynikającą z konstrukcji estymatora. Systematyczne, choć nieistotne statystycznie, niedoszacowanie ($s < 1$) jest zgodne z kierunkiem oczekiwanym przy resztkowym obciążeniu samej ekstrapolacji (człon B^2_{ZNE} w równaniu (16)), które obniża zmierzony wyraz wolny.

Obserwacja ta ma znaczenie wykraczające poza samą charakterystykę ZNE. Rozwój sprzętu i algorytmów zmierza w stronę obwodów *płytkich* wykonywanych przy *oszczędnych* budżetach pomiarów – a więc dokładnie w stronę reżimu, w którym granica dolna staje się warunkiem operacyjnym, a nie ciekawostką. Standardowa charakterystyka ZNE, prowadzona w reżimie obwodów głębokich, tego brzegu nie odsłania; ujawnia go dopiero oś routingu, która z konieczności zaczyna się od punktu o minimalnym narzucie.

Retencja sygnału a wiarygodność liczb ZNE. Köster i Mauerer [19] wykazali – na sprzęcie IQM tej samej klasy co Emerald i przy tych samych współczynnikach składania $\{1, 3, 5\}$ – że gdy wartość $\langle O \rangle$ kolapsuje do podłogi obserwabla (zero dla średniego Z), ekstrapolacja Richardsona degeneruje się do przeskalowania pojedynczego pomiaru i raportuje *pozorną* poprawę. Ponieważ dotyczy to bezpośrednio badanego reżimu, przeprowadzono ich diagnostykę retencji sygnału, $R = |\langle O \rangle(\lambda_{\max})|/|\langle O \rangle(\lambda{=}1)|$, w symulacji odwzorowującej drabinę routingu (Tabela 11).

Tabela 11: Diagnostyka retencji sygnału ZNE. Przy niskim koszcie routingu sygnał przeżywa składanie i liczby ZNE są wiarygodne; przy wysokim koszcie $\langle O \rangle$ osiąga podłogę obserwabla już przy $\lambda = 5$, co plasuje ten reżim w strefie artefaktu opisanej w [19].

Punkt	CZ	$\lvert\langle O \rangle\rvert$ ideał	λ=1	λ=3	λ=5	R
optimal:star	33	0,312	0,204	0,115	0,084	**0,41** (sygnał zachowany)
adverse:all_to_all	87	0,210	0,073	0,014	0,014	0,19 (granicznie)
optimal:all_to_all	90	0,210	0,056	0,019	0,008	**0,15** (kolaps)

Możemy wnioskować dwie rzeczy.

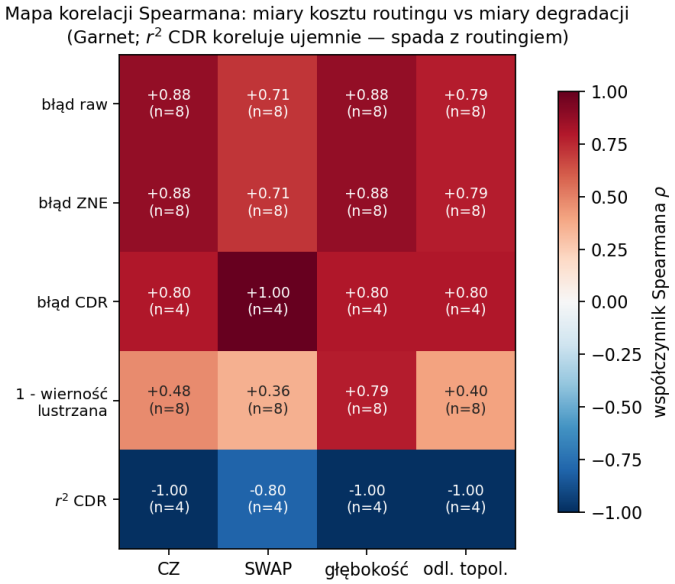
Po pierwsze, ilościowe wnioski dotyczące ZNE ograniczamy do reżimu $R > 0{,}3$, czyli do niskiego kosztu routingu. Przy wysokim koszcie wartości ZNE podano z zaznaczeniem, że nie są odróżnialne od artefaktu ekstrapolacji. W żadnym punkcie ekstrapolacja nie wyszła poza zakres fizyczny $[-1, 1]$, co wyklucza najostrzejszy wariant artefaktu.

Po drugie, sam kolaps sygnału jest *wynikiem*, nie tylko zastrzeżeniem metodologicznym: przy 90 CZ zmierzona amplituda $\langle O \rangle$ stanowi zaledwie 27% wartości idealnej już przy $\lambda = 1$. Daje to definicję progu załamania opartą na fizyce – opartą na utracie sygnału, a nie na porównaniu metod – spójną z teoretycznymi granicami mitygacji, zgodnie z którymi koszt próbkowania rośnie wykładniczo z liczbą bramek w stożku świetlnym obserwabla [21].

Próg pełnego kolapsu. Przy 114 CZ (Emerald, rozmieszczenie rozproszone, wzorzec `all_to_all`) *żadna* metoda nie przewyższa wyniku niemitygowanego: CDR daje 0,279, ZNE 0,139, podczas gdy sam obwód – 0,101. CDR jest w tym punkcie wyraźnie *szkodliwe*: przy $r^2 = 0{,}683$ dopasowanie liniowe jest już na tyle złe, że wyznaczona poprawka psuje wynik zamiast go poprawiać. Wniosek dotyczący CDR pozostaje przy tym niezależny od powyższych zastrzeżeń o ZNE: CDR nie korzysta ze wzmacniania szumu, więc nie podlega mechanizmowi artefaktu [19] – jego załamanie widać wprost w jakości dopasowania.

8 Pozostałe rezultaty

Wybór osi kosztu. Liczba bramek CZ po transpilacji nie jest jedynym kandydatem na miarę narzutu routingu; naturalne alternatywy to liczba bramek SWAP, głębokość obwodu i sumaryczna odległość topologiczna. Analiza korelacji na Garnecie ($n = 8$ punktów) wskazuje, że z błędem ε najsilniej korelują liczba CZ oraz głębokość (Spearman +0,88, $p = 0{,}004$), dalej odległość topologiczna (+0,79, $p = 0{,}02$) i liczba SWAP (+0,71, $p = 0{,}05$); na ODRZE korelacja z CZ wynosi +1,00. Uzasadnia to przyjęcie liczby CZ jako podstawowej osi kosztu, przy zastrzeżeniu, że jest to podsumowanie jednowymiarowe.



Rysunek 6: Mapa korelacji rangowej Spearmana między miarami kosztu routingu a miarami degradacji (Garnet). Liczba punktów podana w każdej komórce; wiersze CDR opierają się na czterech punktach drabiny.

Pełna mapa korelacji (Rysunek 6) ujawnia trzy zależności wykraczające poza sam wybór osi. Po pierwsze, **ZNE nie zmienia uporządkowania konfiguracji**: korelacje rangowe błędu po ZNE są identyczne jak dla błędu bez mitygacji (kolejno +0,88, +0,71, +0,88, +0,79). Mitygacja przeskalowuje wartości, ale nie odwraca hierarchii narzutu routingu – złe rozmieszczenie pozostaje złe. Po drugie, **błąd CDR koreluje z liczbą bramek SWAP silniej (+1,00) niż z samą liczbą CZ (+0,80)**, co jest spójne z obrazem, w którym to właśnie łańcuchy SWAP wprowadzone przez router – a nie bramki dwukubitowe obwodu logicznego – odpowiadają za kumulację błędu koherentnego łamiącego dopasowanie. Po trzecie, **mirror fidelity koreluje najsilniej z głębokością (+0,79), a słabo z liczbą CZ (+0,48)**, podczas gdy błąd klasyfikatora zachowuje się odwrotnie. Sugeruje to *dwa różne kanały degradacji*: miara niezależna od zadania jest wrażliwa przede wszystkim na czas trwania obwodu (dekoherencja), podczas gdy metryka zadaniowa – na liczbę operacji dwukubitowych.

Miara niezależna od zadania. Aby wyniki nie zależały wyłącznie od konkretnego klasyfikatora, zmierzono na Garnecie *mirror fidelity* – obwód złożony ze swoją odwrotnością, dla którego wynikiem idealnym jest powrót do stanu początkowego, a zmierzona przeżywalność stanowi czystą miarę jakości

sprzętu, niezależną od zadania. Przeżywalność spada z 0,776 przy 24 CZ do 0,215–0,277 przy 66–150 CZ.

Ciekawsze od samego spadku jest to, *z czym* mirror infidelity koreluje, a z czym nie. Zestawienie na wspólnych ośmiu punktach drabiny (Tabela 12) daje obraz jednoznaczny.

Tabela 12: Korelacje rangowe mirror infidelity z pozostałymi wielkościami, na ośmiu wspólnych punktach drabiny Garneta. Gwiazdka oznacza $p < 0{,}05$.

Mirror infidelity wobec	Spearman ρ	p
głębokość obwodu po transpilacji	$+0{,}79^{*}$	0,021
błąd klasyfikatora ε	$+0{,}71^{*}$	0,047
liczba bramek CZ	$+0{,}48$	0,233
sumaryczna odległość topologiczna	$+0{,}40$	0,320
liczba bramek SWAP	$+0{,}36$	0,385
względny zysk z ZNE	$-0{,}36$	0,385

Wyłaniają się z tego dwa wnioski, z których żaden nie jest trywialny.

Po pierwsze, mirror fidelity mierzy inną oś niż liczba bramek. Koreluje najsilniej z **głębokością** obwodu (+0,79), a z liczbą bramek CZ już nieistotnie (+0,48). Jest to spójne z jej konstrukcją: obwód mirror jest dwukrotnie dłuższy w czasie, więc dominuje w nim dekoherencja narastająca z *czasem trwania*, podczas gdy narzut routingu jest wielkością *zliczaną*. Obie osie są skorelowane, ale nie są tym samym; liczba CZ okazuje się lepszym predyktorem błędu klasyfikatora (+0,88 wobec +0,71).

Po drugie mirror fidelity nie przewiduje, czy metoda mitygacji pomoże. Korelacja ze względnym zyskiem z ZNE jest zerowa w granicach błędu ($-0{,}36$, $p = 0{,}39$; dla zysku bezwzględnego $-0{,}07$). Widać to wprost w danych: punkt `optimal:circular` ma najgorszą mirror fidelity w całym zbiorze (0,215), a mimo to ZNE redukuje tam błąd o 22% – więcej niż w punkcie `optimal:linear`, którego przeżywalność jest ponad dwukrotnie lepsza (0,527), a zysk wynosi zaledwie 2,7%.

Wniosek praktyczny: miara wierności mówi, jak źle jest, a nie co pomoże. Task-agnostyczny wskaźnik jakości sprzętu odpowiada na pytanie „jak bardzo ten obwód jest zepsuty", ale nie na pytanie „która metoda to naprawi" – bo ta druga odpowiedź zależy od *charakteru* szumu, a nie od jego wielkości. Wzmacnia to główną tezę metodologiczną pracy: żeby zdecydować o wyborze metody, trzeba zmierzyć jej własne założenie (dla CDR – r^2), a nie ogólny wskaźnik wierności.

8.1 Mitygacja błędu odczytu na klasyfikatorze wariacyjnym

Zebrane dane pozwalają ocenić REM w tym zastosowaniu, i wynik jest jednoznacznie negatywny. Uśredniając po 61 konfiguracjach (ansatz × głębokość × fold), REM redukuje błąd ε średnio o 0,0017, czyli o **0,9%** wartości, **w żadnej z 61 konfiguracji nie zmienia ani jednej decyzji klasyfikatora**: dokładność oraz macro-F1 po REM są identyczne z wartościami bez mitygacji we *wszystkich* przypadkach.

Interpretacja jest prosta i zgodna z taksonomią z Sekcji 2.5: REM koryguje wyłącznie ostatni etap obliczenia, podczas gdy stan wchodzący do pomiaru jest już zdegradowany przez błędy bramkowe narosłe wzdłuż routingu. W reżimie, w którym pracujemy, błąd odczytu nie jest kanałem dominującym. Uzasadnia to również decyzję o wyłączeniu REM w kampanii głównej – niezależnie od tego, że platforma IQM Resonance nie udostępnia wymaganej kalibracji detektora.

Odzysk dokładności przy wysokim koszcie routingu. W dedykowanym pomiarze o podwyższonej statystyce (100 punktów ewaluacyjnych, 4096 pomiarów, 96 CZ) ZNE obniża błąd ε z 0,221 do 0,169 (o 24%), lecz dokładność klasyfikacji pozostaje praktycznie niezmieniona (0,78 wobec 0,77). Jest to istotny wynik negatywny dla zastosowań: w reżimie wysokiego narzutu routingu mitygacja poprawia metrykę ciągłą, ale *nie odbudowuje* jakości decyzji klasyfikatora – poprawka nie wystarcza, by przesunąć punkty z powrotem na właściwą stronę granicy decyzyjnej.

9 Wnioski

Praca charakteryzuje reżimy opłacalności metod mitygacji błędów kwantowych jako funkcję narzutu routingu, rozdzielone po topologiach, i wskazuje mechanizm odpowiedzialny za obserwowane załamanie.

Po pierwsze, załamanie regresji danych Clifforda pod narzutem routingu jest **topologicznie ogólne**: jakość dopasowania liniowego spada monotonicznie z liczbą bramek dwukubitowych na każdej badanej topologii, przy czym topologia gwiazdy wchodzi w region załamania przy blisko trzykrotnie niższym budżecie bramek niż krata (≈ 32 wobec ≈ 86 CZ). Teza opiera się na trzech niezależnych pomiarach sprzętowych – dwóch kratach o różnym rozmiarze (Garnet 20q, Emerald 54q) oraz jakościowo odmiennej topologii gwiazdy (ODRA 5q).

Po drugie, mechanizmem tego załamania jest błąd **koherentny**, naruszający założenie liniowości CDR. Wskazuje na to symulacja towarzysząca: pod szumem niekoherentnym twirling nie daje zysku i nie wykazuje trendu, natomiast pod szumem koherentnym zysk jest dodatni, rośnie z kosztem routingu i skaluje się z amplitudą koherencji.

Po trzecie, **circuit twirling** przywraca skuteczność CDR na rzeczywistym sprzęcie. Zysk jest istotny przy pośrednim koszcie routingu (57 CZ: $+0{,}069 \pm 0{,}023$, dodatni we wszystkich trzech oknach kalibracyjnych) i mieści się w poziomie zerowym przy koszcie najniższym, gdzie koherencja nie zdążyła się skumulować. Zależność od samej liczby bramek nie osiąga jednak istotności ($\rho = +0{,}32$, $p = 0{,}41$), ponieważ przy najwyższym koszcie routingu dryf kalibracyjny dominuje nad efektem. Właściwym predyktorem okazuje się *stopień zniszczenia liniowości*: zysk twirlingu koreluje z jakością dopasowania bez twirlingu na poziomie $\rho = -0{,}85$ ($p = 0{,}004$), przy czym korelacja ta znacznie przekracza poziom generowany przez sprzężenie matematyczne w danych kontrolnych. **Twirling odzyskuje zatem tyle, ile koherencja wcześniej zepsuła**, a liczba bramek CZ jest jedynie zaszumionym pośrednikiem tej wielkości.

Po czwarte, granica opłacalności ZNE okazuje się **przewidywalna ilościowo**. Wyprowadzona z samej konstrukcji estymatora Richardsona stała κ została potwierdzona pomiarem sprzętowym dla *dwóch* różnych zbiorów węzłów: $14{,}16 \pm 0{,}83$ wobec przewidywanych 14,656 dla $\{1, 3, 5\}$ ($0{,}60\sigma$) oraz $3{,}39 \pm 0{,}40$ wobec 4,000 dla $\{1, 3\}$ ($1{,}52\sigma$), co daje wspólne nachylenie $0{,}937 \pm 0{,}049$ przy $\chi^2/\mathrm{dof} = 0{,}79$. Potwierdzeniu podlega zatem nie pojedyncza liczba, lecz przewidziane 3,66-krotne *przeskalowanie* stałej przy zmianie zbioru węzłów. Uzupełnia to niezależny test skalowania $S^* \propto B^{-2}$ (zgodność 10%). Ponieważ κ zależy wyłącznie od wyboru węzłów ekstrapolacji, liczba tych węzłów jest *decyzją projektową* przesuwającą próg opłacalności.

Zestawiając przewidywanie „pomoże czy zaszkodzi" ze zmierzonym wynikiem we wszystkich siedmiu punktach sprzętowych o znanym B i V, granica $S^* = \kappa V/B^2$ trafia w **sześciu przypadkach na siedem**. Jedyna niezgodność – Emerald przy 114 CZ – nie jest przy tym przypadkowa: należy do reżimu *kolapsu sygnału*, czyli drugiego, niezależnie zidentyfikowanego mechanizmu, wykrywanego osobną diagnostyką retencji. Złożenie obu reguł opisuje wszystkie zmierzone punkty. Użytkownik dysponuje zatem kryterium, które można sprawdzić *przed* wydaniem czasu maszynowego, znając wyłącznie własny budżet pomiarów oraz zgrubne oszacowanie obciążenia i wariancji obserwabla.

Z perspektywy praktycznej wyniki układają się w regułę doboru metody. Poniżej około **39 bramek CZ** korzystniejsze i niemal siedmiokrotnie tańsze jest ZNE, pod warunkiem że budżet pomiarów przekracza próg $S^* = \kappa V/B^2$; poniżej tego progu ZNE *szkodzi*. Powyżej punktu równowagi opłaca się CDR, którego zakres użyteczności rozszerza twirling. Powyżej około **114 bramek CZ** żadna z badanych metod nie przewyższa wyniku niemitygowanego. Wybór rozmieszczenia kubitów, decydujący o pozycji obwodu na tej osi, okazuje się przy tym decyzją równie istotną co wybór samej metody mitygacji.

A Odtwarzalność: repozytorium

Każda teza pracy daje się odtworzyć z kodu i danych zawartych w repozytorium (Tabela 13). Flaga `-sim` uruchamia identyczny potok na symulatorze (bezkosztowo), a `-resume` pozwala dokończyć przerwaną kampanię bez ponownego opłacania już zebranych punktów.

Tabela 13: Mapowanie: teza → skrypt → dane.

Teza / wynik	Skrypt	Dane
Drabina routingu, punkt wyjścia (ODRA)	`run_hardware.py`, `zne_dryrun.py`	`hardware_results.csv`, `zne_hard_results.csv`
Kampania twirlingowa (3 okna)	`run_garnet_twirl.py`	`garnet_twirl_w{1,2,3}.csv`
Pasma dryfu, istotność, trend	`aggregate_twirl_windows.py`	`garnet_twirl_w123_banded.csv`
Symulacja towarzysząca (null / koherencja)	`run_garnet_twirl.py -sim [-sim-coh]`, `overnight_sims.sh`	`night_{null,coh05,coh10}_banded.csv`
Koherencja na poziomie bramki	`run_garnet_urb.py`	wyniki w Sek. 5
Cross-topology (Emerald)	`run_garnet_twirl.py -device emerald`	`emerald_xtopo.csv`
Załamanie topologicznie ogólne	`analyze_cross_topology.py`	`cross_topology_summary.csv`
Progi metod	`analyze_method_threshold.py`, `analyze_crossover.py`	`garnet_crossover_summary.csv`
Granica opłacalności ZNE	`zne_boundary.py`, `zne_shot_boundary.py`	`zne_shot_boundary_results.csv`
Test ogólności stałej κ ($\{1, 3\}$)	`zne_shot_boundary.py -scales 1 3`	`zne_boundary_k4_results.csv`
Kampania ODRA (raw/CDR/ZNE)	`run_odra_cdr.py -zne`	`odra_full_100pt.csv`
Diagnostyka artefaktu ZNE	`zne_signal_retention.py`	`zne_signal_retention.csv`
Korelacje kosztu routingu	`analyze_routing_correlation.py`	`routing_correlation_summary.csv`
Mirror fidelity (miara task-agnostyczna)	`run_garnet_mirror.py`	`garnet_mirror_results.csv`
Rysunki	`make_final_figures.py`	`fig1-fig5_*.png`

Literatura

[1] Z. Cai, R. Babbush, S. C. Benjamin, S. Endo, W. J. Huggins, Y. Li, J. R. McClean, T. E. O'Brien, *Quantum Error Mitigation*, arXiv:2210.00921 (2023).

[2] K. Temme, S. Bravyi, J. M. Gambetta, *Error mitigation for short-depth quantum circuits*, Phys. Rev. Lett. **119**, 180509 (2017); arXiv:1612.02058.

[3] T. Giurgica-Tiron, Y. Hindy, R. LaRose, A. Mari, W. J. Zeng, *Digital zero-noise extrapolation for quantum error mitigation*, IEEE QCE (2020); arXiv:2005.10921.

[4] A. Kandala, K. Temme, A. D. Córcoles, A. Mezzacapo, J. M. Chow, J. M. Gambetta, *Error mitigation extends the computational reach of a noisy quantum processor*, Nature **567**, 491 (2019); arXiv:1805.04492.

[5] P. Czarnik, A. Arrasmith, P. J. Coles, L. Cincio, *Error mitigation with Clifford quantum-circuit data*, Quantum **5**, 592 (2021); arXiv:2005.10189.

[6] J. J. Wallman, J. Emerson, *Noise tailoring for scalable quantum computation via randomized compiling*, Phys. Rev. A **94**, 052325 (2016); arXiv:1512.01098.

[7] A. Hashim i in., *Randomized Compiling for Scalable Quantum Computing on a Noisy Superconducting Quantum Processor*, Phys. Rev. X **11**, 041039 (2021); arXiv:2010.00215.

[8] J. J. Wallman, C. Granade, R. Harper, S. T. Flammia, *Estimating the coherence of noise*, New J. Phys. **17**, 113020 (2015); arXiv:1503.07865.

[9] M. A. Nielsen, I. L. Chuang, *Quantum Computation and Quantum Information*, Cambridge University Press (2010).

[10] S. Ferracin i in., *Efficiently improving the performance of noisy quantum computers* – synergetyczna mitygacja przez randomized compiling i ZNE, Quantum **8** (2024); arXiv:2212.11198.

[11] A. Lowe, M. H. Gordon, P. Czarnik, A. Arrasmith, P. J. Coles, L. Cincio, *Unified approach to data-driven quantum error mitigation*, Phys. Rev. Research **3**, 033098 (2021); arXiv:2011.01157.

[12] A. Mari, N. Shammah, W. J. Zeng, *Extending quantum probabilistic error cancellation by noise scaling*, Phys. Rev. A **104**, 052607 (2021); arXiv:2108.02237.

[13] C. Vuillot, *Is error detection helpful on IBM 5Q chips?*, Quantum Inf. Comput. **18**, 949 (2018); arXiv:1705.08957.

[14] N. M. Linke i in., *Fault-tolerant quantum error detection*, Sci. Adv. **3**, e1701074 (2017); arXiv:1611.06946.

[15] G. Li, Y. Ding, Y. Xie, *Tackling the qubit mapping problem for NISQ-era quantum devices (SABRE)*, ASPLOS (2019); arXiv:1809.02573.

[16] M. Schuld, R. Sweke, J. J. Meyer, *The effect of data encoding on the expressive power of variational quantum machine learning models*, Phys. Rev. A **103**, 032430 (2021); arXiv:2008.08605.

[17] A. Pérez-Salinas, A. Cervera-Lierta, E. Gil-Fuster, J. I. Latorre, *Data re-uploading for a universal quantum classifier*, Quantum **4**, 226 (2020); arXiv:1907.02085.

[18] J. Bowles, S. Ahmed, M. Schuld, *Better than classical? The subtle art of benchmarking quantum machine learning models*, arXiv:2403.07059 (2024).

[19] M. Köster, W. Mauerer, *Benchmarking Error Mitigation: Artefactual Improvements in Zero-Noise Extrapolation*, arXiv:2607.09360 (2026).

[20] V. Scavino Alfaro, *The finite-shot help–harm boundary of zero-noise extrapolation*, arXiv:2605.08251 (2026).

[21] Y. Quek, D. Stilck França, S. Khatri, J. J. Meyer, J. Eisert, *Exponentially tighter bounds on limitations of quantum error mitigation*, Nature Physics **20**, 1648 (2024); arXiv:2210.11505.

[22] Z. Sayapin, D. Rabinovich, N. Korolev, K. Lakhmanskiy, *Zero-Noise Extrapolation via Cyclic Permutations of Quantum Circuit Layouts*, arXiv:2511.02901 (2025).

[23] Google Quantum AI and Collaborators, *Quantum error correction below the surface code threshold*, Nature **638**, 920–926 (2025).

[24] F. B. Maciejewski, Z. Zimborás, M. Oszmaniec, *Mitigation of readout noise in near-term quantum devices by classical post-processing based on detector tomography*, Quantum **4**, 257 (2020).

[25] P. D. Nation, H. Kang, N. Sundaresan, J. M. Gambetta, *Scalable mitigation of measurement errors on quantum computers*, PRX Quantum **2**, 040326 (2021).