Przygotowanie benchmarku i protokołu eksperymentalnego do oceny wpływu topologii sprzętu oraz kodowania logicznego na jakość obliczeń kwantowych

Sprawozdanie z Miesiąca 1

Karina Leśkiewicz

Sierpień 2026

Streszczenie

Badam, w którym momencie teoretyczny zysk z mitygacji błędów zostaje zniwelowany przez fizyczne ograniczenia sprzętu — w szczególności przez narzut routingu (bramki SWAP) wymuszony topologią procesora. Jako zmienną niezależną przyjęłam liczbę bramek dwukubitowych po kompilacji (transpiled CZ), a jako sygnał jakości — błąd wartości oczekiwanej $|\langle O\rangle_{\text{noisy}} - \langle O\rangle_{\text{ideal}}|$, dokładność klasyfikatora oraz fidelity obwodu.

W Miesiącu 1 zbudowałam powtarzalny zestaw narzędzi: trening w kalibrowanym symulatorze szumu, a następnie inferencję z REM + ZNE na sprzęcie ODRA (IQM Spark, topologia gwiazdy). Uzyskałam kompletną routing ladder dla zbioru `two_curves` na rzeczywistym QPU — zarówno błąd wartości oczekiwanej, jak i mirror fidelity — oraz drugą, niezależną routing ladder (ansätze Banknote) o porównywalnej dokładności bezszumowej i trzykrotnym rozrzucie kosztu CZ. Zaobserwowałam, że skuteczność ekstrapolacji ZNE maleje monotonicznie z kosztem CZ i staje się znikoma w okolicach 85–90 bramek CZ, przy jednoczesnym odzysku dokładności klasyfikatora na sprzęcie tam, gdzie szum zdążył przerzucić znak wartości oczekiwanej. Wykazałam również, że Dynamical Decoupling w natywnej konfiguracji urządzenia *pogarsza* wszystkie mierzone wielkości, i opisałam to jako wynik negatywny. Pełne kodowanie logiczne (QEC) odrzuciłam z uzasadnionych powodów sprzętowych; stosuję mitygację błędów (QEM).

Spis treści

Streszczenie **2**

1 Wprowadzenie i motywacja **4**

2 Podstawy teoretyczne **5**
2.1 Ramy: bias, wariancja i sens mitygacji 5
2.2 Dynamical Decoupling (DD) 5
2.3 Readout Error Mitigation (REM) 6
2.4 Zero-Noise Extrapolation (ZNE) 6

3 Metodologia i uzasadnienia **7**
3.1 VQC, obserwable i metryki jakości 7
3.2 Uzasadnienie zbioru danych i konfiguracja `two_curves` 7
3.3 Uzasadnienie kodowania (angle encoding) 8
3.4 Uzasadnienie ansatzu (HEA) 8
3.5 Model szumu i kalibracja urządzenia 8

4 Zbiór danych i ansätze Banknote **11**

5 Wyniki **11**
5.1 `two_curves`: routing ladder 11
5.2 `two_curves`: błąd $\langle O \rangle$ i dokładność — symulator vs QPU 11
5.3 `two_curves`: mirror fidelity 13
5.4 Banknote: baseline bezszumowy i routing ladder kosztu 14
5.5 Banknote: badanie ablacyjne w symulatorze 14
5.6 Banknote: rzeczywiste QPU 15
5.7 Banknote: mirror fidelity na QPU 17

6 Najważniejsze obserwacje z Miesiąca 1 **19**

7 Uzasadnienie rezygnacji z kubitów logicznych (QEC) **20**

8 Deliverables, podsumowanie i wnioski **21**
8.1 Status deliverables Miesiąca 1 21
8.2 Podsumowanie i wnioski 21

9 Repozytorium **22**

10 Plan na Miesiąc 2 **23**

11 Przegląd literatury **23**

1 Wprowadzenie i motywacja

Dlaczego mitygacja błędów (QEM). Obecne procesory kwantowe działają w reżimie NISQ (Noisy Intermediate-Scale Quantum): mają dziesiątki do setek kubitów, ale błąd pojedynczej bramki dwukubitowej (rzędu 1–2%) i ograniczone czasy koherencji uniemożliwiają wykonywanie głębokich obwodów bez akumulacji szumu. Docelowym rozwiązaniem jest korekcja błędów (QEC), która koduje jeden kubit logiczny w wiele fizycznych i pozwala na dowolnie długie obliczenia — lecz wymaga błędu poniżej progu oraz narzutu zasobów o rzędy wielkości, czego dzisiejszy sprzęt nie spełnia (szczegółowo w sekcji 7). Powstaje luka: chcemy uruchamiać użyteczne algorytmy *już teraz*, na sprzęcie, którego nie stać na pełną korekcję.

Mitygacja błędów (Quantum Error Mitigation, QEM) wypełnia tę lukę. Zamiast korygować błędy w trakcie obliczeń, QEM *redukuje ich wpływ na końcową wartość oczekiwaną* metodami statystycznymi i post-processingiem (Zero-Noise Extrapolation, Readout Error Mitigation, Dynamical Decoupling), bez dodatkowych kubitów i bez feed-forward. Kosztem jest zwiększona wariancja, czyli więcej powtórzeń pomiaru. Dlatego QEM jest dziś głównym praktycznym narzędziem otrzymywania wiarygodnych wyników z maszyn NISQ i przedmiotem intensywnych badań [1]. Kluczowe pytanie, które QEM stawia, jest jednak empiryczne — *do jakiego poziomu szumu (kosztu obwodu) mitygacja realnie pomaga, zanim jej narzut wariancji przeważy zysk.* To pytanie jest osią niniejszego projektu.

Rola topologii sprzętu. Odwzorowanie logicznych kubitów algorytmu na fizyczne kubity procesora jest ograniczone jego topologią. Gdy algorytm wymaga oddziaływania między kubitami, które nie są fizycznie połączone, kompilator wstawia operacje SWAP. Pojedynczy SWAP rozkłada się na trzy bramki CNOT (lub natywny odpowiednik dwukubitowy), co zwiększa głębokość obwodu, akumuluje błąd dwukubitowy i wydłuża okna bezczynności podatne na dekoherencję.

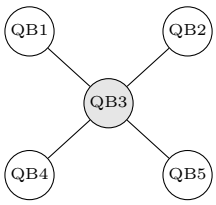
Cel główny. Empiryczne ustalenie, przy jakim koszcie dwukubitowym (po kompilacji) akumulacja szumu z routingu wypycha urządzenie poza reżim, w którym ekstrapolacja ZNE pozostaje wiarygodna — czyli gdzie mitygacja przestaje pomagać.

Pytania badawcze.

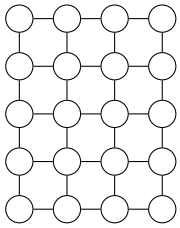
1. Jaka jest bazowa jakość wybranego obwodu na kubitach fizycznych (wartość oczekiwana, fidelity)?
2. Czy wariant logiczny/zakodowany poprawia wynik pomiarowy względem fizycznego?
3. Jak mapowanie optymalne i celowo niekorzystne zmienia głębokość, liczbę SWAP i jakość wyjścia?
4. Czy istnieje mierzalna korelacja między fizyczną odległością kubitów, liczbą SWAP i degradacją jakości modelu?

Sprzęt (trójpoziomowy dostęp).

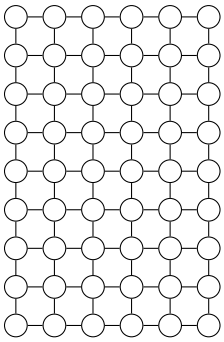
Poziom	Urządzenie	Kubity	Topologia	Rola
A	ODRA (IQM Spark)	5	gwiazda	podstawowy; generator SWAP
B	IQM Garnet	20	krata kwadratowa	walidacja pośrednia
C	IQM Emerald	54	krata kwadratowa	walidacja wielkoskalowa



(a) ODRA (IQM Spark), 5 kubitów



(b) IQM Garnet, 20 kubitów



(c) IQM Emerald, 54 kubity

Rysunek 1: Topologie trzech urządzeń z planu badawczego. (a) ODRA — gwiazda z hubem QB3: każda interakcja między kubitami zewnętrznymi musi przejść przez hub, generując SWAP. (b) Garnet i (c) Emerald — kraty kwadratowe o stopniu wierzchołka do 4, w których sąsiedztwo jest znacznie bogatsze, więc ten sam obwód logiczny wymaga mniej operacji SWAP.

Ten sam benchmark (routing ladder, ansätze, protokół REM + ZNE i mirror fidelity) jest z założenia niezależny od urządzenia: w Miesiącu 2 zostanie zastosowany bez zmian na Garnecie i Emeraldzie, co pozwoli porównać wpływ topologii wprost, przy identycznej procedurze pomiarowej.

2 Podstawy teoretyczne

W tej sekcji przedstawiam metody, które badałam: Dynamical Decoupling (DD), Readout Error Mitigation (REM) oraz Zero-Noise Extrapolation (ZNE), wraz z ramami bias/wariancja, w których działa mitygacja błędów [1].

2.1 Ramy: bias, wariancja i sens mitygacji

Skupiam się na średniokwadratowym odchyleniu estymatora $\hat{O}$ od wartości prawdziwej $\mathrm{Tr}[O\rho_0]$:

$$\mathrm{MSE}[\hat{O}] = \mathbb{E}\Big[(\hat{O} - \mathrm{Tr}[O\rho_0])^2\Big] = \mathrm{Bias}[\hat{O}]^2 + \mathrm{Var}[\hat{O}]. \tag{1}$$

Przy dużej liczbie wykonań MSE jest ograniczone przez bias — błąd systematyczny, którego nie usuwa zwiększanie liczby powtórzeń. Mitygacja konstruuje estymator $\hat{O}_{em}$ o mniejszym biasie, $|\mathrm{Bias}[\hat{O}_{em}]| \leq |\mathrm{Bias}[\hat{O}_\rho]|$,

$$C_{em} = \frac{\mathrm{Var}[\hat{O}_{em}]}{\mathrm{Var}[\hat{O}_\rho]}. \tag{2}$$

To wyjaśnia, dlaczego ciągły błąd wartości oczekiwanej jest czulszym miernikiem niż accuracy: mitygacja redukuje bias $\langle O \rangle$, ale przy małej próbie blisko granicy decyzyjnej dodana wariancja może nieznacznie przesuwać dokładność [1]. Ta zależność jest bezpośrednio widoczna w wynikach (sekcja 5.2): ZNE redukuje błąd $\langle O \rangle$ nawet 4,6-krotnie, nie zmieniając przy tym dokładności.

2.2 Dynamical Decoupling (DD)

DD to technika sterowania w otwartej pętli, tłumiąca dekoherencję kubitów bezczynnych (T_1, T_2) wynikającą z oddziaływania układ–otoczenie. W kontekście kompilacji topology-aware bramki SWAP znacząco zwiększają głębokość, pozostawiając nieuczestniczące kubity bezczynne przez długi czas.

Dla Hamiltonianu układu i otoczenia $H = H_S \otimes I_E + I_S \otimes H_E + H_{int}$ wprowadzamy sterujący $H_c(t)$ jako ciąg natychmiastowych, równoodległych impulsów. Dla N impulsów $\{P_k\}$ w odstępach τ operator ewolucji to

$$U(T) = \prod_{k=1}^{N} \left(P_k \, e^{-iH\tau} \right), \tag{3}$$

a przy odpowiednim doborze sekwencji średni efekt oddziaływania znika w pierwszym rzędzie rozwinięcia Magnusa:

$$H_{int}^{(0)} = \frac{1}{T} \sum_{k=1}^{N} P_k^\dagger H_{int} P_k \approx 0. \tag{4}$$

Automatyczne wstawianie DD przez kompilator. (1) transformacja obwodu do DAG i mapowanie na topologię, czyli wstawianie SWAP; (2) pobranie kalibracji: czasy bramek w ns i rozdzielczość zegara dt; (3) harmonogram ALAP/ASAP z przypisaniem t_{start}, t_{end}, przy czym ALAP minimalizuje czas w superpozycji; (4) ekstrakcja okien bezczynności T_{idle}; (5) padding: od T_{idle} odejmujemy czas impulsów, a resztę dzielimy na równe τ zgrane z zegarem; (6) wstrzyknięcie impulsów. Na sprzęcie IQM DD jest natywną opcją kompilacji i korzystam z wbudowanej strategii urządzenia; w symulatorze modeluję je zamianą tempa dekoherencji $T_2^* \to T_2^{\text{echo}}$ (echo Hahna).

2.3 Readout Error Mitigation (REM)

REM to klasyczne przetwarzanie po wykonaniu obwodu. W kubitach nadprzewodzących fidelity pomiaru jest ograniczona, więc sprzęt myli stan końcowy. Błędy odczytu działają jak klasyczny proces Markowa na rozkładzie prawdopodobieństw. Konstruujemy macierz przypisania A o wymiarze $2^n \times 2^n$:

$$A_{i|j} = P(\text{zmierzono } i \mid \text{przygotowano idealnie } j), \qquad \vec{p}_{\text{noisy}} = A\,\vec{p}_{\text{ideal}}. \tag{5}$$

Zwykłe odwrócenie $\vec{p}_{\text{mit}} = A^{-1}\vec{p}_{\text{noisy}}$ przy skończonej liczbie shotów daje wyniki niefizyczne (ujemne prawdopodobieństwa), dlatego stosuje się ograniczony problem najmniejszych kwadratów:

$$\min_{\vec{x}} \|A\vec{x} - \vec{p}_{\text{noisy}}\|_2 \quad \text{przy} \quad x_i \geq 0,\ \textstyle\sum_i x_i = 1. \tag{6}$$

W mojej implementacji (obserwable Z/I) używam dokładnego, per-kubitowego modelu symetrycznego bit-flip: symetryczny błąd p tłumi $\langle Z \rangle$ o czynnik $(1-2p)$, więc nieobciążony estymator to $\langle Z \rangle_{\text{mit}} = \langle Z \rangle_{\text{meas}}/(1-2p)$. Podanie wolnych-od-błędu-odczytu wartości oczekiwanych do ZNE jest istotne: pozwala ZNE skupić się wyłącznie na szumie bramek, bez klasowego biasu pomiaru [3, 1].

2.4 Zero-Noise Extrapolation (ZNE)

ZNE wykorzystuje stany zaszumione przy różnych poziomach błędu λ: stan ρ_λ, a $\text{Tr}[O\rho_\lambda]$ traktujemy jako funkcję λ. Sondujemy przy zwiększonych $\{\lambda_m\}$ i dążymy do $\lambda \to 0$. Poziom szumu zwiększamy cyfrowo przez unitary folding $U \to U(U^\dagger U)^k$ dla $\lambda = 2k+1 \in \{1, 3, 5\}$.

Ekstrapolacja Richardsona. Zakładamy, że wartość oczekiwana jest funkcją wielomianową poziomu szumu, $\text{Tr}[O\rho_\lambda] = a_0 + a_1\lambda + \cdots + a_{M-1}\lambda^{M-1}$. Interesuje nas wyraz wolny a_0, czyli wartość w $\lambda = 0$. Mając pomiary w M punktach $\lambda_1, \ldots, \lambda_M$ przeprowadzamy przez nie *dokładnie jeden* wielomian stopnia $M-1$ i odczytujemy jego wartość w zerze. Jest to interpolacja Lagrange'a wyliczona w punkcie 0, co daje kombinację liniową pomiarów o stałych współczynnikach:

$$\mathbb{E}[\hat{O}_{em}] = \sum_{m=1}^{M} \text{Tr}[O\rho_{\lambda_m}] \prod_{k \neq m} \frac{\lambda_k}{\lambda_k - \lambda_m}, \qquad C_{em} \sim \left(\sum_m \left| \prod_{k \neq m} \frac{\lambda_k}{\lambda_k - \lambda_m} \right| \right)^2. \tag{7}$$

Istotą metody jest to, że współczynniki są *naprzemienne co do znaku* i większe od jedności, więc ekstrapolacja jest różnicą dużych liczb. Stąd bierze się narzut wariancji: C_{em} rośnie, gdy λ_m jest za duże albo gdy odstępy $|\lambda_m - \lambda_k|$ są za małe. Gdy C_{em} eksploduje, ekstrapolacja staje się niewykonalna — i to jest sam w sobie wskaźnik załamania metody. Dla dużych λ stosuję wariant wykładniczy. Ideę „sztucznego zwiększania i ekstrapolacji błędu" wprowadzili Li i Benjamin [5]; porównuję warianty liniowy, Richardsona i wykładniczy.

3 Metodologia i uzasadnienia

3.1 VQC, obserwable i metryki jakości

Model realizuje odwzorowanie parametryzowanym obwodem $U(x, \theta)$; predykcja to znak wartości oczekiwanej obserwabli:

$$f(x, \theta) = \langle O \rangle = \langle 0 | U^\dagger O \, U | 0 \rangle, \qquad \hat{y} = \operatorname{sgn} \langle O \rangle, \tag{8}$$

z obserwablą mean value $O_{\text{mean}} = \frac{1}{n} \sum_q Z_q$ (`two_curves`) lub pojedynczym Z na kubicie readout (Banknote).

Błąd wartości oczekiwanej. Definiuję go jako $\varepsilon = |\langle O \rangle_{\text{noisy}} - \langle O \rangle_{\text{ideal}}|$, gdzie $\langle O \rangle_{\text{ideal}}$ liczę dokładnie ze statevectora (zamrożona referencja). Mierzę właśnie tę wielkość, ponieważ: (i) to dokładnie ją redukuje mitygacja (bias estymatora); (ii) jest ciągła i czuła, w przeciwieństwie do dokładności, która zmienia się skokowo; (iii) jest wprost porównywalna z referencją bezszumową; (iv) pozwala zlokalizować region załamania ZNE. Dokładność raportuję jako metrykę wtórną.

Fidelity (mirror circuit). Obwód lustrzany wykonuje U, a potem $U^\dagger$, więc stan idealny to dokładnie $|0\rangle^{\otimes n}$, niezależnie od danych wejściowych. Mierzoną wielkością jest prawdopodobieństwo przeżycia $F = P(|0\rangle^{\otimes n})$.

Wartość $F = 1$ oznacza obwód wykonany idealnie. Dolnym ograniczeniem *nie* jest zero, lecz floor stanu maksymalnie zdepolaryzowanego: dla $n = 5$ kubitów losowy rozkład daje $F = 2^{-5} = 0{,}031$. Wynik na poziomie 0,03 oznacza zatem, że obwód utracił całą informację. Ponieważ obwód lustrzany zawiera U i $U^\dagger$, jego koszt bramkowy jest *dwukrotnością* kosztu obwodu inferencyjnego — w tabelach podaję dlatego „mirror CZ", czyli 2× liczbę CZ obwodu użytkowego. Zaletą tej metryki jest to, że nie zależy ona od zadania ani od granicy decyzyjnej klasyfikatora: mierzy wyłącznie jakość wykonania danej struktury routingu na urządzeniu. Praktyczne ograniczenie: gdy F zbliża się do floor 0,031, metryka traci rozdzielczość i nie odróżnia już obwodów między sobą.

3.2 Uzasadnienie zbioru danych i konfiguracja `two_curves`

Zbiór `two_curves` pochodzi z pakietu `qml-benchmarks` i towarzyszącego badania porównawczego modeli QML [4]. To syntetyczny zbiór do klasyfikacji binarnej o kontrolowanej trudności (parametry `degree`, `offset`), co pozwala ustawić nietrywialny, lecz osiągalny pułap klasyczny. Badanie [4] pokazuje też, że przy małych zadaniach klasyczne modele często dorównują kwantowym, a usunięcie splątania bywa nieszkodliwe — co uzasadnia traktowanie wzorca splątającego jako obiektu badań, a nie źródła przewagi.

Zablokowana konfiguracja. Parametry modelu `two_curves` użytego we wszystkich eksperymentach:

Parametr	Wartość
liczba cech d	8
liczba kubitów n	5
`degree`	8
kodowanie	angle encoding z data re-uploading ($d = 8 > n = 5$)
readout	mean value $\frac{1}{n}\sum_q Z_q$
wzorzec splątający (model)	star
liczba warstw L (zablokowana)	3
dokładność testowa bezszumowa	0,911
podzbiór ewaluacyjny	30 punktów, zbalansowany, seeded

Depth sweep. Model wybrałam wykonując depth sweep po $L \in \{2, 3, 4, 5\}$ i stosując regułę: maksymalna dokładność testowa, remis rozstrzygany mniejszą liczbą bramek dwukubitowych.

L	dokł. treningowa	dokł. testowa	log. 2q	uwaga
2	0,933	0,889	8	
3	0,933	**0,911**	**12**	**wybrana** (remis, najmniej 2q)
4	0,933	0,911	16	
5	0,924	0,911	20	

3.3 Uzasadnienie kodowania (angle encoding)

Stosuję angle encoding: każda cecha wchodzi jako kąt obrotu jednokubitowego, $R_y(x_i)$. Dla `two_curves` angle encoding jest użyty w schemacie **data re-uploading** — ten sam blok kodowania powtarzam w każdej z L warstw, dzięki czemu obwód z $n = 5$ kubitami koduje $d = 8 > n$ cech (warunek $d \leq n \cdot L$), a funkcja modelu staje się skończonym szeregiem Fouriera po cechach, co daje większą wyrazistość bez zwiększania liczby kubitów [4]. Dla Banknote używam prostego R_y angle encoding (5 cech na 5 kubitów, bez re-uploadingu). Angle encoding jest tani w bramki i zgodny ze sprzętem, bo obroty są natywne.

3.4 Uzasadnienie ansatzu (HEA)

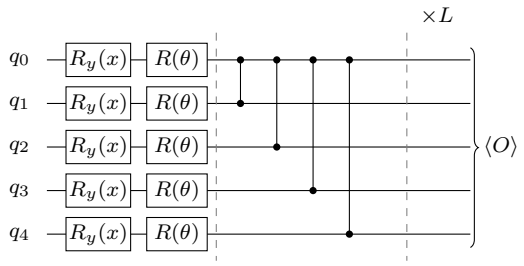
Używam Hardware-Efficient Ansatz (HEA): każda warstwa to (i) blok angle encoding, (ii) uczone obroty jednokubitowe, (iii) blok entangling. HEA używa bramek natywnych i lokalnego splątania, a wzorzec splątający jest regulowanym źródłem bramek dwukubitowych — ten sam obwód logiczny przepuszczam przez rosnący koszt routingu. Wybór HEA i traktowanie splątania jako zmiennej jest spójny z wnioskami benchmarku QML [4].

Poniżej pełne obwody czterech wariantów ansatzu, w kolejności rosnącego kosztu routingu. Każdy obwód pokazuje jedną warstwę: blok angle encoding $R_y(x)$, warstwę uczonych obrotów $R(\theta)$ oraz blok entangling złożony z bramek CZ; całość powtarzana jest L razy, po czym następuje odczyt obserwabli. Warianty różnią się *wyłącznie* blokiem entangling.

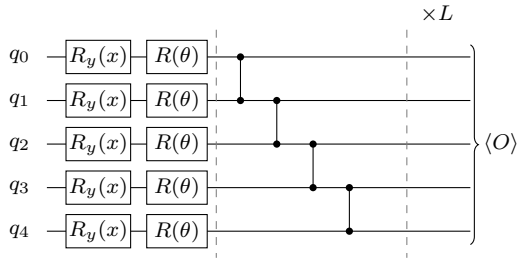
3.5 Model szumu i kalibracja urządzenia

Symulator Aer skalibrowałam do 5-kubitowej gwiazdy ODRA (hub QB3 = kubit logiczny 0). Zebrałam dwa okna kalibracyjne (`collect_odra_calibration.py`): pierwsze do budowy modelu szumu, drugie w dniu pomiaru na QPU, co pozwala ocenić dryf urządzenia.

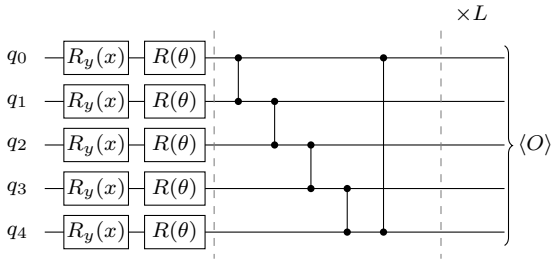
okno	T_1 [μs]	T_2^* [μs]	T_2^{echo} [μs]	p_{1q}	p_{2q}	p_{ro}
30.07.2026 (model)	15,6–21,2	7,0–10,4	11,0–14,7	$\sim$0,0020	0,0190	0,014–0,026
03.08.2026 (pomiar)	12,8–22,2	6,6–11,0	11,0–15,1	$\sim$0,0020	0,0203	0,015–0,030



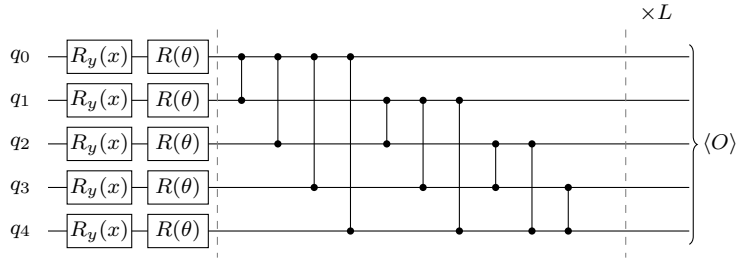
(a) **star** — hub q_0 splata się z każdym pozostałym kubitem; 4 bramki CZ na warstwę, zgodne z topologią urządzenia (bez SWAP).



(b) **linear** — łańcuch sąsiadów; 4 bramki CZ na warstwę.



(c) **circular** — łańcuch domknięty w ring; 5 bramek CZ.



(d) **all-to-all** — każda para kubitów; 10 bramek CZ na warstwę, najdroższy w routingu.

Rysunek 2: Pełne obwody czterech wariantów ansatzu HEA. Struktura warstwy jest identyczna (angle encoding $R_y(x)$, uczone obroty $R(\theta)$, blok entangling zaznaczony liniami przerywanymi), zmienia się wyłącznie blok CZ. Koszt po kompilacji na gwiazdę podaje tabela 1.

$t_{1q} = 20$ ns, $t_{2q} = 60$ ns (stałe). Między oknami błąd dwukubitowy p_{2q} wzrósł o $\sim 7\%$ (0,0190 $\rightarrow$ 0,0203), a błąd odczytu pogorszył się na górnym krańcu (0,026 $\rightarrow$ 0,030), przy stabilnym p_{1q} i lekkim spadku dolnej granicy T_1. Taki dryf — kilkuprocentowy w ciągu kilku dni — jest bezpośrednim uzasadnieniem, dlaczego ten sam obwód potrafi dać różny wynik na QPU w różnych dniach (por. sekcja 5.6).

4 Zbiór danych i ansätze Banknote

Dodatkowo, chcąc sprawdzić *znane* ansätze o różnym dostosowaniu do QPU, wykorzystuję dane i modele z projektu Banknote (KN-Axion; UCI Banknote, 5 cech, R_y angle encoding, cechy skalowane do $[-\pi/4, \pi/4]$, etykiety $\{-1, +1\}$). Repozytorium źródłowe: https://github.com/Kolo-Naukowe-Axion/QC1_Quantum_Banknote_Classifier_on_ODRA_5.

Stosuję nazewnictwo z pracy źródłowej:

- **topology** (w kodzie `star`) — natywny, hub QB2, readout Z na kubicie 2; kompiluje się na gwiazdę bez SWAP;
- **native** (w kodzie `odra`) — ring R_Z/CZ, readout kubit 0;
- **baseline** (w kodzie `simulator`) — ring CRX/CRY, readout kubit 0, najdroższy w CZ.

Ewaluacja odbywa się na pełnym zbiorze testowym foldu 1 (275 punktów, naturalna niezbalansowana proporcja 153/122), zgodnie z metodologią pracy źródłowej. Ze względu na koszt czasu QPU głównego sweepu (wszystkie ansätze i głębokości) nie powtarzam na pięciu foldach; pełną 5-foldową walidację krzyżową wykonuję wyłącznie w kluczowym punkcie $L = 6$ (sekcja 5.6), gdzie porównuję się z pracą źródłową.

5 Wyniki

Sekcja jest zorganizowana zbiorami: najpierw komplet wyników dla `two_curves` (koszt routingu, błąd $\langle O \rangle$ i dokładność, fidelity, wnioski), następnie analogicznie dla Banknote.

5.1 `two_curves`: routing ladder

Routing ladder to uporządkowany ciąg wariantów obwodu realizujących *ten sam* obwód logiczny, ale o rosnącym koszcie CZ po kompilacji — uzyskany przez zmianę wzorca entangling. Dzięki temu kontrolowanie zmieniam zmienną niezależną (koszt routingu), trzymając zadanie stałym. Każdy poziom ma własny klasyfikator wytrenowany przy tej samej pojemności.

Tabela 1: Routing ladder `two_curves` przy zablokowanym $L = 3$.

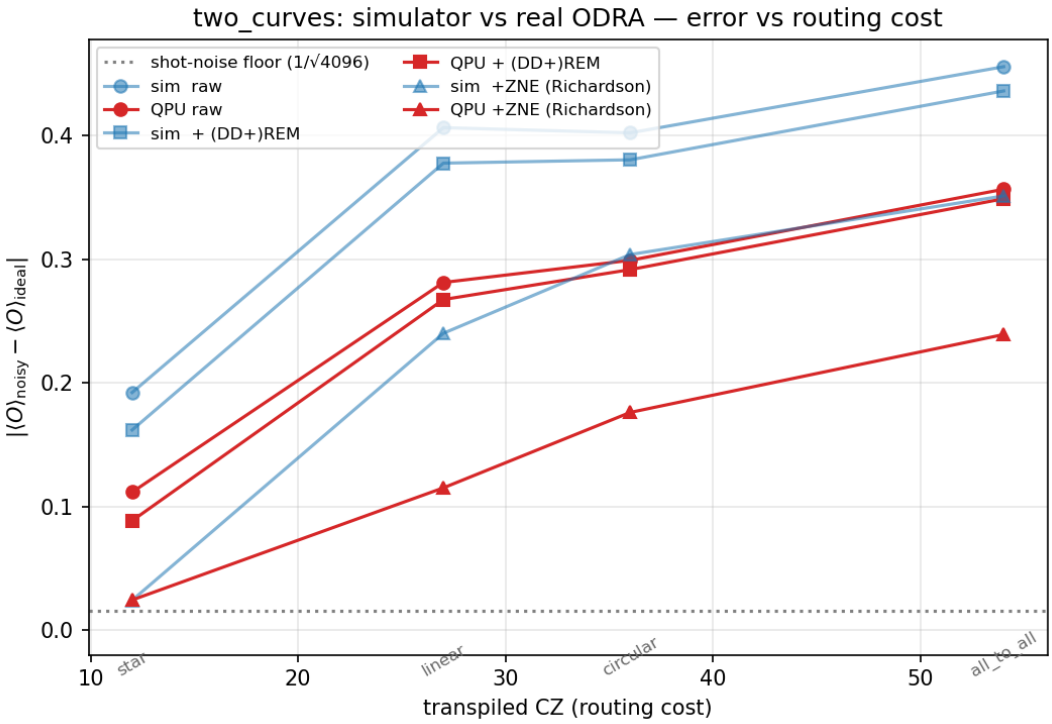
Poziom	Wzorzec	log. 2q	CZ po komp.	mirror CZ
0	star	12	12	24
1	linear	12	27	54
2	circular	15	36	72
3	all_to_all	30	54	108

5.2 `two_curves`: błąd $\langle O \rangle$ i dokładność — symulator vs QPU

Parametry pomiaru: 4096 shotów, skale szumu $\{1, 3, 5\}$, $R = 3$ powtórzenia (pasma błędu i dryf), 30 punktów ewaluacyjnych. Kolumny raportują kolejne szczeble mitygacji: raw → +REM → +ZNE (Richardson).

Tabela 2: `two_curves`: błąd $\langle O \rangle$ i dokładność. *Symulator* oznacza tu nasz **kalibrowany, szumowy** model Aer (DD+REM) — *nie* bezszumowy ideał; poniżej rzeczywiste ODRA (wiersze DD-off), $R = 3$.

		błąd $\langle O \rangle$			**accuracy**		
Wzorzec	CZ	raw	+REM	+ZNE	raw	+REM	+ZNE
Symulator							
star	12	0,192	0,162	0,024	0,867	0,867	0,867
linear	27	0,406	0,378	0,240	0,878	0,900	0,900
circular	36	0,402	0,380	0,304	0,900	0,900	0,900
all_to_all	54	0,456	0,436	0,351	0,889	0,900	0,900
Rzeczywiste ODRA (QPU), DD-off							
star	12	0,112	0,088	**0,024**	0,900	0,900	0,867
linear	27	0,281	0,267	0,115	0,922	0,922	0,900
circular	36	0,299	0,292	0,176	0,900	0,900	0,900
all_to_all	54	0,357	0,349	0,239	0,878	0,878	0,867
Rzeczywiste ODRA (QPU), DD-on — ablacja							
star	12	0,159	0,138	0,029	0,900	0,900	0,867
linear	27	0,375	0,365	0,209	0,900	0,900	0,900
circular	36	0,382	0,378	0,292	0,911	0,900	0,911
all_to_all	54	0,458	0,454	0,373	0,900	0,900	0,911



Rysunek 3: `two_curves`: $|\langle O \rangle$ err| vs CZ, symulator vs rzeczywiste ODRA, szczeble raw / +REM / +ZNE.

Wnioski.

1. **Błąd rośnie monotonicznie z kosztem CZ** — i na symulatorze, i na sprzęcie. Routing degraduje wynik, co potwierdza wybór CZ jako właściwej zmiennej niezależnej.

2. **ZNE działa i jest silne.** Na QPU przy star błąd spada z 0,112 do 0,024, czyli **4,6-krotnie**. Odzysk maleje z kosztem: przy all_to_all z 0,357 tylko do 0,239.

3. **Dokładność nie reaguje.** Dla każdego z czterech wzorców entangling dokładność pozostaje w przedziale 0,867–0,922, niezależnie od szczebla mitygacji. Jest to bezpośrednia ilustracja ram z sekcji 2.1: predykcja to $\mathrm{sgn}\langle O\rangle$, a więc próg, który sam z siebie tłumi szum. Punkty leżą daleko od granicy decyzyjnej, więc redukcja biasu nie zmienia znaku — to błąd $\langle O\rangle$ niesie tu sygnał.

4. **DD pogarsza wynik na sprzęcie.** Przy każdym wzorcu wiersz DD-on ma wyższy błąd niż DD-off (star: 0,159 vs 0,112; all_to_all: 0,458 vs 0,357).

5.3 `two_curves`: mirror fidelity

Pomiar wykonany na rzeczywistym QPU (8192 shotów, 5 reprezentatywnych wejść) oraz w symulatorze przy identycznym protokole.

Tabela 3: `two_curves`: mirror fidelity $P(|0\rangle^5)$. Floor depolaryzacyjny wynosi $2^{-5} = 0{,}031$.

		QPU		**symulator**		
Wzorzec	mirror CZ	DD-off	DD-on	DD-off	DD-on	QPU/sim
star	24	**0,549**	0,389	0,330	0,367	1,67×
linear	54	0,211	0,120	0,085	0,102	2,48×
circular	72	0,118	0,060	0,051	0,062	2,31×
all_to_all	108	0,094	0,048	0,054	0,059	1,73×

Uzasadnienie niskich wartości fidelity Bezwzględny poziom fidelity może wydawać się zaskakująco mały, jest jednak dokładnie taki, jakiego należy oczekiwać, i nie wynika z błędu pomiaru. Składają się na to trzy niezależne czynniki.

Po pierwsze, $P(|0\rangle^5)$ jest kryterium bardzo surowym: zdarzenie jest zaliczone tylko wtedy, gdy *wszystkie pięć* kubitów zostanie odczytanych poprawnie jednocześnie. Pojedynczy błąd na dowolnym kubicie niszczy cały wynik, więc wielkość ta spada znacznie szybciej niż jednokubitowa wartość oczekiwana $\langle Z\rangle$, do której przywykliśmy w pozostałych sekcjach.

Po drugie, obwód lustrzany z definicji *podwaja* koszt bramkowy: wariant star używa w inferencji 12 bramek CZ, ale jego wersja lustrzana już 24. Mierzymy zatem obwód dwa razy dłuższy niż ten, który realizuje klasyfikację.

Po trzecie, degradacja jest wykładnicza w liczbie bramek. Dopasowany model urządzenia (sekcja 5.7) daje efektywnie 0,86% błędu na bramkę CZ i 0,613% na bramkę jednokubitową. Dla wariantu star (24 CZ i 80 bramek jednokubitowych) przewiduje to $F \approx \exp(-0{,}0086 \cdot 24 - 0{,}00613 \cdot 80) \approx 0{,}50$, wobec zmierzonych 0,549. Zgodność jest bardzo dobra, co potwierdza, że pomiar jest spójny z niezależnie wyznaczonymi parametrami błędu.

Wnioski.

1. **Fidelity spada monotonicznie z kosztem routingu** — od 0,549 przy star do 0,094 przy all_to_all. Trend jest niezależny od zadania, więc potwierdza, że degradacja jest własnością struktury obwodu, a nie klasyfikatora.

2. **QPU jest o 1,7–2,5× lepsze niż nasz symulator** przy każdym poziomie. Kalibrowany model szumu jest systematycznie pesymistyczny, co jest spójne z wnioskiem z pomiaru błędu $\langle O \rangle$.

3. **DD pogarsza fidelity na sprzęcie, ale poprawia ją w symulatorze.** Na QPU każda konfiguracja z DD wypada gorzej (star: 0,389 wobec 0,549), podczas gdy w symulatorze DD nieznacznie pomaga (0,367 wobec 0,330). Przyczyna jest jasna: w symulatorze modeluję DD jako poprawę $T_2^* \to T_2^{\text{echo}}$, więc z konstrukcji może ono wyłącznie pomóc. Rzeczywiste impulsy DD wnoszą natomiast własny błąd koherentny, którego model nie zawiera. Wniosek praktyczny: *o skuteczności DD nie wolno wnioskować z symulacji*, trzeba ją zmierzyć na urządzeniu — i na IQM SPARKu wypada ona negatywnie.

4. **Najdroższe warianty wyczerpują metrykę.** Wartości 0,118 i 0,094 są już tylko 3–4× powyżej floor 0,031, więc mirror fidelity traci tam rozdzielczość i nie należy nadinterpretować różnicy między circular a all_to_all.

5.4 Banknote: baseline bezszumowy i routing ladder kosztu

Tabela 4: Banknote: dokładność bezszumowa (**nasz symulator statevector**, średnia z 5 foldów) i koszt CZ na gwieździe.

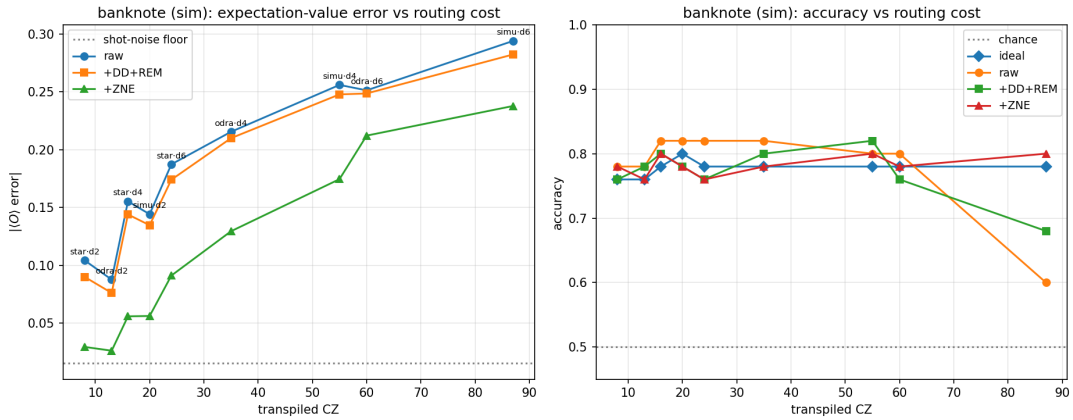
Ansatz (nazwa w kodzie)	głęb.	CZ	głęb. po komp.	dokł. bezszum.
topology (`star`)	2/4/6	8/16/24	14/26/38	0,856 / 0,889 / 0,885
native (`odra`)	2/4/6	13/35/57	24/66/108	0,871 / 0,876 / 0,886
baseline (`simulator`)	2/4/6	20/52/87	56/140/231	0,891 / 0,880 / 0,883

Wniosek. Trzy ansätze mają niemal identyczną dokładność bezszumową (około 0,88), ale różnią się kosztem CZ nawet 3,6-krotnie (24 vs 87 przy głębokości 6). Jest to więc czysta routing ladder: przy ustalonym zadaniu i ustalonej jakości modelu zmienia się niemal wyłącznie koszt kompilacji.

5.5 Banknote: badanie ablacyjne w symulatorze

Tabela 5: Banknote — **nasz kalibrowany symulator szumowy** (Aer, DD+REM): błąd $\langle O \rangle$ raw → ZNE oraz dokładność raw → ZNE.

Ansatz	głęb.	CZ	err raw	err +DD+REM	err ZNE	dokł. (raw → ZNE)
topology	2	8	0,104	0,090	0,030	0,78 → 0,78
native	2	13	0,088	0,076	0,026	0,78 → 0,76
baseline	2	20	0,144	0,135	0,056	0,82 → 0,78
topology	4	16	0,155	0,144	0,056	0,82 → 0,80
native	4	35	0,215	0,210	0,130	0,82 → 0,78
baseline	4	55	0,256	0,248	0,175	0,80 → 0,80
topology	6	24	0,187	0,174	0,091	0,82 → 0,76
native	6	60	0,251	0,249	0,212	0,80 → 0,78
baseline	6	87	0,294	0,282	0,238	**0,60 → 0,80**



Rysunek 4: Banknote (symulator): błąd $\langle O \rangle$ (lewy panel) i dokładność (prawy) vs CZ, zbiorczo dla głębokości $\{2, 4, 6\}$.

Wnioski. Najważniejszy wynik tej sekcji: **ZNE potrafi odzyskać dokładność klasyfikatora**. Dla wariantu baseline przy głębokości 6 (87 CZ) mitygacja podnosi dokładność z 0,60 do 0,80, czyli praktycznie do poziomu bezszumowego — szum zdążył tam już przerzucić znak $\langle O \rangle$ dla części punktów, a ZNE cofa ten efekt.

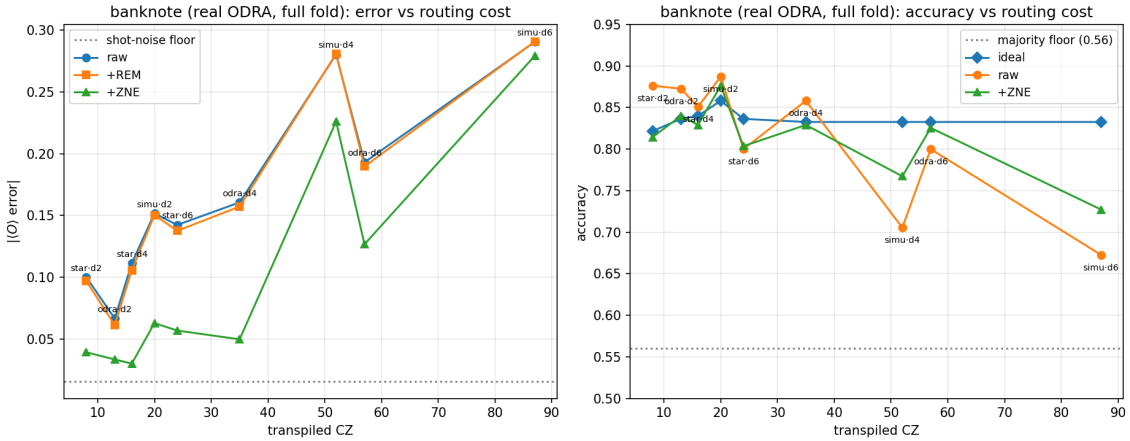
Poza tym jednym przypadkiem krzywa ZNE leży wprawdzie poniżej raw i DD+REM dla każdej konfiguracji, ale różnica maleje wraz z kosztem CZ, więc odzysk słabnie. Potwierdza to obserwację z `two_curves`: dokładność reaguje na mitygację dopiero wtedy, gdy szum jest na tyle duży, że zaczyna zmieniać znak wartości oczekiwanej.

5.6 Banknote: rzeczywiste QPU

Wynik główny tej sekcji pochodzi z **pełnego foldu testowego (275 punktów, fold 1, naturalna proporcja klas 153/122, floor większości** 0,56**)** — czyli dokładnie ze zbioru ewaluacyjnego pracy źródłowej — wykonanego na rzeczywistym QPU dla wszystkich trzech ansätze i trzech głębokości. Metryki: błąd $\langle O \rangle$ (raw → ZNE), dokładność (ideał / raw / ZNE) oraz macro-F1 (raw / ZNE). DD wyłączone (uzasadnienie: wynik negatywny DD, sekcja poniżej i 5.7).

Tabela 6: Banknote na ODRA — **nasz pomiar QPU**, pełny fold (275 pkt), DD-off. Dla każdego ansatzu podano błąd $\langle O \rangle$ raw → ZNE, dokładność (ideał bezszumowy z naszego symulatora statevector / raw QPU / ZNE) oraz macro-F1 (raw / ZNE). ZNE = REM+ekstrapolacja Richardsona.

			err $\langle O \rangle$		dokładność			macro-F1	
Ansatz	głęb.	CZ	raw	ZNE	ideał	raw	ZNE	raw	ZNE
topology	2	8	0,100	0,039	0,822	0,876	0,815	0,873	0,801
native	2	13	0,067	0,033	0,836	0,873	0,840	0,871	0,834
baseline	2	20	0,152	0,063	0,858	0,887	0,876	0,889	0,874
topology	4	16	0,111	0,030	0,840	0,851	0,829	0,843	0,815
native	4	35	0,161	0,050	0,833	0,858	0,829	0,857	0,815
baseline	4	52	0,280	0,226	0,833	0,706	**0,767**	0,699	**0,767**
topology	6	24	0,142	0,057	0,836	0,800	0,804	0,778	0,783
native	6	57	0,193	0,127	0,833	0,800	0,826	0,781	0,815
baseline	6	87	0,291	0,279	0,833	0,673	**0,727**	0,663	**0,724**



Rysunek 5: Banknote na rzeczywistym ODRA (pełny fold, 275 pkt, DD-off): błąd $\langle O \rangle$ (lewy panel) oraz dokładność (prawy panel) wobec transpilowanego kosztu CZ, dla drabiny routingu topology $<$ native $<$ baseline i głębokości $\{2, 4, 6\}$, wzdłuż potoku raw $\rightarrow$ +REM $\rightarrow$ +ZNE. Analogiczny do rysunku symulatorowego z sekcji 5.5. Dane z tabeli 6.

Główny wynik sprzętowy — odzysk dokładności i słabnięcie ZNE z kosztem CZ. Poniższe wnioski opisują pomiar pojedynczego foldu (fold 1, tab. 6); wersję odporną, uśrednioną po pięciu foldach, podaje tab. 8 niżej (baseline jest silnie zależny od foldu, więc liczby dla 87 CZ należy czytać łącznie z nią). Dane na pełnym foldzie układają się w spójny obraz sterowany kosztem routingu.

1. **Współczynnik redukcji błędu ZNE maleje monotonicznie z CZ.** Przy niskim koszcie ZNE tnie błąd $\langle O \rangle$ silnie (topology, 16 CZ: 0,111 $\rightarrow$ 0,030, czyli 3,7$\times$), przy wysokim coraz słabiej, aż do granicy skuteczności: baseline przy 87 CZ daje już tylko 0,291 $\rightarrow$ 0,279 (współczynnik 1,04, mitygacja praktycznie nieskuteczna). Jest to najczystsza sprzętowa ilustracja słabnięcia ZNE z kosztem CZ.

2. **Dokładność reaguje wyłącznie tam, gdzie szum zdążył przerzucić znak $\langle O \rangle$.** Dla tanich ansätze (topology, native, oraz baseline przy głębokości 2) dokładność surowa jest już bliska ideału, więc ZNE nie ma czego odzyskiwać i bywa nieznacznie niższa (nasycenie, dyskusja w sekcji 2.1). Odzysk pojawia się dopiero przy baseline i dużym koszcie: przy 52 CZ dokładność rośnie 0,706 $\rightarrow$ 0,767 (macro-F1 0,699 $\rightarrow$ 0,767), a przy 87 CZ 0,673 $\rightarrow$ 0,727 (macro-F1 0,663 $\rightarrow$ 0,724) — odzysk rzędu 34–48% luki do ideału, mierzony na rzeczywistym sprzęcie.

3. **Macro-F1 podąża za dokładnością, więc odzysk jest zrównoważony klasowo.** W żadnym wierszu DD-off macro-F1 nie odrywa się od dokładności (np. baseline 87 CZ: dokł. 0,673 / F1 0,663), czyli klasyfikator nie zapada się w stronę klasy większościowej — mimo naturalnej niezbalansowanej proporcji foldu.

DD na sprzęcie — ablacja (podzbiór 40 pkt, głębokość 6). Poniższa tabela (te same obwody, DD włączone) dokumentuje wynik negatywny DD, który na pełnym foldzie nie był mierzony.
Przy każdym ansatzu włączenie DD wyraźnie obniża dokładność względem DD-off (topology: 0,733 $\rightarrow$ 0,517; native: 0,775 $\rightarrow$ 0,483), co potwierdza wynik negatywny DD z sekcji 5.7 i uzasadnia raportowanie potoku jako REM+ZNE.

Tabela 7: Banknote na ODRA, głębokość 6 — ablacja DD (podzbiór zbalansowany 40 pkt, te same obwody, DD włączone).

Ansatz	CZ	err raw	err ZNE	dokł. raw	dokł. ZNE
topology	24	0,183	0,140	0,517	0,650
native	60	0,236	0,198	0,483	0,642
baseline	84	0,232	0,198	0,525	0,558

Porównanie z pracą źródłową (raw wobec raw) i walidacja krzyżowa 5-fold. Praca źródłowa mierzy dokładność i macro-F1 *na rzeczywistym QPU* (IQM Spark), na zamrożonych wagach, *bez mitygacji* (raw), uśredniając po pięciu foldach walidacji krzyżowej. Właściwym punktem odniesienia jest zatem nasza kolumna *raw* (bez REM/ZNE); REM i ZNE stanowią *dodatkowy* poziom odzysku ponad tym, co raportuje praca. Aby porównać w identycznych warunkach, powtórzyłam pomiar na wszystkich pięciu foldach przy głębokości 6 (native i baseline, DD-off, 275 pkt/fold, 4096 shots); wynik zapisany w `banknote_hardware_cv_d6.csv`.

Tabela 8: Banknote L=6 na ODRA — walidacja krzyżowa 5-fold (275 pkt/fold, DD-off, 4096 shots), średnia±odchylenie międzyfoldowe. Kolumny *raw*/*ZNE* to **nasz pomiar QPU**; ostatnia kolumna to wynik **pracy źródłowej na QPU** (raw, bez mitygacji) — i to ją należy porównywać z naszą kolumną *raw*. ZNE = REM+ekstrapolacja Richardsona.

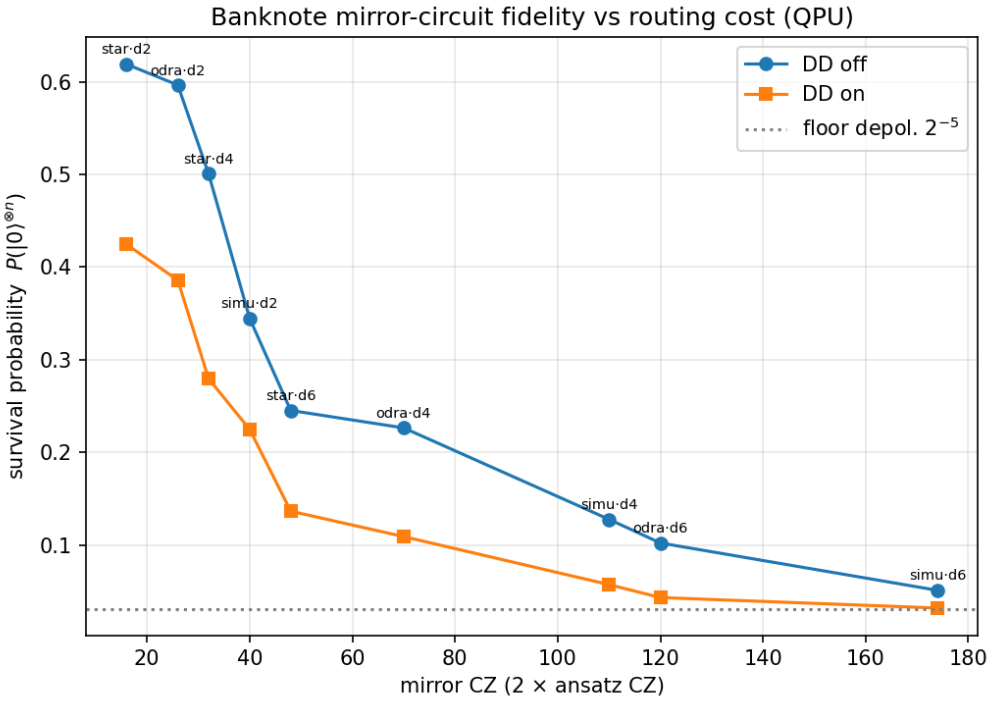
		nasze QPU: dokł.		**nasze QPU**: macro-F1		praca QPU
Ansatz	CZ	raw	ZNE	raw	ZNE	dokł. / F1
native (odra)	57–60	$0{,}809 \pm 0{,}042$	$0{,}867 \pm 0{,}030$	$0{,}796 \pm 0{,}049$	$0{,}862 \pm 0{,}033$	0,590 / 0,142
baseline (sim)	84–87	$0{,}626 \pm 0{,}091$	$0{,}643 \pm 0{,}097$	$0{,}601 \pm 0{,}107$	$0{,}624 \pm 0{,}108$	0,565 / 0,044

Wnioski z walidacji krzyżowej:

1. **Nie odtwarzamy zapaści ringów z pracy — i nie wynika to z naszej mitygacji.** Praca raportuje przy L=6 zapaść obu ringów do floor klasy większościowej (native 0,590 / F1 0,142; baseline 0,565 / F1 0,044); u nas native pozostaje zdrowy (raw 0,809 / F1 0,796), a baseline degraduje się bez zapaści klasowej (F1 $\approx$ 0,60). Ponieważ wagi, ansätze i transpilacja są identyczne, a nasz raw już przewyższa pracę, różnicę przypisuję dryfowi kalibracji (bezpośredni dowód: ten sam fold 1 baseline dał raw 0,673 dnia 1.08 i 0,607 dnia 3.08). Nie jest to więc wynik, na którym się skupiam — **wymaga on jeszcze double-checku**, a kwestia zapadania się ansatzu native (`odra`) zostanie rozstrzygnięta w Miesiącu 2.

2. **ZNE odzyskuje ponad raw także tutaj, ale słabnie z kosztem CZ.** Native (57 CZ): raw 0,809 $\rightarrow$ ZNE 0,867 (błąd $\langle O \rangle$ 0,190 $\rightarrow$ 0,119, 1,6×). Baseline (87 CZ): raw 0,626 $\rightarrow$ ZNE 0,643 (błąd 0,278 $\rightarrow$ 0,284) — przy tym koszcie redukcja błędu *zanika* i uśredniona po foldach potrafi się odwrócić, co potwierdza górną granicę użyteczności ZNE z sekcji 6.

5.7 Banknote: mirror fidelity na QPU



Rysunek 6: Banknote mirror-circuit fidelity $P(|0\rangle^5)$ na rzeczywistym QPU wobec kosztu routingu (mirror CZ), DD-off vs DD-on; linia przerywana to floor depolaryzacyjny 2^{-5}.

Tabela 9: Banknote: mirror fidelity $P(|0\rangle^5)$ na rzeczywistym QPU (8192 shotów).

Ansatz	głęb.	mirror CZ	DD-off	DD-on	DD-on / DD-off
topology	2	16	0,619	0,425	0,69
topology	4	32	0,501	0,280	0,56
topology	6	48	0,245	0,137	0,56
native	2	26	0,596	0,386	0,65
native	4	70	0,226	0,109	0,48
native	6	120	0,102	0,043	0,42
baseline	2	40	0,345	0,225	0,65
baseline	4	110	0,128	0,057	0,45
baseline	6	174	0,051	0,032	0,63

Wnioski.

1. Fidelity spada monotonicznie z mirror CZ w obrębie każdego ansatzu i porządkuje ansätze dokładnie tak, jak przewiduje koszt routingu: topology > native > baseline.

2. **DD pogarsza fidelity we wszystkich dziewięciu konfiguracjach**, zachowując jedynie 42–69% wartości DD-off, przy czym kara rośnie z głębokością obwodu.

3. Baseline przy głębokości 6 osiąga 0,051, czyli praktycznie floor depolaryzacyjny 0,031 — obwód traci niemal całą informację. To niezależne potwierdzenie, że słabnięcie ZNE przy wysokim koszcie CZ zbiega się z reżimem, w którym obwód przestaje w ogóle przenosić sygnał.

4. Łącząc wszystkie 13 punktów pomiarowych QPU z obu badań (`two_curves` i Banknote), jednolity dwuparametrowy model $F = (1 - 2^{-n}) \exp(-a\, n_{CZ} - b\, n_{1q}) + 2^{-n}$ odtwarza pomiary z medianą błędu względnego 10,5% przy efektywnym 0,86% na bramkę CZ i 0,613% na bramkę jednokubitową. Ponieważ obwody zawierają 2–4× więcej bramek jednokubitowych niż CZ, *to bramki jednokubitowe odpowiadają za około 60% budżetu błędu.* Sam koszt CZ jest więc dobrym, ale niepełnym predyktorem jakości na sprzęcie.

6 Najważniejsze obserwacje z Miesiąca 1

Poniżej zbieram najważniejsze, zweryfikowane wnioski z całego miesiąca. Każdy jest poparty konkretnymi liczbami z sekcji wyników; podaję je w formie skrótowej jako podsumowanie wykonawcze.

1. **ZNE działa, a jego siła słabnie przewidywalnie z kosztem CZ.** Na rzeczywistym QPU (`two_curves`, DD-off) współczynnik redukcji błędu $\langle O \rangle$ spada wraz z routingiem: star (12 CZ) 0,112 → 0,024 (4,6×), linear (27 CZ) 0,281 → 0,115 (2,4×), circular (36 CZ) 0,299 → 0,176 (1,7×), all_to_all (54 CZ) 0,357 → 0,239 (1,5×). Trend jest monotoniczny i powtarza się na symulatorze.

2. **Accuracy nie jest zawsze miarodajne** — dopóki szum nie przerzuci znaku $\langle O \rangle$. W `two_curves` dokładność trzyma się w przedziale 0,87–0,92 mimo 15× zmiany błędu $\langle O \rangle$. Mitygacja zaczyna poprawiać dokładność dopiero *powyżej progu kosztu*, gdy szum przerzucił znak $\langle O \rangle$ dla części punktów — na QPU (Banknote, baseline) próg leży około 50 CZ: przy 52 CZ dokładność rośnie 0,706 → 0,767, a przy 87 CZ 0,673 → 0,727. Poniżej progu dokładność surowa jest już przy suficie i ZNE jej nie podnosi. To bezpośrednia ilustracja ram bias/wariancja z sekcji 2.1.

3. **Dynamical Decoupling to wynik negatywny na tym urządzeniu — i symulator tego nie widzi.** Natywne `STANDARD_DD` pogorszyło każdą mierzoną wielkość w czterech niezależnych eksperymentach:

eksperyment	DD-off	DD-on
`two_curves` star, błąd $\langle O \rangle$	0,112	0,159
`two_curves` star, mirror fidelity	0,549	0,389
Banknote d6 star, dokładność QPU	0,733	0,517
Banknote d6 star, mirror fidelity	0,245	0,137

   Kalibrowany symulator przewiduje, że DD *pomaga*, bo modeluje je wyłącznie jako poprawę $T_2^* \to T_2^{\text{echo}}$. Wniosek metodologiczny: skuteczność DD trzeba mierzyć na urządzeniu.

4. **Kalibrowany symulator jest konserwatywnym, pesymistycznym przybliżeniem.** Każdy punkt mirror fidelity na sprzęcie przewyższa predykcję symulatora o czynnik od 1,7 do 2,5 (`two_curves`: star 0,549 wobec 0,330, linear 0,211 wobec 0,085). Trening względem symulatora daje więc bezpieczne dolne ograniczenie, a nie zawyżoną prognozę.

5. **Mirror fidelity opisuje jeden dwuparametrowy model per-bramka.** Dopasowanie do 13 punktów QPU z obu badań daje $\approx$ 0,86% błędu na bramkę CZ i $\approx$ 0,61% na bramkę jednokubitową (mediana błędu względnego 10,5%); dla star model przewiduje $F \approx$ 0,50 wobec zmierzonych 0,549. Ponieważ mirror fidelity jest niezależna od zadania ($UU^\dagger$), degradacja jest własnością struktury obwodu, nie klasyfikatora.

6. **Koszt CZ to właściwa, lecz niepełna zmienna niezależna.** Błąd rośnie monotonicznie z CZ w dwóch różnych zbiorach i niezależnie od ansatzu, co uzasadnia całą konstrukcję routing ladder. Zarazem obwody mają 2–4× więcej bramek jednokubitowych niż CZ, więc te pierwsze odpowiadają za około 60% budżetu błędu — sam CZ jest dobrym, ale niepełnym predyktorem. Ta intuicja będzie kluczowa w Miesiącu 2 przy ustalaniu progu opłacalności mitygacji (threshold) wzdłuż osi kosztu CZ.

7. **ZNE ma dwa różne profile zależności od kosztu CZ — i trzeba je rozróżnić.**

   - *Redukcja błędu $\langle O \rangle$ słabnie monotonicznie z CZ.* Jest najsilniejsza przy niskim koszcie i zanika przy wysokim: współczynnik spada z 4,6× (12 CZ) do 1,04× (87 CZ). Dla tej metryki nie ma „okna– ZNE jest po prostu najlepsze przy tanich obwodach.
   - *Odzysk dokładności ma natomiast charakter okna.* Pojawia się dopiero powyżej pewnego progu kosztu (tu $\gtrsim$ 50 CZ), gdy szum zdąży obniżyć dokładność surową poniżej ideału i jest co odzyskiwać (baseline 52 CZ: 0,706 $\to$ 0,767; 87 CZ: 0,673 $\to$ 0,727). Poniżej progu dokładność surowa jest już przy suficie, więc ZNE nic nie wnosi i bywa nieznacznie niższa (dodana wariancja).

   Dolna krawędź okna jest zmierzona. Górną krawędź lokalizuje walidacja 5-foldowa: przy 87 CZ (baseline L=6) uśredniona po foldach redukcja błędu $\langle O \rangle$ *zanika i potrafi się odwrócić* (0,278 $\to$ 0,284), a przyrost dokładności (0,626 $\to$ 0,643) mieści się w rozrzucie międzyfoldowym — czyli w okolicach 85–90 CZ ZNE przestaje być opłacalne. Dokładne wyznaczenie progu na innych urządzeniach jest zadaniem Miesiąca 2. Dodatkowo wariant wykładniczy ekstrapolacji staje się niestabilny przy wysokim koszcie.

8. **Mirror fidelity ma granicę rozdzielczości przy podłodze depolaryzacyjnej** $2^{-5} =$ 0,031. Dla all_to_all (`two_curves`) wynosi 0,094 — tylko $\sim 3\times$ powyżej floor — więc różnic circular vs all_to_all nie należy nadinterpretowywać.

Podsumowanie QEM (REM+ZNE) mierzalnie odzyskuje informację na rzeczywistym sprzęcie: redukcja błędu $\langle O \rangle$ jest najsilniejsza przy niskim koszcie CZ i słabnie monotonicznie z routingiem, natomiast odzysk dokładności włącza się dopiero powyżej progu szumu — a przy tym DD na tym urządzeniu szkodzi mimo że symulator przewiduje korzyść, a niezależny od zadania model mirror fidelity wiąże wszystko z błędami pojedynczych bramek.

7 Uzasadnienie rezygnacji z kubitów logicznych (QEC)

Rozważałam zakodowanie każdego kubitu logicznego w około 13 kubitów fizycznych (rząd wielkości kodu powierzchniowego $d = 3$). Odrzucam pełne QEC z trzech niezależnych powodów [5, 1]:

1. **Budżet kubitów.** $5 \times 13 = 65 > 54$ (Emerald) — nie mieści się nawet na największym urządzeniu z planu.

2. **Wymóg poniżej progu.** QEC pomaga tylko wtedy, gdy błąd fizyczny jest mniejszy niż próg (około 0,5–1%) [6]. ODRA ma $p_{2q} \approx 1{,}9\%$, a Garnet i Emerald są blisko progu; w tym reżimie kodowanie dokłada więcej błędu, niż usuwa.

3. **Bramki nie-Clifforda.** VQC używa ciągłych obrotów zależnych od danych ($R_y(x)$), nietranswersalnych.

„Wariant logiczny" realizuję zatem jako uzasadnioną wersję zredukowaną (Deliverable D3).

8 Deliverables, podsumowanie i wnioski

8.1 Status deliverables Miesiąca 1

Deliverable	Status	Gdzie w dokumencie / w kodzie
D1. Przegląd literatury (mitygacja + narzut kubitów logicznych)	✓	Sekcja 11 oraz *Literatura*; kontekst teoretyczny w sekcji 2
D2. Raport baseline'u obwodu i metryk	✓	Sekcje 5.1–5.6 (tabele i rysunki); kod: `freeze_reference.py` (zamrożona referencja bezszumowa), `train_vqc.py`, `train_patterns.py`; dane: `review_notes.md`, katalog `figures/`
D3. Wariant zakodowany/logiczny albo uzasadniona wersja zredukowana	✓	Sekcja 7 (analiza QEC → QEM, trzy niezależne powody odrzucenia)
D4. Protokół eksperymentalny mapowania optymalnego i niekorzystnego	✓	Sekcja 5.1 (definicja routing ladder, tabela 1); kod: `routing_sweep.py` (generacja routing ladder), `run_hardware.py` (wykonanie na QPU)

8.2 Podsumowanie i wnioski

- Zbudowałam powtarzalny zestaw narzędzi QEM z treningiem w kalibrowanym symulatorze i inferencją na sprzęcie. Zbiór `two_curves` został zmierzony na rzeczywistym QPU zarówno pod względem błędu $\langle O \rangle$, jak i mirror fidelity, dzięki czemu stanowi gotowy punkt odniesienia — ten sam protokół można teraz zastosować bez zmian do ewaluacji na większych urządzeniach (Garnet, Emerald) i porównać wyniki wprost.

- Błąd $\langle O \rangle$ rośnie monotonicznie z kosztem CZ, a odzysk ZNE maleje z CZ — spójnie na symulatorze i na sprzęcie. Odpowiada to na pytania badawcze 3 i 4.

- **Skuteczność ZNE maleje monotonicznie z kosztem CZ.** Na pełnym foldzie współczynnik redukcji błędu $\langle O \rangle$ spada z 3,7× przy 16 CZ do 1,04× przy 87 CZ (mitygacja praktycznie nieskuteczna). Bezpiecznym wnioskiem jest *malejąca opłacalność mitygacji w okolicach* 85–90 *CZ*, a nie aktywne pogarszanie dokładności. Ilościowe wyznaczenie tego progu na Garnecie i Emeraldzie (inna topologia, inny profil błędów) jest zadaniem Miesiąca 2.

- **ZNE odzyskuje dokładność klasyfikatora na sprzęcie** tam, gdzie szum przerzucił znak $\langle O \rangle$: baseline przy 52 CZ zyskuje 0,706 → 0,767 (macro-F1 równolegle, bez zapaści

klasowej). Przy 87 CZ odzysk jest już w granicach rozrzutu międzyfoldowego (walidacja 5-fold: 0,626 → 0,643), co wyznacza górną granicę opłacalności mitygacji.

- **DD w natywnej konfiguracji urządzenia jest wynikiem negatywnym** — pogarsza wszystkie mierzone wielkości w czterech niezależnych eksperymentach. Właściwym opisem zastosowanego potoku jest zatem REM + ZNE.
- **Porównanie z pracą źródłową (raw wobec raw, walidacja 5-fold) nie odtwarza raportowanej zapaści ringów przy L=6**: native pozostaje zdrowy, baseline degraduje się bez zapaści klasowej, a różnicę — ponieważ wagi, ansätze i transpilacja są identyczne — przypisuję dryfowi kalibracji urządzenia. Wynik wzmacnia tezę pracy o zależności zachowania on-device od kalibracji.

9 Repozytorium

Kod projektu jest dostępny na GitHub: https://github.com/karinaleskiewicz06/QEM

Główne pliki:

- `ansatz.py` — HEA z data re-uploading, wzorce entangling i liczenie kosztu dwukubitowego. Testy: `test_ansatz.py`.
- `noisy_sim.py` — kalibrowany model szumu Aer (gwiazda ODRA), harmonogram bezczynności, REM, ładowanie kalibracji.
- `zne_dryrun.py` — prymitywy ZNE (unitary folding, ekstrapolacja liniowa / Richardsona / wykładnicza), przebieg ablacyjny w symulatorze.
- `run_hardware.py` — wykonanie `two_curves` na ODRA (iqm-client), staged rollout, wznawialny zapis, ablacja DD.
- `collect_odra_calibration.py` — pobranie i remap kalibracji ODRA.

Odtworzenie wyników (skrypt → dane → tabela/rysunek). Każdy wynik w raporcie da się prześledzić do konkretnej komendy i pliku:

Skrypty z prefiksem `banknote_study/` podano bez tego prefiksu dla zwięzłości.

Skrypt / komenda	Plik wynikowy	W raporcie
`routing_sweep.py`	`routing_ladder.csv`	Tab. 1 (5.1)
`run_hardware.py --submit`	`hardware_results.csv`	Sekcja 5.2
`mirror_fidelity_two_curves.py`	`two_curves_mirror_ fidelity{,_sim}.csv`	Sekcja 5.3
`noiseless_and_cost.py`	`banknote_noiseless_ cost.csv`	Sekcja 5.4
`run_zne_banknote.py`	`banknote_zne_ d{2,4,6}.csv`	Sekcja 5.5
`run_hardware_banknote.py --submit`	`banknote_hardware_ fullfold.csv`	Tab. 6 (5.6)
ten sam, `--folds 1..5 --depths 6`	`banknote_hardware_ cv_d6.csv`	5.6 (CV, w toku)
`mirror_fidelity.py`	`banknote_mirror_ fidelity.csv`	Sekcja 5.7
`make_figures.py`	`figures/*.png`	rysunki sekcji 5

Skrypty sprzętowe domyślnie działają w trybie `--dry-run` (budują i walidują obwody lokalnie, nic nie wysyłają); wysyłka wymaga flagi `--submit` oraz zmiennych `IQM_SERVER_URL` i `IQM_TOKEN`. Zapis jest wznawialny (`--resume`).

10 Plan na Miesiąc 2

Na podstawie wyników Miesiąca 1 plan na Miesiąc 2 obejmuje trzy kierunki:

- **Rozszerzenie na pozostałe dwa urządzenia.** Przeniesienie routing ladder na IQM Garnet (20 kubitów) i IQM Emerald (54 kubity), czyli na topologię kraty kwadratowej, aby sprawdzić, czy obserwowane zależności są własnością gwiazdy, czy ogólną własnością narzutu routingu.
- **Wyznaczenie progu.** Ilościowe określenie progu kosztu dwukubitowego, przy którym mitygacja przestaje być opłacalna — na podstawie zaobserwowanego w Miesiącu 1 słabnięcia ZNE w okolicach 85–90 CZ, zmierzonego teraz na trzech różnych urządzeniach i topologiach.
- **Warstwa „logical-ish".** Detekcja błędów z post-selekcją (małe kody, na przykład $[[4, 2, 2]]$) jako bliskoterminowy odpowiednik ochrony logicznej — w miarę możliwości sprzętowych, bez wymogu szybkiego feed-forward.

11 Przegląd literatury

Poniżej adnotowany przegląd, pogrupowany według filarów projektu: mitygacja błędów (ZNE, REM), narzut kubitów logicznych / QEC oraz benchmarking QML (zbiór danych, encoding, ansatz).

Mitygacja błędów — przegląd. Cai i in., *Quantum Error Mitigation* [1]. Kompletny przegląd metod QEM w erze NISQ (ZNE, PEC, REM, symetryzacja) wraz z ramami estymatora: dekompozycja MSE na bias i wariancję oraz narzut próbkowania C_{em}. **Związek z projektem:** dostarcza formalizmu, w którym mierzę błąd $\langle O \rangle$ (redukcja biasu) i uzasadniam, dlaczego dokładność jest metryką wtórną; punkt odniesienia dla wyboru potoku mitygacji.

Zero-Noise Extrapolation. Li i Benjamin, *Efficient variational quantum simulator incorporating active error minimisation* [5]. Jedna z prac wprowadzających ideę sztucznego zwiększania błędu i ekstrapolacji do zera; omawia też, dlaczego QEC jest kosztowne. **Związek z projektem:** teoretyczne źródło mojego ZNE oraz część uzasadnienia rezygnacji z pełnego QEC (sekcja 7).

Giurgica-Tiron i in., *Digital zero noise extrapolation* [2]. Wprowadza unitary folding ($U \to U(U^\dagger U)^k$) jako cyfrowe skalowanie szumu dostępne na poziomie bramek oraz porównuje ekstrapolacje: liniową, Richardsona i wykładniczą. **Związek z projektem:** bezpośrednia podstawa mojej implementacji ZNE (skale $\{1, 3, 5\}$, trzy warianty ekstrapolacji), wykonanej samodzielnie w repozytorium.

Readout Error Mitigation. Koh, Koh i Thompson, *Readout Error Mitigation for Mid-Circuit Measurements and Feedforward* [3]. Formalizuje błędy odczytu jako proces klasyczny i podaje protokół REM, także dla pomiarów śródobwodowych. **Związek z projektem:** uzasadnia REM jako warstwę bazową przed ZNE; stosuję dokładny, per-kubitowy model Z/I ($\langle Z \rangle / (1 - 2p)$) zamiast pełnej macierzy A.

Narzut kubitów logicznych / QEC. Google Quantum AI, *Quantum error correction below the surface code threshold* [6]. Pierwsza demonstracja logicznego kubitu, którego błąd *maleje* wraz ze wzrostem odległości kodu ($d = 3, 5, 7$) — tzn. działanie poniżej progu — przy koszcie rzędu d^2 kubitów fizycznych na jeden logiczny. **Związek z projektem:** kwantyfikuje narzut kubitów logicznych i wymóg pracy poniżej progu, na których opieram uzasadnienie rezygnacji z pełnego QEC na rzecz QEM (sekcja 7); pokazuje zarazem, że pełna ochrona logiczna jest poza zasięgiem urządzeń z planu (ODRA/Garnet/Emerald).

Benchmarking QML — zbiór danych, encoding, ansatz. Bowles, Ahmed i Schuld, *Better than classical?* [4]. Duże, systematyczne badanie 12 modeli QML na 6 zadaniach (pakiet `qml-benchmarks`, źródło `two_curves`); pokazuje między innymi, że usunięcie splątania często nie szkodzi. **Związek z projektem:** uzasadnia wybór `two_curves`, schemat angle encoding z data re-uploading oraz traktowanie wzorca entangling jako obiektu badań, a nie źródła przewagi.

Literatura

[1] Z. Cai, R. Babbush, S. C. Benjamin, S. Endo, W. J. Huggins, Y. Li, J. R. McClean, T. E. O'Brien, *Quantum Error Mitigation*, arXiv:2210.00921 (2023).

[2] T. Giurgica-Tiron, Y. Hindy, R. LaRose, A. Mari, W. J. Zeng, *Digital zero noise extrapolation for quantum error mitigation*, IEEE QCE / arXiv:2005.10921 (2020).

[3] J. M. Koh, D. E. Koh, J. Thompson, *Readout Error Mitigation for Mid-Circuit Measurements and Feedforward*, arXiv:2406.07611 (2024).

[4] J. Bowles, S. Ahmed, M. Schuld, *Better than classical? The subtle art of benchmarking quantum machine learning models*, arXiv:2403.07059 (2024).

[5] Y. Li, S. C. Benjamin, *Efficient variational quantum simulator incorporating active error minimisation*, Phys. Rev. X **7**, 021050 / arXiv:1611.09301 (2017).

[6] Google Quantum AI, *Quantum error correction below the surface code threshold*, Nature **638**, 920 / arXiv:2408.13687 (2025).

[7] *On-Device Verification of Variational Quantum Classifiers*, (2026). Źródło modeli i danych Banknote: https://github.com/Kolo-Naukowe-Axion/QC1_Quantum_Banknote_Classifier_on_ODRA_5.