Przygotowanie benchmarku i protokołu eksperymentalnego do oceny wpływu topologii sprzętu oraz kodowania logicznego na jakość obliczeń kwantowych

Sprawozdanie z Miesiąca 2

Karina Leśkiewicz

Sierpień 2026

1 Wprowadzenie: druga metoda mitygacji — Clifford Data Regression

Miesiąc 2 rozszerza badanie z pojedynczej metody mitygacji do *porównania* strategii mitygacji i bliskoterminowej ochrony logicznej wzdłuż tej samej osi kosztu routingu. W Miesiącu 1 potok stanowiła para REM+ZNE; teraz dokładam drugą metodę mitygacji błędów — **Clifford Data Regression (CDR)** — oraz warstwę „logical-ish" opartą na detekcji błędów (kod $[[4, 2, 2]]$, sekcja osobna). Wszystkie metody oceniam na tych samych metrykach jakości (błąd $\langle O \rangle$, dokładność, mirror fidelity) oraz na *wspólnej walucie kosztu* — liczbie shotów QPU potrzebnych do osiągnięcia zadanej tolerancji — tak, aby były wprost porównywalne mimo różnych narzutów natywnych.

Pozycjonowanie i wkład. Samo *istnienie* progu, przy którym mitygacja przestaje się opłacać, nie jest wynikiem nowym — wynika wprost z ram bias/wariancja [1] (rosnący narzut próbkowania C_{em} w ZNE) oraz z teorii jałowych płaskowyżów indukowanych szumem [9]: przy dostatecznej głębokości stan zbiega do maksymalnie zmieszanego i *każda* metoda musi zawieść. Wkładem tej pracy nie jest więc odkrycie, że próg istnieje, lecz jego **ilościowy, rozdzielony po urządzeniach i topologiach pomiar**: gdzie dokładnie leży punkt opłacalności — na gwieździe IQM Spark (ODRA) wobec kraty kwadratowej (Garnet, Emerald) — jest wielkością specyficzną dla urządzenia, kalibracji i topologii, której nie sposób podać bez pomiaru. Kluczowe przeramowanie polega na tym, że **osią kosztu jest narzut routingu (bramki SWAP), a nie sama głębokość obwodu**: ten sam obwód logiczny przekracza próg w *różnych* punktach na różnych topologiach wyłącznie z powodu rozmieszczenia (placementu) kubitów. Widać to już w samej drabinie kosztu: identyczny obwód wzorca `star` kompiluje się do 12 CZ przy rozmieszczeniu zwartym, ale do 78 CZ przy rozproszonym na Emeraldzie (sekcja mapowania). To porównanie — próg opłacalności mitygacji jako funkcja *topologii i metody*, mierzony wzdłuż osi narzutu routingu — stanowi właściwy wkład sprawozdania; wynik progowy z Miesiąca 1 (≈85–90 CZ na gwieździe) jest jego punktem odniesienia, a nie tezą samą w sobie.

Motywacja: inny profil narzutu niż ZNE. ZNE sztucznie zwiększa szum i ekstrapoluje do zera, więc jego estymator jest różnicą dużych liczb o naprzemiennych znakach; narzut wariancji C_{em} rośnie z kosztem obwodu i to on wyznacza górną granicę użyteczności ZNE (w Miesiącu 1 zmierzoną w okolicach 85–90 CZ, gdzie współczynnik redukcji błędu spadał do ≈1,0). CDR *nie* zwiększa szumu — zamiast tego *uczy się* korekty z danych — więc ma z zasady inny profil załamania. Jest to naturalny kandydat na drugą metodę: pytanie badawcze brzmi, która z metod załamuje się pierwsza wraz z rosnącym kosztem routingu.

Mechanizm. CDR [5] (Czarnik i in., *Error mitigation with Clifford quantum-circuit data*, Quantum **5**, 592, 2021; arXiv:2005.10189) buduje klasyczny model korekcji na **obwodach treningowych bliskich Cliffordowi**. Konstrukcja przebiega w trzech krokach:

1. **Generacja zbioru treningowego.** Z obwodu docelowego tworzę warianty o *identycznej strukturze* (ten sam wzorzec splątający, ta sama transpilacja i routing), w których obroty niekliffordowskie — w naszym VQC data-zależne $R_y(x)$ — zostają „przyciągnięte" do najbliższego kąta kliffordowskiego (wielokrotności $\pi/2$). Dzięki twierdzeniu Gottesmana–Knilla wartość oczekiwana takiego obwodu jest *dokładnie i efektywnie* obliczalna symulacją stabilizatorową, co daje bezszumową referencję $\langle O\rangle_{\text{ideal}}$ bez kosztu wektora stanu.

2. **Zbieranie par (szum, ideał).** Każdy obwód treningowy wykonuję na urządzeniu (lub w kalibrowanym symulatorze), otrzymując parę $\big(\langle O\rangle_{\text{noisy}}, \langle O\rangle_{\text{ideal}}\big)$. Ponieważ obwody treningowe mają ten sam profil szumu co docelowy, para ta próbkuje odwzorowanie szumu urządzenia.

3. **Dopasowanie i zastosowanie.** Dopasowuję regresję (w wariancie podstawowym *liniową*)

$$\langle O\rangle_{\text{ideal}} \approx a\,\langle O\rangle_{\text{noisy}} + b, \tag{1}$$

   a wyuczone współczynniki (a, b) stosuję do surowej wartości obwodu *docelowego*. Estymator CDR nie wymaga wzmacniania szumu, więc nie dziedziczy eksplozji wariancji ZNE.

Koszt i założenia. Narzutem CDR jest budżet obwodów treningowych: N obwodów bliskich Cliffordowi $\times$ liczba shotów każdego. Ten koszt wliczam do wspólnej waluty (shots-to-target), aby porównanie z ZNE było uczciwe. Kluczowe założenie CDR to *stacjonarność i wyuczalność* odwzorowania szumu: jeśli kalibracja dryfuje między pomiarem zbioru treningowego a obwodu docelowego, wyuczona korekta przestaje pasować. Dlatego — inaczej niż w ZNE — obwody treningowe i docelowy uruchamiam w tym samym oknie/zadaniu, a wrażliwość CDR na dryf (udokumentowany w sekcji 2) traktuję jako część wyniku, a nie usterkę pomiaru.

2 Pełna walidacja krzyżowa 5-fold na QPU (Banknote, wszystkie głębokości)

Rozszerzyłam walidację krzyżową z Miesiąca 1 (dotąd tylko $L = 6$, dwa ansätze) na **pełną siatkę**: trzy ansätze $\times$ trzy głębokości $\{2, 4, 6\}$ $\times$ wszystkie pięć foldów, wykonane na rzeczywistym QPU ODRA (IQM Spark). Metodyka jest identyczna z pracą źródłową i z Miesiącem 1: dla każdego foldu używam *jego własnych* wag (uczonych na zbiorze treningowym tego foldu) i oceniam na jego rozłącznym zbiorze testowym — pełnym foldzie (274–275 pkt, naturalna proporcja klas), więc bez wycieku danych i z sensowną macro-F1. Konfiguracja: DD wyłączone, 4096 shotów, potok raw $\rightarrow$ +REM $\rightarrow$ +ZNE (Richardson, skale $\{1, 3, 5\}$). Wynik podaję jako średnią $\pm$ odchylenie *międzyfoldowe* (ddof $= 1$). Dane: `banknote_hardware_cv_full.csv`; agregacja: `run_cv_banknote.py --aggregate-csv`.

Tabela 1: Banknote na ODRA — **pełna 5-fold CV**, wszystkie ansätze i głębokości (DD-off, 4096 shots, pełny fold). Dokładność i macro-F1 podane jako średnia ± odchylenie międzyfoldowe; kolumna err to średni $|\langle O\rangle$-błąd$|$ wobec ideału bezszumowego. ZNE = REM+ekstrapolacja Richardsona. Wiersze uporządkowane rosnącym kosztem CZ w obrębie każdej głębokości (drabina routingu star < odra < sim).

		dokładność		**macro-F1**		err $\langle O\rangle$
Ansatz	CZ	raw	ZNE	raw	ZNE	raw → ZNE
głębokość 2						
star	8	$0{,}840 \pm 0{,}035$	$0{,}843 \pm 0{,}031$	$0{,}834 \pm 0{,}041$	$0{,}838 \pm 0{,}033$	$0{,}072 \to 0{,}043$
odra	13	$0{,}855 \pm 0{,}029$	$0{,}875 \pm 0{,}020$	$0{,}854 \pm 0{,}029$	$0{,}873 \pm 0{,}021$	$0{,}112 \to 0{,}058$
simulator	20	$0{,}808 \pm 0{,}038$	$0{,}813 \pm 0{,}079$	$0{,}796 \pm 0{,}050$	$0{,}792 \pm 0{,}098$	$0{,}149 \to 0{,}163$
głębokość 4						
star	16	$0{,}886 \pm 0{,}009$	$0{,}886 \pm 0{,}035$	$0{,}885 \pm 0{,}010$	$0{,}881 \pm 0{,}039$	$0{,}126 \to 0{,}036$
odra	36	$0{,}682 \pm 0{,}187$	$0{,}744 \pm 0{,}100$	$0{,}645 \pm 0{,}223$	$0{,}729 \pm 0{,}107$	$0{,}259 \to 0{,}217$
simulator	52	$0{,}699 \pm 0{,}074$	$0{,}711 \pm 0{,}052$	$0{,}672 \pm 0{,}089$	$0{,}677 \pm 0{,}089$	$0{,}246 \to 0{,}220$
głębokość 6						
star	24	$0{,}868 \pm 0{,}058$	$0{,}886 \pm 0{,}039$	$0{,}862 \pm 0{,}071$	$0{,}883 \pm 0{,}044$	$0{,}161 \to 0{,}093$
odra	58	$0{,}731 \pm 0{,}050$	$0{,}776 \pm 0{,}063$	$0{,}698 \pm 0{,}062$	$0{,}760 \pm 0{,}068$	$0{,}226 \to 0{,}177$
simulator	86	$0{,}583 \pm 0{,}062$	$0{,}594 \pm 0{,}075$	$0{,}537 \pm 0{,}084$	$0{,}548 \pm 0{,}098$	$0{,}285 \to 0{,}281$

2.1 Wnioski

1. **Drabina routingu obowiązuje na każdej głębokości.** Dokładność surowa spada monotonicznie z kosztem CZ przy *każdej* głębokości i zachowuje ten sam porządek ansätze (dla $L = 6$: star 0,868 > odra 0,731 > simulator 0,583). Jest to najczystsze jak dotąd potwierdzenie, że transpilowany koszt CZ jest właściwą zmienną niezależną — teraz z pasmami błędu z pięciu foldów.

2. **ZNE odzyskuje dokładność dokładnie tam, gdzie istnieje luka — i wygasa na szczycie drabiny.** Największy zysk mają średnio- i wysokokosztowe pierścienie (odra L=4: 0,682 → 0,744; odra L=6: 0,731 → 0,776; +0,05–0,06). Dla tanich obwodów dokładność surowa jest już przy ideale, więc ZNE nic nie wnosi (star L=2, 4). W najdroższym punkcie — **simulator L=6, 86 CZ** — odzysk *zanika*: 0,583 → 0,594 (w granicach rozrzutu), a błąd $\langle O\rangle$ 0,285 → 0,281 (współczynnik ≈1,0). To bezpośredni pomiar granicy opłacalności ZNE w okolicach 85–90 CZ zapowiadanej w Miesiącu 1.

3. **Redukcja błędu $\langle O\rangle$ jest monotoniczna w koszcie i najsilniejsza przy tanich obwodach** (star L=4: 0,126 → 0,036, ≈3,5×; odra L=2: ≈1,9×; simulator L=6: ≈1,0×, martwa). Potwierdza to, że siła ZNE słabnie z routingiem niezależnie od tego, czy przekłada się na dokładność.

4. **Nadal nie odtwarzamy zapaści pierścieni z pracy źródłowej.** Najgorszy przypadek (simulator L=6) degraduje się w stronę floor klasy większościowej (0,56), osiągając F1 0,537, ale *nie* zapada do F1≈0,04 raportowanego w pracy; odra L=6 pozostaje zdrowy (F1 0,698). W żadnym wierszu DD-off macro-F1 nie odrywa się od dokładności — brak zapaści klasowej.

5. **Pierścień odra przy L=4 jest niestabilny międzyfoldowo.** Dokładność $0{,}682 \pm 0{,}187$ i F1 $0{,}645 \pm 0{,}223$ mają ogromny rozrzut: część foldów utrzymuje wynik, część się załamuje. Sam ten rozrzut jest wynikiem — wskazuje na indukowaną routingiem niestabilność, a nie stabilny punkt pracy, i jest kandydatem do dokładniejszego zbadania (drift, dobór kubitów) na Garnecie/Emeraldzie.

6. **Dryf urządzenia względem Miesiąca 1.** Te same wagi, ansätze i transpilacja, lecz pomiar L=6 z pełnej CV (12.08) daje niższe wartości niż CV z Miesiąca 1 (03.08): odra $0{,}809 \pm 0{,}042 \to 0{,}731 \pm 0{,}050$, simulator $0{,}626 \pm 0{,}091 \to 0{,}583 \pm 0{,}062$. Różnicę — przy identycznym potoku — przypisuję dryfowi kalibracji między dniami; jest to bezpośrednie, ilościowe potwierdzenie tezy o zależności zachowania on-device od stanu urządzenia. Wynikowo trend (drabina, okno ZNE, brak zapaści klasowej) jest niezmieniony; przesuwa się jedynie bezwzględny poziom.

3 Porównanie metod na symulatorze ODRA (`two_curves`)

Poniżej zestawiam trzy metody obsługi błędów — ZNE, CDR i detekcję $[[4, 2, 2]]$ — wzdłuż tej samej osi kosztu routingu, na wiernym symulatorze gwiazdy ODRA z *realną* kalibracją (`calibrations/odra.json`). Ustawienia dobrane pod wiarygodność: 8192 shotów (błąd statystyczny $\langle Z \rangle$ ≈0,005), 5 powtórzeń dla pasm błędu (ZNE), 200 obwodów treningowych (CDR), pełny 30-punktowy zbiór ewaluacyjny, $p_{2q} = 0{,}019$ (zmierzony błąd 2q ODRA) dla $[[4, 2, 2]]$. Emeralda (2^{54} stanów) *nie da się* zasymulować klasycznie — cross-topology musi przyjść ze sprzętu; symulator ODRA jest wierną kontrolą.

Tabela 2: ZNE: ablacja raw → DD+REM → ZNE (Richardson), pasma ±odchylenie po 5 powtórzeniach. Accuracy i macro-F1 (zbiór zbalansowany, więc F1 ≈ acc).

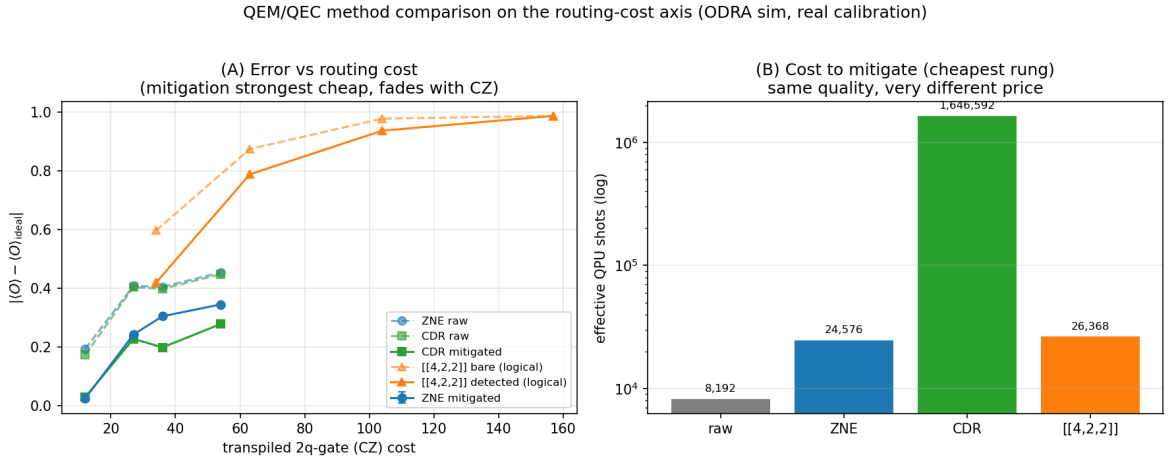
Wzorzec	CZ	raw	DD+REM	ZNE	acc (raw→ZNE)	F1 (raw→ZNE)
star	12	0,193	0,162	**0,024**	0,87→0,87	0,87→0,87
linear	27	0,408	0,378	0,243	0,89→0,90	0,89→0,90
circular	36	0,405	0,382	0,305	0,90→0,90	0,90→0,90
all_to_all	54	0,454	0,433	0,345	0,90→0,87	0,90→0,87

Tabela 3: CDR: błąd $\langle O \rangle$ raw → CDR, jakość dopasowania r^2, accuracy i macro-F1.

Wzorzec	CZ	raw	CDR	r^2	acc (raw→CDR)	F1 (raw→CDR)
star	12	0,172	**0,028**	0,98	0,87→0,87	0,87→0,87
linear	27	0,404	0,228	0,79	0,90→0,90	0,90→0,90
circular	36	0,398	0,199	0,66	0,90→0,90	0,90→0,90
all_to_all	54	0,448	0,278	0,49	0,90→0,90	0,90→0,90

Tabela 4: $[[4, 2, 2]]$ detekcja (Option C, mirror): logiczny błąd $\langle O \rangle$ (bez → z detekcją; ideał $\bar{Z}_1 = +1$), fidelity oraz współczynnik akceptacji (koszt post-selekcji).

Warstwy	CZ	logiczny $\langle O \rangle$-błąd		fidelity		akceptacja
		bez	z detekcją	bez	z detekcją	
1	34	0,597	**0,419**	0,396	0,637	0,62
2	63	0,874	0,788	0,226	0,410	0,55
3	104	0,978	0,937	0,151	0,296	0,51
4	157	0,987	0,987	0,131	0,261	0,51



Rysunek 1: Porównanie metod na osi kosztu routingu (ODRA sim, realna kalibracja). (A) błąd $\langle O \rangle$ vs koszt CZ: raw (kreskowany) i mitygowany (ciągły) dla ZNE, CDR oraz logiczny błąd $[[4, 2, 2]]$; wszystkie metody mitygują najmocniej przy tanim routingu i słabną z kosztem. (B) efektywne shoty (skala log) na najtańszym szczeblu — CDR osiąga ten sam błąd co ZNE, lecz $\sim$67$\times$ drożej.

Wnioski.

1. **Wszystkie trzy metody mitygują najmocniej przy tanim routingu i słabną przewidywalnie z kosztem CZ.** ZNE i CDR tną błąd $\langle O \rangle$ dramatycznie przy gwieździe (ZNE 0,193$\rightarrow$0,024; CDR 0,172$\rightarrow$0,028), a zysk maleje monotonicznie do $\sim$54 CZ. Detekcja $[[4, 2, 2]]$ powtarza ten wzorzec w logicznym $\langle O \rangle$-błędzie: 0,597$\rightarrow$0,419 (-30%) przy 34 CZ, aż do zaniku przy 157 CZ (obwód w pełni zdepolaryzowany, 0,987$\rightarrow$0,987).

2. **Accuracy i macro-F1 są nasycone.** Na zbalansowanym `two_curves` obie trzymają się 0,87–0,90 niezależnie od metody i szczebla, mimo redukcji błędu $\langle O \rangle$ nawet 6-krotnej — bo predykcja to $\operatorname{sgn}\langle O \rangle$, a punkty leżą daleko od granicy decyzyjnej. *Czułym wskaźnikiem jest ciągły $\langle O \rangle$-błąd, nie accuracy* (potwierdzenie tezy z Miesiąca 1). Przy all_to_all ZNE wręcz *obniża* accuracy (0,90$\rightarrow$0,87) — dodana wariancja przerzuca pojedynczy znak blisko sufitu.

3. **Na wspólnej walucie kosztu ZNE dominuje.** ZNE i CDR docierają do niemal tego samego błędu (a CDR bywa lekko lepszy przy dużym koszcie, bo nie wzmacnia szumu), lecz efektywny koszt to ZNE $=8192\times3 = 24\,576$ shotów wobec CDR $=8192\times201 = 1\,646\,592$ — $\sim$67$\times$ **drożej za ten sam wynik** (rys. 1B). r^2 CDR spada 0,98$\rightarrow$0,49 z kosztem — własny sygnał załamania metody.

4. $[[4, 2, 2]]$ **kupuje wierność kosztem shotów.** Detekcja podnosi fidelity $\sim$1,6$\times$ i tnie logiczny $\langle O \rangle$-błąd przy niskim koszcie, przy akceptacji $\sim$0,5 ($\sim$2$\times$ więcej shotów). Uwaga metodologiczna: accuracy jest *nieinformatywna* dla kodu detekcyjnego na surogacie Clifforda (wartości logiczne kolapsują do ±1 lub 0), więc właściwymi metrykami są logiczny $\langle O \rangle$-błąd, fidelity i koszt akceptacji.

Literatura

[1] Z. Cai, R. Babbush, S. C. Benjamin, S. Endo, W. J. Huggins, Y. Li, J. R. McClean, T. E. O'Brien, *Quantum Error Mitigation*, arXiv:2210.00921 (2023).

[2] K. Temme, S. Bravyi, J. M. Gambetta, *Error mitigation for short-depth quantum circuits*, Phys. Rev. Lett. **119**, 180509 (2017); arXiv:1612.02058.

[3] T. Giurgica-Tiron, Y. Hindy, R. LaRose, A. Mari, W. J. Zeng, *Digital zero-noise extrapolation for quantum error mitigation*, IEEE QCE (2020); arXiv:2005.10921.

[4] A. Kandala, K. Temme, A. D. Córcoles, A. Mezzacapo, J. M. Chow, J. M. Gambetta, *Error mitigation extends the computational reach of a noisy quantum processor*, Nature **567**, 491 (2019); arXiv:1805.04492.

[5] P. Czarnik, A. Arrasmith, P. J. Coles, L. Cincio, *Error mitigation with Clifford quantum-circuit data*, Quantum **5**, 592 (2021); arXiv:2005.10189.

[6] F. B. Maciejewski, Z. Zimborás, M. Oszmaniec, *Mitigation of readout noise in near-term quantum devices by classical post-processing based on detector tomography*, Quantum **4**, 257 (2020); arXiv:1907.08518.

[7] P. D. Nation, H. Kang, N. Sundaresan, J. M. Gambetta, *Scalable mitigation of measurement errors on quantum computers*, PRX Quantum **2**, 040326 (2021); arXiv:2108.12518.

[8] G. Li, Y. Ding, Y. Xie, *Tackling the qubit mapping problem for NISQ-era quantum devices (SABRE)*, ASPLOS (2019); arXiv:1809.02573.

[9] S. Wang, E. Fontana, M. Cerezo, K. Sharma, A. Sone, L. Cincio, P. J. Coles, *Noise-induced barren plateaus in variational quantum algorithms*, Nat. Commun. **12**, 6961 (2021); arXiv:2007.14384.

[10] J. R. McClean, S. Boixo, V. N. Smelyanskiy, R. Babbush, H. Neven, *Barren plateaus in quantum neural network training landscapes*, Nat. Commun. **9**, 4812 (2018); arXiv:1803.11173.

[11] C. Vuillot, *Is error detection helpful on IBM 5Q chips?*, Quantum Inf. Comput. **18**, 949 (2018); arXiv:1705.08957.

[12] N. M. Linke, M. Gutierrez, K. A. Landsman, C. Figgatt, S. Debnath, K. R. Brown, C. Monroe, *Fault-tolerant quantum error detection*, Sci. Adv. **3**, e1701074 (2017); arXiv:1611.06946.

[13] Google Quantum AI, *Quantum error correction below the surface code threshold*, Nature **638**, 920 (2025); arXiv:2408.13687.

[14] J. Bowles, S. Ahmed, M. Schuld, *Better than classical? The subtle art of benchmarking quantum machine learning models*, arXiv:2403.07059 (2024).

[15] M. Schuld, R. Sweke, J. J. Meyer, *The effect of data encoding on the expressive power of variational quantum machine learning models*, Phys. Rev. A **103**, 032430 (2021); arXiv:2008.08605.

[16] A. Pérez-Salinas, A. Cervera-Lierta, E. Gil-Fuster, J. I. Latorre, *Data re-uploading for a universal quantum classifier*, Quantum **4**, 226 (2020); arXiv:1907.02085.