Przygotowanie benchmarku i protokołu eksperymentalnego do oceny wpływu topologii sprzętu oraz kodowania logicznego na jakość obliczeń kwantowych

Sprawozdanie z Miesiąca 2

Karina Leśkiewicz

Sierpień 2026

NOTATKA ROBOCZA (usunąć przed wysłaniem): przed złożeniem pracy należy w całości sprawdzić i domknąć listę otwartych luk merytorycznych w pliku `project_review_gaps.md` (m.in. crossover metod, koszt cross-topology Emeralda, korelacja SWAP↔degradacja, pasma driftu, oraz niewykorzystane elementy gałęzi logicznej `[[4,2,2]]`).

1 Wprowadzenie: druga metoda mitygacji — Clifford Data Regression

Miesiąc 2 rozszerza badanie z pojedynczej metody mitygacji do *porównania* strategii mitygacji i bliskoterminowej ochrony logicznej wzdłuż tej samej osi kosztu routingu. W Miesiącu 1 potok stanowiła para REM+ZNE; teraz dokładam drugą metodę mitygacji błędów — **Clifford Data Regression (CDR)** — oraz warstwę „logical-ish" opartą na detekcji błędów (kod $[[4, 2, 2]]$, sekcja osobna). Wszystkie metody oceniam na tych samych metrykach jakości (błąd $\langle O \rangle$, dokładność, mirror fidelity) oraz na *wspólnej walucie kosztu* — liczbie shotów QPU potrzebnych do osiągnięcia zadanej tolerancji — tak, aby były wprost porównywalne mimo różnych narzutów natywnych.

Pozycjonowanie i wkład. Samo *istnienie* progu, przy którym mitygacja przestaje się opłacać, nie jest wynikiem nowym — wynika wprost z ram bias/wariancja [1] (rosnący narzut próbkowania C_{em} w ZNE) oraz z teorii jałowych płaskowyżów indukowanych szumem [13]: przy dostatecznej głębokości stan zbiega do maksymalnie zmieszanego i *każda* metoda musi zawieść. Wkładem tej pracy nie jest więc odkrycie, że próg istnieje, lecz jego **ilościowy, rozdzielony po urządzeniach i topologiach pomiar**: gdzie dokładnie leży punkt opłacalności — na gwieździe IQM Spark (ODRA) wobec kraty kwadratowej (Garnet, Emerald) — jest wielkością specyficzną dla urządzenia, kalibracji i topologii, której nie sposób podać bez pomiaru. Kluczowe przeramowanie polega na tym, że **osią kosztu jest narzut routingu (bramki SWAP), a nie sama głębokość obwodu**: ten sam obwód logiczny przekracza próg w *różnych* punktach na różnych topologiach wyłącznie z powodu rozmieszczenia (placementu) kubitów. Widać to już w samej drabinie kosztu: identyczny obwód wzorca `star` kompiluje się do 12 CZ przy rozmieszczeniu zwartym, ale do 78 CZ przy rozproszonym na Emeraldzie (sekcja mapowania). To porównanie — próg opłacalności mitygacji jako funkcja *topologii i metody*, mierzony wzdłuż osi narzutu routingu — stanowi właściwy wkład sprawozdania; wynik progowy z Miesiąca 1 (≈85–90 CZ na gwieździe) jest jego punktem odniesienia, a nie tezą samą w sobie.

Motywacja: inny profil narzutu niż ZNE. ZNE sztucznie zwiększa szum i ekstrapoluje do zera, więc jego estymator jest różnicą dużych liczb o naprzemiennych znakach; narzut wariancji

C_{em} rośnie z kosztem obwodu i to on wyznacza górną granicę użyteczności ZNE (w Miesiącu 1 zmierzoną w okolicach 85–90 CZ, gdzie współczynnik redukcji błędu spadał do ≈1,0). CDR *nie* zwiększa szumu — zamiast tego *uczy się* korekty z danych — więc ma z zasady inny profil załamania. Jest to naturalny kandydat na drugą metodę: pytanie badawcze brzmi, która z metod załamuje się pierwsza wraz z rosnącym kosztem routingu.

Mechanizm. CDR [9] (Czarnik i in., *Error mitigation with Clifford quantum-circuit data*, Quantum **5**, 592, 2021; arXiv:2005.10189) buduje klasyczny model korekcji na **obwodach treningowych bliskich Cliffordowi**. Konstrukcja przebiega w trzech krokach:

1. **Generacja zbioru treningowego.** Z obwodu docelowego tworzę warianty o *identycznej strukturze* (ten sam wzorzec splątający, ta sama transpilacja i routing), w których obroty niekliffordowskie — w naszym VQC data-zależne $R_y(x)$ — zostają „przyciągnięte" do najbliższego kąta kliffordowskiego (wielokrotności $\pi/2$). Dzięki twierdzeniu Gottesmana–Knilla wartość oczekiwana takiego obwodu jest *dokładnie i efektywnie* obliczalna symulacją stabilizatorową, co daje bezszumową referencję $\langle O\rangle_{\text{ideal}}$ bez kosztu wektora stanu.

2. **Zbieranie par (szum, ideał).** Każdy obwód treningowy wykonuję na urządzeniu (lub w kalibrowanym symulatorze), otrzymując parę $\big(\langle O\rangle_{\text{noisy}}, \langle O\rangle_{\text{ideal}}\big)$. Ponieważ obwody treningowe mają ten sam profil szumu co docelowy, para ta próbkuje odwzorowanie szumu urządzenia.

3. **Dopasowanie i zastosowanie.** Dopasowuję regresję (w wariancie podstawowym *liniową*)

$$\langle O\rangle_{\text{ideal}} \approx a\,\langle O\rangle_{\text{noisy}} + b, \tag{1}$$

   a wyuczone współczynniki (a, b) stosuję do surowej wartości obwodu *docelowego*. Estymator CDR nie wymaga wzmacniania szumu, więc nie dziedziczy eksplozji wariancji ZNE.

Koszt i założenia. Narzutem CDR jest budżet obwodów treningowych: N obwodów bliskich Cliffordowi × liczba shotów każdego. Ten koszt wliczam do wspólnej waluty (shots-to-target), aby porównanie z ZNE było uczciwe. Kluczowe założenie CDR to *stacjonarność i wyuczalność* odwzorowania szumu: jeśli kalibracja dryfuje między pomiarem zbioru treningowego a obwodu docelowego, wyuczona korekta przestaje pasować. Dlatego — inaczej niż w ZNE — obwody treningowe i docelowy uruchamiam w tym samym oknie/zadaniu, a wrażliwość CDR na dryf (udokumentowany w sekcji 2) traktuję jako część wyniku, a nie usterkę pomiaru.

2 Pełna walidacja krzyżowa 5-fold na QPU (Banknote, wszystkie głębokości)

Rozszerzyłam walidację krzyżową z Miesiąca 1 (dotąd tylko $L = 6$, dwa ansätze) na **pełną siatkę**: trzy ansätze × trzy głębokości $\{2, 4, 6\}$ × wszystkie pięć foldów, wykonane na rzeczywistym QPU ODRA (IQM Spark). Metodyka jest identyczna z pracą źródłową i z Miesiącem 1: dla każdego foldu używam *jego własnych* wag (uczonych na zbiorze treningowym tego foldu) i oceniam na jego rozłącznym zbiorze testowym — pełnym foldzie (274–275 pkt, naturalna proporcja klas), więc bez wycieku danych i z sensowną macro-F1. Konfiguracja: DD wyłączone, 4096 shotów, potok raw → +REM → +ZNE (Richardson, skale $\{1, 3, 5\}$). Wynik podaję jako średnią ± odchylenie *międzyfoldowe* (ddof = 1). Dane: `banknote_hardware_cv_full.csv`; agregacja: `run_cv_banknote.py --aggregate-csv`.

Tabela 1: Banknote na ODRA — **pełna 5-fold CV**, wszystkie ansätze i głębokości (DD-off, 4096 shots, pełny fold). Dokładność i macro-F1 podane jako średnia ± odchylenie międzyfoldowe; kolumna err to średni $|\langle O\rangle$-błąd$|$ wobec ideału bezszumowego. ZNE = REM+ekstrapolacja Richardsona. Wiersze uporządkowane rosnącym kosztem CZ w obrębie każdej głębokości (drabina routingu star < odra < sim).

		dokładność		**macro-F1**		err $\langle O\rangle$
Ansatz	CZ	raw	ZNE	raw	ZNE	raw → ZNE
głębokość 2						
star	8	$0{,}840 \pm 0{,}035$	$0{,}843 \pm 0{,}031$	$0{,}834 \pm 0{,}041$	$0{,}838 \pm 0{,}033$	$0{,}072 \to 0{,}043$
odra	13	$0{,}855 \pm 0{,}029$	$0{,}875 \pm 0{,}020$	$0{,}854 \pm 0{,}029$	$0{,}873 \pm 0{,}021$	$0{,}112 \to 0{,}058$
simulator	20	$0{,}808 \pm 0{,}038$	$0{,}813 \pm 0{,}079$	$0{,}796 \pm 0{,}050$	$0{,}792 \pm 0{,}098$	$0{,}149 \to 0{,}163$
głębokość 4						
star	16	$0{,}886 \pm 0{,}009$	$0{,}886 \pm 0{,}035$	$0{,}885 \pm 0{,}010$	$0{,}881 \pm 0{,}039$	$0{,}126 \to 0{,}036$
odra	36	$0{,}682 \pm 0{,}187$	$0{,}744 \pm 0{,}100$	$0{,}645 \pm 0{,}223$	$0{,}729 \pm 0{,}107$	$0{,}259 \to 0{,}217$
simulator	52	$0{,}699 \pm 0{,}074$	$0{,}711 \pm 0{,}052$	$0{,}672 \pm 0{,}089$	$0{,}677 \pm 0{,}089$	$0{,}246 \to 0{,}220$
głębokość 6						
star	24	$0{,}868 \pm 0{,}058$	$0{,}886 \pm 0{,}039$	$0{,}862 \pm 0{,}071$	$0{,}883 \pm 0{,}044$	$0{,}161 \to 0{,}093$
odra	58	$0{,}731 \pm 0{,}050$	$0{,}776 \pm 0{,}063$	$0{,}698 \pm 0{,}062$	$0{,}760 \pm 0{,}068$	$0{,}226 \to 0{,}177$
simulator	86	$0{,}583 \pm 0{,}062$	$0{,}594 \pm 0{,}075$	$0{,}537 \pm 0{,}084$	$0{,}548 \pm 0{,}098$	$0{,}285 \to 0{,}281$

2.1 Wnioski

1. **Drabina routingu obowiązuje na każdej głębokości.** Dokładność surowa spada monotonicznie z kosztem CZ przy *każdej* głębokości i zachowuje ten sam porządek ansätze (dla $L = 6$: star 0,868 > odra 0,731 > simulator 0,583). Jest to najczystsze jak dotąd potwierdzenie, że transpilowany koszt CZ jest właściwą zmienną niezależną — teraz z pasmami błędu z pięciu foldów.

2. **ZNE odzyskuje dokładność dokładnie tam, gdzie istnieje luka — i wygasa na szczycie drabiny.** Największy zysk mają średnio- i wysokokosztowe pierścienie (odra L=4: 0,682 → 0,744; odra L=6: 0,731 → 0,776; +0,05–0,06). Dla tanich obwodów dokładność surowa jest już przy ideale, więc ZNE nic nie wnosi (star L=2, 4). W najdroższym punkcie — **simulator L=6, 86 CZ** — odzysk *zanika*: 0,583 → 0,594 (w granicach rozrzutu), a błąd $\langle O\rangle$ 0,285 → 0,281 (współczynnik ≈1,0). To bezpośredni pomiar granicy opłacalności ZNE w okolicach 85–90 CZ zapowiadanej w Miesiącu 1.

3. **Redukcja błędu $\langle O\rangle$ jest monotoniczna w koszcie i najsilniejsza przy tanich obwodach** (star L=4: 0,126 → 0,036, ≈3,5×; odra L=2: ≈1,9×; simulator L=6: ≈1,0×, martwa). Potwierdza to, że siła ZNE słabnie z routingiem niezależnie od tego, czy przekłada się na dokładność.

4. **Nadal nie odtwarzamy zapaści pierścieni z pracy źródłowej.** Najgorszy przypadek (simulator L=6) degraduje się w stronę floor klasy większościowej (0,56), osiągając F1 0,537, ale *nie* zapada do F1≈0,04 raportowanego w pracy; odra L=6 pozostaje zdrowy (F1 0,698). W żadnym wierszu DD-off macro-F1 nie odrywa się od dokładności — brak zapaści klasowej.

5. **Pierścień odra przy L=4 jest niestabilny międzyfoldowo.** Dokładność $0{,}682 \pm 0{,}187$ i F1 $0{,}645 \pm 0{,}223$ mają ogromny rozrzut: część foldów utrzymuje wynik, część się załamuje. Sam ten rozrzut jest wynikiem — wskazuje na indukowaną routingiem niestabilność, a nie stabilny punkt pracy, i jest kandydatem do dokładniejszego zbadania (drift, dobór kubitów) na Garnecie/Emeraldzie.

6. **Dryf urządzenia względem Miesiąca 1.** Te same wagi, ansätze i transpilacja, lecz pomiar L=6 z pełnej CV (12.08) daje niższe wartości niż CV z Miesiąca 1 (03.08): odra $0{,}809 \pm 0{,}042 \to 0{,}731 \pm 0{,}050$, simulator $0{,}626 \pm 0{,}091 \to 0{,}583 \pm 0{,}062$. Różnicę — przy identycznym potoku — przypisuję dryfowi kalibracji między dniami; jest to bezpośrednie, ilościowe potwierdzenie tezy o zależności zachowania on-device od stanu urządzenia. Wynikowo trend (drabina, okno ZNE, brak zapaści klasowej) jest niezmieniony; przesuwa się jedynie bezwzględny poziom.

3 Porównanie metod na symulatorze ODRA (`two_curves`)

Poniżej zestawiam trzy metody obsługi błędów — ZNE, CDR i detekcję $[[4, 2, 2]]$ — wzdłuż tej samej osi kosztu routingu, na wiernym symulatorze gwiazdy ODRA z *realną* kalibracją (`calibrations/odra.json`). Ustawienia dobrane pod wiarygodność: 8192 shotów (błąd statystyczny $\langle Z \rangle$ ≈0,005), 5 powtórzeń dla pasm błędu (ZNE), 200 obwodów treningowych (CDR), pełny 30-punktowy zbiór ewaluacyjny, $p_{2q} = 0{,}019$ (zmierzony błąd 2q ODRA) dla $[[4, 2, 2]]$. Emeralda (2^{54} stanów) *nie da się* zasymulować klasycznie — cross-topology musi przyjść ze sprzętu; symulator ODRA jest wierną kontrolą.

Tabela 2: ZNE: ablacja raw → DD+REM → ZNE (Richardson), pasma ±odchylenie po 5 powtórzeniach. Accuracy i macro-F1 (zbiór zbalansowany, więc F1 ≈ acc).

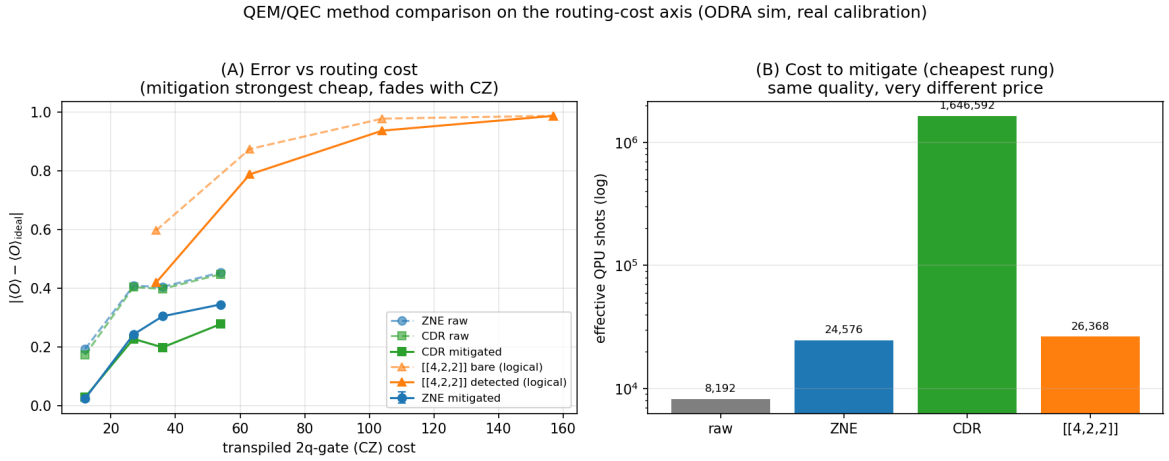
Wzorzec	CZ	raw	DD+REM	ZNE	acc (raw→ZNE)	F1 (raw→ZNE)
star	12	0,193	0,162	**0,024**	0,87→0,87	0,87→0,87
linear	27	0,408	0,378	0,243	0,89→0,90	0,89→0,90
circular	36	0,405	0,382	0,305	0,90→0,90	0,90→0,90
all_to_all	54	0,454	0,433	0,345	0,90→0,87	0,90→0,87

Tabela 3: CDR: błąd $\langle O \rangle$ raw → CDR, jakość dopasowania r^2, accuracy i macro-F1.

Wzorzec	CZ	raw	CDR	r^2	acc (raw→CDR)	F1 (raw→CDR)
star	12	0,172	**0,028**	0,98	0,87→0,87	0,87→0,87
linear	27	0,404	0,228	0,79	0,90→0,90	0,90→0,90
circular	36	0,398	0,199	0,66	0,90→0,90	0,90→0,90
all_to_all	54	0,448	0,278	0,49	0,90→0,90	0,90→0,90

Tabela 4: $[[4, 2, 2]]$ detekcja (Option C, mirror): logiczny błąd $\langle O \rangle$ (bez → z detekcją; ideał $\bar{Z}_1 = +1$), fidelity oraz współczynnik akceptacji (koszt post-selekcji).

Warstwy	CZ	logiczny $\langle O \rangle$-błąd		fidelity		akceptacja
		bez	z detekcją	bez	z detekcją	
1	34	0,597	**0,419**	0,396	0,637	0,62
2	63	0,874	0,788	0,226	0,410	0,55
3	104	0,978	0,937	0,151	0,296	0,51
4	157	0,987	0,987	0,131	0,261	0,51



Rysunek 1: Porównanie metod na osi kosztu routingu (ODRA sim, realna kalibracja). (A) błąd $\langle O \rangle$ vs koszt CZ: raw (kreskowany) i mitygowany (ciągły) dla ZNE, CDR oraz logiczny błąd $[[4, 2, 2]]$; wszystkie metody mitygują najmocniej przy tanim routingu i słabną z kosztem. (B) efektywne shoty (skala log) na najtańszym szczeblu — CDR osiąga ten sam błąd co ZNE, lecz $\sim$67$\times$ drożej.

Wnioski.

1. **Wszystkie trzy metody mitygują najmocniej przy tanim routingu i słabną przewidywalnie z kosztem CZ.** ZNE i CDR tną błąd $\langle O \rangle$ dramatycznie przy gwieździe (ZNE 0,193$\rightarrow$0,024; CDR 0,172$\rightarrow$0,028), a zysk maleje monotonicznie do $\sim$54 CZ. Detekcja $[[4, 2, 2]]$ powtarza ten wzorzec w logicznym $\langle O \rangle$-błędzie: 0,597$\rightarrow$0,419 (-30%) przy 34 CZ, aż do zaniku przy 157 CZ (obwód w pełni zdepolaryzowany, 0,987$\rightarrow$0,987).

2. **Accuracy i macro-F1 są nasycone.** Na zbalansowanym `two_curves` obie trzymają się 0,87–0,90 niezależnie od metody i szczebla, mimo redukcji błędu $\langle O \rangle$ nawet 6-krotnej — bo predykcja to $\operatorname{sgn}\langle O \rangle$, a punkty leżą daleko od granicy decyzyjnej. *Czułym wskaźnikiem jest ciągły $\langle O \rangle$-błąd, nie accuracy* (potwierdzenie tezy z Miesiąca 1). Przy all_to_all ZNE wręcz *obniża* accuracy (0,90$\rightarrow$0,87) — dodana wariancja przerzuca pojedynczy znak blisko sufitu.

3. **Na wspólnej walucie kosztu ZNE dominuje.** ZNE i CDR docierają do niemal tego samego błędu (a CDR bywa lekko lepszy przy dużym koszcie, bo nie wzmacnia szumu), lecz efektywny koszt to ZNE $=8192\times3 = 24\,576$ shotów wobec CDR $=8192\times201 = 1\,646\,592$ — $\sim$67$\times$ **drożej za ten sam wynik** (rys. 1B). r^2 CDR spada 0,98$\rightarrow$0,49 z kosztem — własny sygnał załamania metody.

4. $[[4, 2, 2]]$ **kupuje wierność kosztem shotów.** Detekcja podnosi fidelity $\sim$1,6$\times$ i tnie logiczny $\langle O \rangle$-błąd przy niskim koszcie, przy akceptacji $\sim$0,5 ($\sim$2$\times$ więcej shotów). Uwaga metodologiczna: accuracy jest *nieinformatywna* dla kodu detekcyjnego na surogacie Clifforda (wartości logiczne kolapsują do ±1 lub 0), więc właściwymi metrykami są logiczny $\langle O \rangle$-błąd, fidelity i koszt akceptacji.

4 Circuit twirling: tłumienie błędów koherentnych (wyprowadzenie)

Motywacja. Błąd bramki opisuje kanał kwantowy (odwzorowanie CPTP) $\mathcal{E}$. Rozróżniamy dwa reżimy. Błąd *koherentny* jest sam unitarny, $\mathcal{E}(\rho) = V\rho V^\dagger$ (np. systematyczna nad-rotacja

$V = e^{-i\theta Z/2}$): jest odwracalny, dodaje się w *amplitudzie* (po N bramkach prawdopodobieństwo błędu $\sim (N\theta)^2$) i *systematycznie przesuwa* $\langle O\rangle$. Błąd *stochastyczny* to mieszanina Pauliego $\mathcal{E}(\rho) = \sum_k p_k P_k \rho P_k$: dodaje się w *prawdopodobieństwie* ($\sim Np$). Kluczowe: ZNE zakłada gładkie skalowanie szumu, a CDR liniową relację $\langle O\rangle_{\text{ideal}} \approx a\langle O\rangle_{\text{noisy}} + b$ — błędy koherentne łamią oba założenia.

Macierz procesu χ. Dowolny kanał zapisujemy w bazie Pauliego [5]:

$$\mathcal{E}(\rho) = \sum_{a,b} \chi_{ab}\, P_a\, \rho\, P_b. \tag{2}$$

Dla kanału unitarnego z $V = \sum_a c_a P_a$ mamy $\chi_{ab} = c_a c_b^*$ (iloczyn zewnętrzny wektora współczynników). Diagonala $\chi_{aa} = |c_a|^2$ to stochastyczne prawdopodobieństwa błędów Pauliego; elementy *poza-diagonalne* χ_{ab} ($a \neq b$) kodują część *koherentną*. Przykład: $V = e^{-i\theta Z/2} = \cos\frac{\theta}{2}\, I - i \sin\frac{\theta}{2}\, Z$ daje $\chi_{II} = \cos^2\frac{\theta}{2}$, $\chi_{ZZ} = \sin^2\frac{\theta}{2}$ oraz niezerowe $\chi_{IZ} = \chi_{ZI}^* = i\cos\frac{\theta}{2}\sin\frac{\theta}{2}$.

Twirl Pauliego zeruje poza-diagonalę. Twirlowany kanał to średnia po grupie Pauliego [4, 2]:

$$\mathcal{E}_T(\rho) = \frac{1}{4^n} \sum_k P_k^\dagger\, \mathcal{E}(P_k \rho P_k)\, P_k. \tag{3}$$

Korzystając z $P_k P_a P_k = (-1)^{\langle a,k\rangle} P_a$ (gdzie $\langle a,k\rangle \in \{0,1\}$ to symplektyczny iloczyn: 0 dla komutacji, 1 dla antykomutacji):

$$\mathcal{E}_T(\rho) = \sum_{a,b} \chi_{ab} \underbrace{\left[\tfrac{1}{4^n}\textstyle\sum_k (-1)^{\langle a\oplus b,\, k\rangle}\right]}_{=\,\delta_{ab}} P_a \rho P_b = \sum_a \chi_{aa}\, P_a \rho P_a. \tag{4}$$

Suma wewnętrzna to ortogonalność charakterów: znika, chyba że $a = b$. Intuicyjnie — pole χ_{aa} mnoży się przez $(\pm 1)^2 = +1$ (zawsze przeżywa), pole χ_{ab} ($a \neq b$) przez naprzemienne ± 1, które sumują się do zera. Zatem twirl **kasuje część koherentną**, zostawiając czysto stochastyczny kanał Pauliego. Nad-rotacja θ staje się losowym Z-flipem o prawdopodobieństwie $\sin^2\frac{\theta}{2}$, a akumulacja błędu spada z $\sim (N\theta)^2$ do $\sim N\theta^2/4$.

Randomized compiling (implementacja). Kanału nie uśrednia się wprost — *randomizujemy obwód* [2]: każdą *Cliffordowską* bramkę 2-kubitową G zastępujemy $B\,G\,A$ z losową Paulią A i kompensacją $B = GAG^\dagger$; wtedy $BGA = G$ (ideał zachowany), a szum na G jest twirlowany. B jest Paulią *tylko dlatego, że G jest Cliffordem*. Bramki jednokubitowe (rotacje R_x, non-Clifford) *wchłaniają* losowe Pauli do warstwy jednokubitowej — bez dodatkowej głębi — i *nie* są twirlowane bezpośrednio (dla non-Clifforda $GAG^\dagger$ nie jest Paulią). Uśrednienie $\langle O\rangle$ po M losowych instancjach realizuje kanał twirlowany. Reżim eksperymentalny (odniesienie): RC na sprzęcie nadprzewodzącym stosuje $M \sim 20$ randomizacji (5–10 wystarcza do zbieżności) i ~ 8192 shotów na obwód [3]; CDR typowo ~ 10 obwodów treningowych near-Clifford [9]. Nasza kampania celuje w ten reżim w pełnej wersji (metodologia §9b); pilot używa świadomie okrojonych $M = 8$, shots 2048.

Konsekwencja dla ZNE i CDR. Po twirlingu szum jest Pauliego, więc $\langle O\rangle(\lambda)$ maleje monotonicznie (poprawna ekstrapolacja ZNE), a relacja $\langle O\rangle_{\text{ideal}}$–$\langle O\rangle_{\text{noisy}}$ jest liniowa (poprawny fit CDR). W symulacji z wstrzykniętą nad-rotacją $\theta = 0{,}15$ rad/CX twirl+ZNE poprawia $\langle O\rangle$-błąd $\sim 2{,}2\times$ względem samego ZNE, a twirl+CDR przywraca r^2 dopasowania z 0,81 do 0,99 (błąd $0{,}109 \to 0{,}015$). To sugeruje, że obserwowany *spadek* r^2 CDR z kosztem 2q na sprzęcie (rozdz. o porównaniu metod) jest sygnaturą błędu koherentnego, którą twirling powinien odwrócić — hipotezę tę zweryfikowaliśmy bezpośrednio na Garnecie (poniżej).

Pilot na sprzęcie (Garnet). IQM Resonance nie wystawia twirlingu serwerowo (tylko dynamical decoupling), więc realizujemy go *client-side*: losowe Pauli wokół każdej bramki dwukubitowej, uśredniane po M instancjach. Drabina trzech punktów kosztu routingu (12/57/96 transpiled CZ na modelu `two_curves` offset 0,1), $n_{\text{train}} = 10$, $M = 6$, 3 punkty ewaluacji, 1024 shoty. Dla CDR (najostrzejsza metryka — jakość dopasowania r^2):

transpiled CZ	r^2 (bez twirl)	r^2 (twirl)	Δr^2
12 (optimal, star)	0,957	0,986	+0,029
57 (optimal, all-to-all)	0,820	0,939	+0,119
96 (adverse, all-to-all)	0,837	0,909	+0,072

r^2 bez twirlingu spada z kosztem routingu (sygnatura błędu koherentnego łamiącego liniowość CDR), a twirling przywraca je na każdym punkcie, z zyskiem rosnącym przy wysokim CZ — co potwierdza mechanizm na prawdziwym sprzęcie; błąd $\langle O \rangle$ CDR maleje po twirlingu na każdym punkcie (np. 0,069 → 0,056 przy 96 CZ). Dla ZNE wynik jest *mieszany* (twirling pomaga przy 12 CZ: 0,083 → 0,048, ale szkodzi przy 57/96 CZ), co przypisujemy osłabieniu twirlingu logicznego pod foldingiem ZNE oraz ograniczonej statystyce pilota — wątek do rozstrzygnięcia w wersji pełnej (twirling natywny, unitarity RB, pasma driftu; metodologia §9).

Hipotezy. Wyniki (sim + pilot sprzętowy) prowadzą do następujących hipotez, które wersja pełna ma zweryfikować ilościowo:

H1 Narzut routingu (liczba CZ) akumuluje *koherentny* błąd, który łamie liniowość dopasowania CDR — r^2 CDR maleje z kosztem 2q. *(Wsparte: r^2 spada 0,98 → 0,49 z kosztem; pilot 0,96 → 0,82–0,84.)*

H2 Circuit twirling zamienia błąd koherentny w stochastyczny i *przywraca* liniowość CDR (r^2 rośnie), z zyskiem rosnącym z kosztem CZ. *(Potwierdzone na Garnecie: $\Delta r^2 = +0{,}03/+0{,}12/+0{,}07$ przy 12/57/96 CZ.)*

H3 Zysk twirlingu jest proporcjonalny do *frakcji koherentnej* szumu — przewidywalny z unitarity u (mierzonej przez URB). *(Do sprawdzenia: predicted=measured.)*

H4 CDR jest bardziej wrażliwe na koherencję niż ZNE (dopasowanie liniowe pęka; ekstrapolacja ZNE jest odporniejsza) ⇒ twirling pomaga CDR bardziej niż ZNE. *(Wsparte: pilot CDR jednoznaczny, ZNE mieszany.)*

H5 twirling+ZNE składa się, gdy frakcja koherentna jest wysoka (sim: 6/6 seedów poprawy); na sprzęcie opłaca się tam, gdzie koherencja dominuje.

Decyzja: kampania twirlingu skupia się na CDR (nie ZNE). Podkreślamy, że *nie* rezygnujemy z ZNE jako metody — ZNE pozostaje na osi porównania metod (crossover ZNE/CDR). Rezygnujemy z *kombinacji* twirling+ZNE jako osobnego wyniku, z trzech spójnych powodów: (i) ekstrapolacja ZNE jest z natury *odporna* na błąd koherentny (nie opiera się na dopasowaniu liniowym, w przeciwieństwie do CDR, którego fit liniowy koherencja łamie — H4), więc twirling ma tam mało do zyskania; (ii) pomiar URB+RB wskazuje, że frakcja koherentna *na poziomie bramki* jest mała i utopiona w driftcie ($u - p^2 \approx 0{,}02$ przy driftcie $\approx 0{,}09$), a sim pokazuje zysk twirling+ZNE tylko przy *dużej* koherencji — czego Garnet nie ma; (iii) na sprzęcie twirling+ZNE *szkodził* przy wysokim koszcie 2q (narzut twirlingu > zysk, gdy koherencji mało). Wniosek: twirling wnosi wartość tam, gdzie metoda jest *wrażliwa na koherencję* (CDR), a nie tam, gdzie jest na nią odporna (ZNE). Kampania pełna (§9b) mierzy więc twirling+CDR z pasmami driftu oraz koherencję *na poziomie obwodu* (właściwy predyktor), pomijając kosztowne gate-URB (drift zaciera sygnał).

Plan weryfikacji i koszt (wersja pełna, §9b). (1) **Unitarity RB** na krawędziach Garneta (opt. i adverse) → zmierzona frakcja koherentna u [∼150 cr]; (2) **twirling natywny** zamiast logicznego; (3) pełna drabina CZ, M=10–20 randomizacji, n_{train}=10, wyższe shoty, 5–8 punktów ewaluacji [∼600–900 cr]; (4) **pasma driftu** (≥ 2 okna kalibracji) na kluczowym punkcie [∼200 cr]; (5) **test H3**: czy zysk twirlingu zgadza się z przewidywaniem z u. Łącznie ∼1000–1300 kredytów (pełny reżim literaturowy M=20/shots=8192 na całej drabinie przekroczyłby budżet, więc skalujemy). Wynik: sprzętowa, ilościowo przewidywalna charakteryzacja tego, kiedy twirling odzyskuje skuteczność mitygacji pod narzutem routingu.

Literatura

[1] Z. Cai, R. Babbush, S. C. Benjamin, S. Endo, W. J. Huggins, Y. Li, J. R. McClean, T. E. O'Brien, *Quantum Error Mitigation*, arXiv:2210.00921 (2023).

[2] J. J. Wallman, J. Emerson, *Noise tailoring for scalable quantum computation via randomized compiling*, Phys. Rev. A **94**, 052325 (2016); arXiv:1512.01098.

[3] A. Hashim, R. K. Naik, A. Morvan, J.-L. Ville, B. Mitchell, J. M. Kreikebaum, M. Davis, E. Smith, C. Iancu, K. P. O'Brien, I. Hincks, J. J. Wallman, J. Emerson, I. Siddiqi, *Randomized Compiling for Scalable Quantum Computing on a Noisy Superconducting Quantum Processor*, Phys. Rev. X **11**, 041039 (2021); arXiv:2010.00215.

[4] J. Emerson, M. Silva, O. Moussa, C. Ryan, M. Laforest, J. Baugh, D. G. Cory, R. Laflamme, *Symmetrized characterization of noisy quantum processes*, Science **317**, 1893 (2007); arXiv:0707.0685.

[5] M. A. Nielsen, I. L. Chuang, *Quantum Computation and Quantum Information*, Cambridge University Press (2010) — reprezentacja χ (macierz procesu).

[6] K. Temme, S. Bravyi, J. M. Gambetta, *Error mitigation for short-depth quantum circuits*, Phys. Rev. Lett. **119**, 180509 (2017); arXiv:1612.02058.

[7] T. Giurgica-Tiron, Y. Hindy, R. LaRose, A. Mari, W. J. Zeng, *Digital zero-noise extrapolation for quantum error mitigation*, IEEE QCE (2020); arXiv:2005.10921.

[8] A. Kandala, K. Temme, A. D. Córcoles, A. Mezzacapo, J. M. Chow, J. M. Gambetta, *Error mitigation extends the computational reach of a noisy quantum processor*, Nature **567**, 491 (2019); arXiv:1805.04492.

[9] P. Czarnik, A. Arrasmith, P. J. Coles, L. Cincio, *Error mitigation with Clifford quantum-circuit data*, Quantum **5**, 592 (2021); arXiv:2005.10189.

[10] F. B. Maciejewski, Z. Zimborás, M. Oszmaniec, *Mitigation of readout noise in near-term quantum devices by classical post-processing based on detector tomography*, Quantum **4**, 257 (2020); arXiv:1907.08518.

[11] P. D. Nation, H. Kang, N. Sundaresan, J. M. Gambetta, *Scalable mitigation of measurement errors on quantum computers*, PRX Quantum **2**, 040326 (2021); arXiv:2108.12518.

[12] G. Li, Y. Ding, Y. Xie, *Tackling the qubit mapping problem for NISQ-era quantum devices (SABRE)*, ASPLOS (2019); arXiv:1809.02573.

[13] S. Wang, E. Fontana, M. Cerezo, K. Sharma, A. Sone, L. Cincio, P. J. Coles, *Noise-induced barren plateaus in variational quantum algorithms*, Nat. Commun. **12**, 6961 (2021); arXiv:2007.14384.

[14] J. R. McClean, S. Boixo, V. N. Smelyanskiy, R. Babbush, H. Neven, *Barren plateaus in quantum neural network training landscapes*, Nat. Commun. **9**, 4812 (2018); arXiv:1803.11173.

[15] C. Vuillot, *Is error detection helpful on IBM 5Q chips?*, Quantum Inf. Comput. **18**, 949 (2018); arXiv:1705.08957.

[16] N. M. Linke, M. Gutierrez, K. A. Landsman, C. Figgatt, S. Debnath, K. R. Brown, C. Monroe, *Fault-tolerant quantum error detection*, Sci. Adv. **3**, e1701074 (2017); arXiv:1611.06946.

[17] Google Quantum AI, *Quantum error correction below the surface code threshold*, Nature **638**, 920 (2025); arXiv:2408.13687.

[18] J. Bowles, S. Ahmed, M. Schuld, *Better than classical? The subtle art of benchmarking quantum machine learning models*, arXiv:2403.07059 (2024).

[19] M. Schuld, R. Sweke, J. J. Meyer, *The effect of data encoding on the expressive power of variational quantum machine learning models*, Phys. Rev. A **103**, 032430 (2021); arXiv:2008.08605.

[20] A. Pérez-Salinas, A. Cervera-Lierta, E. Gil-Fuster, J. I. Latorre, *Data re-uploading for a universal quantum classifier*, Quantum **4**, 226 (2020); arXiv:1907.02085.